

ДЗ 03. Разработка стратегии, оценка рисков и дорожной карты AI-проекта

Сдать до: 14.05.2026 Преподаватель: Николай Осипов Кейс: «Ритейлер и AI-рекомендации» — компания TechnoMart (топ-5 ритейлер бытовой техники, 2 млн MAU, 50 000+ SKU, 150 оффлайн-магазинов). PDF в ЛК.

Ключевые вводные из кейса

Параметр	Значение
Масштаб	2 млн MAU, 50K+ SKU, 150 оффлайн-магазинов
Текущая конверсия блока «с этим покупают»	0.5 % (rule-based)
Бизнес-цель	AOV +10 %, персонализация главной + рассылок, generative описания подборок
Стек As-Is	Bitrix-монолит на PHP + MySQL (БД «задыхается»), 1С (синк раз в 15 мин), GA — только агрегаты
Команда клиента	Сильные PHP-разработчики; нет DS, нет DE
Сроки	Первый результат через 3 месяца, иначе проект закрывают
Бюджет	Разработка — ОК; GPU-серверы — закупка до 2 мес, лучше стартовать в облаке
Безопасность	ПДн (ФИО, телефоны, адреса). Запрет на публичные LLM (ChatGPT и т.п.)
Стейкхолдеры	CEO (хайп, нетерпелив), CTO (скептик, защищает монолит), CMO (ежедневный AI-push)

Шаг 1. Уточняющие вопросы клиенту (7)

- KPI и горизонт.** AOV +10 % — за какой период считаем (квартал / полгода / год)? Текущий baseline AOV? Дополнительно: целевая конверсия блока рекомендаций (сейчас 0.5 %, какой минимум на MVP считается успехом — 1.5 % / 2 % / 3 %)?
- Кликстрим и данные о поведении.** Какая глубина истории доступна в GA, можно ли получить выгрузку «сырых» событий за 90+ дней? Готовы ли вы поставить наш SDK для сбора кликов на свои сервера с первой недели проекта (без этого PoC опирается только на заказы из 1С)?
- Оmnikanальность и user_id.** Какой % оффлайн-покупателей идентифицируется через программу лояльности / карту / телефон? Эти связки есть в 1С? Какой допустимый лаг сопоставления онлайн/оффлайн (15 мин / час / сутки)?
- Каталог и атрибуты SKU.** Что есть в ежедневном XML кроме базовых полей: бренд, категория, остатки, маржа, изображения, текстовые описания? Какой % SKU имеет качественные описания (нужно для generative descriptions и content-based)?
- Безопасность и допустимые модели.** Запрет на «публичные нейросети типа ChatGPT» — относится ли он к российским managed-LLM (Yandex GPT, GigaChat) при подписанном DPA, или строго self-hosted? Это решающий ADR.
- Эксплуатация после релиза.** Нет DS/DE в команде. Планируете ли наём (когда, в каком составе) или managed-сервис от нас (6–12 мес) с переходом на ваших ребят? Это сильно влияет на стек (managed-friendly vs DIY).
- Приоритет в рамках 3 месяцев.** Что важнее показать к decision gate: умная лента на главной (рост конверсии — нравится CEO/CMO) или generative descriptions для push-рассылок (быстрая «вау-демо» — нравится CMO)? Кто принимает решение при конфликте приоритетов CEO / CTO / CMO?

Шаг 2. Выбор контрактной модели

Рекомендация

Этап	Длит.	Модель	Cap / FP-бюджет	Чем закрываем
PoC	4 нед	T&M with a cap	Cap $\approx$ 15 % от плановой стоимости MVP	Подбор моделей, EDA, проверка гипотез на реальных данных. Без cap CEO не согласует, без T&M мы не возьмёмся — R&D-неопределённость по качеству GA-данных слишком высокая.
MVP-1	8 нед	Гибрид: FP на инфра+API+интеграцию с Bitrix через события, T&M на ML-составляющую	FP-часть фиксирована; ML — почасово с подекадной отчётностью	Интеграция и сервис-обязка прогнозируемы; модель и метрики — продолжающийся R&D с A/B-валидацией.
Production / scale	После защиты MVP	FP по фичам + T&M-абонемент на ML-эксплуатацию	Подписывается отдельно после demo dec.gate	Score известен. Эксплуатация (retraining, мониторинг, реакция на дрейф) — регулярный R&D.

Защита перед стейкхолдерами

Перед CEO (нетерпелив, хайп): «Вы платите за **результат**, а не за гипотезы. PoC с потолком в N руб. — если данных не хватает или модель не вытягивает, закрываем на 4 неделе, дальше не платите. После PoC — FP по фичам, цена фиксирована, никаких сюрпризов.»

Перед СТО (защищает монолит): «**Ядро Bitrix мы не трогаем.** AI — это отдельный микросервис в облаке, подписан на события из MySQL через очередь (read-only replica). Вызов из сайта — HTTP-API с timeout. Если AI отвалится — сайт работает как сейчас. Откатиться = снять флаг.»

Перед СМО (хочет push): «В PoC берём в работу один экран — главную. Push-рассылки с generative descriptions — параллельный трек MVP-2 (после защиты MVP-1) либо ускоренная фича по CR.»

Шаг 3. Карта рисков (AI-специфика + кейс-специфика)

Шкала 1–5; **Score** = Вер. $\times$ Влияние.

Шаг 4. Дорожная карта (3 месяца — критический горизонт CEO)

Месяц 1. PoC (4 нед.)

Цель: доказать, что персонализированный recsys даёт лифт vs текущие 0.5 % CTR rule-based.

Поле	Значение
Scope	Один экран — главная; один сегмент — залогиненные онлайн-пользователи; офлайн-оценка
Архитектурные решения	AI как отдельный микросервис в YC; чтение из read-replica MySQL; SDK сбора кликов на серверах TechnoMart с week 1; ALS / item-based collab-filtering на заказах 1C + накопленные клики
Технологии	Python + LightGBM/implicit ALS + Qdrant; локально и в YC dev-окружении
DoD	• Golden set ≥ 1 000 оценок релевантности (собран на маркетологе TechnoMart)• Recall@10 ≥ 0.3 на тестовой выборке• Отчёт по данным: что есть, чего нет, что качаем со second-party• ADR с CTO: «AI-сервис не трогает ядро» — подписан до week 0• Презентация для CEO на week 4 с decision gate

Месяц 2–3. MVP-1 (8 нед.)

Цель: запустить онлайн A/B на главной и доказать 3× лифт конверсии блока (с 0.5 % до ≥ 1.5 %).

Поле	Значение
Scope	Web + мобильное приложение, главная + карточка товара, A/B на 5 % трафика; первая итерация generative descriptions для одной категории SKU (например, ноутбуки — высокий чек)
Архитектурные решения	FastAPI + Qdrant + Redis-cache; деплой в YC Managed K8s; MLflow для версий моделей; self-hosted Saiga / T-lite на A100 (YC) для LLM; PII-mask на входе
Guardrails	Output validator для LLM-описаний (regex по числовым атрибутам); фильтр 18+, нулевые остатки, заблокированные SKU
Observability	Prometheus + Grafana; Langfuse для трейсинга LLM-запросов; cost/request дашборд
DoD	• Онлайн A/B 2 нед: CTR блока ≥ 1.5 %, p<0.05• Latency p95 < 200 мс• 100 generative descriptions провалидированы маркетингом (≥ 90 % ассерт)• OpEx в рамках утверждённого бюджета• Защита перед CEO + CTO + СМО

После 3 месяцев — Production / MVP-2 (откладываем на потом)

- Омниканальность: матчинг онлайн/офлайн через программу лояльности
- СМО push-рассылки с AI-рекомендациями (отдельный батч-пайплайн)
- Расширение generative descriptions на все категории
- Cold-start для новых пользователей (контекстная модель)
- Миграция критичных нагрузок на on-prem GPU (после закупки)

- HA / DR (multi-zone)

Полезные материалы

-  Описание кейса (PDF)
-  Матрица рисков. Пример заполнения
-  Шаблон реестра рисков для количественной оценки (Risk Academy)
-  Приложения A1–A10 к уроку 2 — особенно **A5 (Risk Register)**, **A6 (Change Request)**, **A7 (TCO)**

Формат сдачи

PDF или ссылка на **Google Doc / Holst**, содержащий 4 раздела (вопросы, контракт, риски, roadmap). Если ссылка — открытый доступ для проверяющего.

Критерии оценки vs. этот драфт

Критерий	Покрытие
Обоснованность контракта	✅ Связан с уровнем неопределённости (R&D ↔ T&M, инфра ↔ FP), отдельная защита перед CEO/CTO/CMO
Полнота Roadmap (PoC / MVP / Prod)	✅ 3 этапа + явный defer на «потом»
Реалистичность AI-рисков	✅ 10 рисков из реалий кейса (Bitrix задыхается, нет DS, ПДн, GPU-закупка 2 мес)
Структура	✅ 4 раздела, таблицы, диаграмма стейкхолдеров через защиту

Компетенции

- Аргументированно обосновывать выбор коммерческой модели контракта (FP / T&M / T&M with a cap).
- Составлять матрицу рисков и черновик Change Request для FP-проектов.
- Разрабатывать дорожную карту проекта, декомпозируя задачи на этапы PoC, MVP и Production.

TODO перед сдачей

-  Перечитать вопросы — поправить под свой опыт (artcloud-кейсы, реальные интеграции)
-  Реалистично оценить cap PoC (% от бюджета MVP) под цифры своей компании
-  Свести в **Google Doc** + открыть доступ
-  Опционально: PDF через `./scripts/md-to-pdf.sh --landscape --font=10pt 01-strategy/homework/03-strategiya-postavki.md`
-  Отправить ссылку / PDF на проверку