

# Стратегия внедрения системы AI-рекомендаций — TechnoMart

Студент: Зубик Александр <azubik@mtbank.by> Курс: OTUS AI-Architect — Д3-03

Кейс: «Ритейлер и AI-рекомендации» — компания **TechnoMart** (топ-5 ритейлер бытовой техники, 2 млн MAU, 50 000+ SKU, 150 оффлайн-магазинов).

## Постановка задачи

Разработать стратегию внедрения AI-системы рекомендаций для TechnoMart: выбрать контрактную модель, оценить риски и подготовить дорожную карту для согласования с заказчиком (CEO / CTO / CMO).

По условию необходимо:

- 1. **Анализ требований** — сформулировать 5–7 уточняющих вопросов клиенту, без ответа на которые нельзя начинать проект.
- 2. **Выбор контракта** — обосновать модель (**T&M / FP / гибрид**) для этапа PoC и для основной разработки; пояснить, почему это выгодно обеим сторонам.
- 3. **Оценка рисков** — составить матрицу рисков (минимум 5, специфичных для AI) с планом митигации.
- 4. **Roadmap** — дорожная карта с критериями успеха (**DoD**) для этапов **PoC** (проверка гипотезы), **MVP** (выход на пользователей) и **Production** (масштабирование).

## Контекст проекта

Из RFP вижу следующую картину:

| Параметр                                  | Значение                                                                                      |
|-------------------------------------------|-----------------------------------------------------------------------------------------------|
| Масштаб                                   | 2 млн MAU, 50K+ SKU, 150 оффлайн-магазинов                                                    |
| Текущая конверсия блока «с этим покупают» | <b>0.5 %</b> (rule-based)                                                                     |
| Бизнес-цель                               | <b>AOV +10 %</b> , персонализация главной + рассылок, generative описания подборок            |
| Стек As-Is                                | Bitrix-монолит на PHP + MySQL (БД «задыхается»), 1C (синк раз в 15 мин), GA — только агрегаты |
| Команда клиента                           | Сильные PHP-разработчики; <b>нет DS, нет DE</b>                                               |
| Сроки                                     | <b>Первый результат через 3 месяца</b> , иначе проект закрывают                               |
| Бюджет                                    | Разработка — ОК; <b>GPU-серверы — закупка до 2 мес</b> , лучше стартовать в облаке            |
| Безопасность                              | ПДн (ФИО, телефоны, адреса). <b>Запрет на публичные LLM</b>                                   |
| Стейкхолдеры                              | CEO (хайп, нетерпелив), CTO (скептик, защищает монолит), CMO (ежедневный AI-push)             |

Если коротко — что меня цепляет в этих вводных. При масштабе 2 млн MAU и каталоге 50K+ SKU **конверсия блока 0.5 %** — это в 2–3 раза ниже среднерыночного для ритейла, и руководство об этом прекрасно знает. То есть мы заходим в ситуацию «теряем покупателей буквально каждый день». При этом — 3 месяца на первый результат и **нет DS-команды у клиента**. Это меняет всё:

- скорость важнее «академически правильной» архитектуры;
- мы заходим с managed-сервисом, иначе после нашего ухода система просто рухнет за 2–3 месяца;
- инфра — облачная (YC / Cloud.ru), потому что GPU они физически не успеют купить за 3 месяца.

Дальше — что я хочу выяснить у клиента, какой контракт предлагаю, какие риски вижу и как разложу это на 3 месяца.

---

## Шаг 1. С чем я иду к клиенту: 7 вопросов

Прежде чем что-то проектировать, мне нужно снять основные неизвестные. Вот что я задал бы на первой встрече — по приоритету: первые три определяют, **можно ли вообще делать PoC**, остальные — на чём базируется MVP.

1. **Про KPI и горизонт.** AOV +10 % — за какой период считаем (квартал, полгода, год)? И от какого baseline стартуем? Заодно сразу хочу зафиксировать минимум по конверсии блока для MVP — сейчас 0.5 %, целимся в 1.5 %, 2 % или 3 %? Эту цифру важно закрыть на берегу, иначе на decision gate начнутся споры «достигли / не достигли».
2. **Про кликстрим.** GA отдаёт только агрегаты — а есть ли сырые события за 90+ дней или их нужно начинать копить с нуля? Если с нуля — пустите ли вы наш SDK на свои сервера прямо **с первой недели** проекта? От этого зависит, на чём строить PoC: на свежем кликстриме или на surrogate-сигнале из заказов 1C.
3. **Про омниканальность.** У вас 150 оффлайн-магазинов плюс онлайн. Какой % оффлайн-покупателей идентифицирован (программа лояльности, карта, телефон при покупке)? Эти связки лежат в 1C? Без сшивки онлайн+оффлайн вытащить «умную ленту с учётом оффлайн-покупок» из RFP мы не сможем — это нужно понимать сразу.
4. **Про каталог.** В ежедневном XML — что там кроме базовых полей? Бренд, категория, остатки, маржа — хорошо. А **описания товаров и картинки**? Без них не получится ни content-based фолбэк для холодного старта, ни generative descriptions, которых хочет маркетинг.
5. **Про допустимые модели.** Запрет на «публичные нейросети типа ChatGPT» — он распространяется на **российские managed-LLM** (Yandex GPT, GigaChat) при подписанном DPA? Или строго self-hosted? Это **решающий ADR** — от него зависит вся остальная архитектура инференса.
6. **Про эксплуатацию после нашего ухода.** Команды DS/DE у вас нет. Что планируете дальше — нанимать (когда, в каком составе) или **managed-сервис от нас** на 6–12 мес с постепенным переходом? Это сильно меняет стек: managed-friendly решения и DIY-стек — разные миры.

7. **Про приоритет на 3 месяца.** Что вам важнее увидеть к decision gate — **умную ленту на главной** (рост конверсии, на это смотрит CEO) или **generative descriptions** для push-рассылок (быстрая «вау-демо», нравится СМО)? Если выбирать — кто принимает решение при конфликте CEO / СТО / СМО?

Шаг 2. Контракт — почему гибрид

Главная сложность кейса с точки зрения контракта — у CEO жёсткий 3-месячный дедлайн, и при этом куча R&D-неопределённости: непонятно качество данных, не факт что AOV +10 % вообще достигим за квартал, не ясно как Bitrix-монолит переживёт интеграцию. Одной моделью это не закрыть — либо клиент платит за наши гипотезы (плохо для него), либо мы закладываем все риски в цену (плохо для нас, клиент не подпишет). Поэтому делю на 3 этапа, каждому — своя контрактная форма.

Рекомендация

| Этап               | Длит.            | Модель                                                                            | Cap / FP-бюджет                                              | Чем закрываем                                                                                                                                                             |
|--------------------|------------------|-----------------------------------------------------------------------------------|--------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| РoC                | 4 нед            | T&M with a cap                                                                    | Cap ≈ 15 % от плановой стоимости MVP                         | Подбор моделей, EDA, проверка гипотез на реальных данных. Без cap CEO не согласует, без T&M мы не возьмёмся — R&D-неопределённость по качеству GA-данных слишком высокая. |
| MVP-1              | 8 нед            | Гибрид: FP на инфра+API+интеграцию с Bitrix через события, T&M на ML-составляющую | FP-часть фиксирована; ML — почасово с подекадной отчётностью | Интеграция и сервис-обязка прогнозируемы; модель и метрики — продолжающийся R&D с A/B-валидацией.                                                                         |
| Production / scale | После защиты MVP | FP по фичам + T&M-абонемент на ML-эксплуатацию                                    | Подписывается отдельно после demo dec.gate                   | Scope известен. Эксплуатация (retraining, мониторинг, реакция на дрейф) — регулярный R&D.                                                                                 |

Защита перед стейкхолдерами

**Перед CEO (нетерпелив, хайп):** «Вы платите за **результат**, а не за гипотезы. РoC с потолком в N руб. — если данных не хватает или модель не вытягивает, закрываем на 4 неделе, дальше не платите. После РoC — FP по фичам, цена фиксирована, никаких сюрпризов.»

**Перед СТО (защищает монолит):** «Ядро Bitrix мы не трогаем. AI — это отдельный микросервис в облаке, подписан на события из MySQL через очередь (read-only replica). Вызов из сайта — HTTP-API с timeout. Если AI отвалится — сайт работает как сейчас. Откатиться = снять флаг.»

**Перед СМО (хочет push):** «В PoC берём в работу один экран — главную. Push-рассылки с generative descriptions — параллельный трек MVP-2 (после защиты MVP-1) либо ускоренная фича по CR.»

---

### **Шаг 3. Риски — где я ожидаю боль**

Выписал 10 рисков, специфичных именно для этого кейса — не общие «AI-проекты непредсказуемы», а конкретные: «GA не отдаёт сырьё», «Bitrix задыхается», «у клиента нет команды». По каждому — оценка по шкале 1–5 (Score = Вер. × Вли.) и план митигации. Сначала пройду по критичным (Score ≥ 16) — это то, на что нужно тратить время до старта; потом по средним.

**Критичные и высокие риски (Score  $\geq 16$ )**

| ID   | Категория        | Описание риска                                                                                                       | Вер. | Вли. | Score       | Стратегия | План митигации                                                                                                                                                                                     |
|------|------------------|----------------------------------------------------------------------------------------------------------------------|------|------|-------------|-----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| R-01 | Data             | GA не отдаёт сырые события → невозможно обучить персонализированную модель на детальном кликстриме                   | 5    | 5    | 25 Critical | Mitigate  | Неделя 1: ставим свой SDK сбора событий на сервера TechnoMart. К PoC накопится 2–3 недели сырья. Для холодного старта PoC — surrogate сигнал из заказов 1C.                                        |
| R-02 | Architecture     | Bitrix-монолит «задыхается» — нельзя нагружать его дополнительными запросами / write-операциями                      | 5    | 5    | 25 Critical | Avoid     | AI как <b>отдельный сервис</b> в YC: чтение через read-replica MySQL + очередь событий, hot-path рекомендаций — Redis precomputed + Qdrant. Никаких write в Bitrix. ADR подписать с СТО на week 0. |
| R-03 | LLM Quality      | Generative Descriptions выдают неверные факты («32 GB RAM» когда 16 GB) → репутационный риск, конфликт с маркетингом | 4    | 5    | 20 Critical | Mitigate  | Constrained generation: LLM пишет только обёртку, факты из каталога подставляются по шаблону. Validation-слой проверяет упоминания цифр/брендов. Fallback на rule-based, если validate fails.      |
| R-04 | Security / Legal | ПДн (ФИО, телефон, адрес) попадают в публичные LLM (152-ФЗ, ГОСТ)                                                    | 4    | 5    | 20 Critical | Avoid     | Self-hosted RU-LLM (Saiga / T-lite / Qwen на арендованной A100 в YC). Anonymization-слой на входе: маскируем PII перед отправкой в LLM. Логирование промптов с маскированием.                      |
| R-05 | Team / Org       | Нет DS / DE на стороне клиента — после нашего ухода система деградирует за 2–3 месяца                                | 5    | 4    | 20 Critical | Mitigate  | В контракт включён <b>managed-сервис 6–12 мес</b> : ретрейн по расписанию, on-call. Runbook + документация. Параллельно — поддержка найма (JD, скрининг).                                          |
| R-06 | Cost             | GPU-аренда + LLM-инференс при 2 млн MAU вылетают за OpEx-бюджет                                                      | 4    | 4    | 16 High     | Mitigate  | recsys на <b>CPU</b> (LightGBM / ALS); GPU только для generative descriptions в <b>офлайн-batch</b> + кэш в Redis; FinOps-ревью 1 раз в 2 нед.                                                     |

### Средние риски (Score < 16)

| ID   | Категория    | Описание риска                                                                                                | Вер. | Вли. | Score     | Стратегия         | План митигации                                                                                                                                                                    |
|------|--------------|---------------------------------------------------------------------------------------------------------------|------|------|-----------|-------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| R-07 | Scope        | CEO под влиянием хайпа расширяет scope после первой демо («давайте ещё голос / видео / агент»)                | 4    | 3    | 12 Medium | Accept (Contract) | Change Management в FP-контракт MVP: новые модальности — через CR с переоценкой стоимости и сроков (шаблон A6 из ур.2).                                                           |
| R-08 | Stakeholder  | Конфликт СМО (ежедневный push) и СТО (любое касание ядра = риск)                                              | 3    | 4    | 12 Medium | Mitigate          | Push реализуем как <b>отдельный сервис в облаке</b> , не интегрируется с ядром Bitrix; маркетинг получает доступ к админке с превью генерации. СТО видит, что монолит не трогаем. |
| R-09 | Performance  | Latency p95 > 200 мс — рекомендации тормозят сайт, CTR падает                                                 | 3    | 4    | 12 Medium | Mitigate          | Precompute top-N для всех логин-юзеров офлайн (раз в час), online — только подмешивание контекста; cache в Redis с TTL 1 ч; нагрузочный тест за 2 нед до production.              |
| R-10 | Data Quality | Каталог в XML с лагом в сутки → новые товары попадают в рекомендации с задержкой, остатки рассинхронизированы | 3    | 3    | 9 Medium  | Mitigate          | Постпроцессинг: фильтрация SKU по остаткам из 1C (синк 15 мин); согласовать с клиентом переход на event-driven обновление каталога в Roadmap (MVP-2).                             |

### Количественная оценка критичных рисков — PERT

Качественная шкала ВxВ даёт ранжирование, но не отвечает на вопрос «**насколько риск может выбить нас из бюджета PoC**». Поэтому для топ-5 рисков я делаю количественную оценку по 3-точечному методу — это упрощённая, детерминированная версия модели Монте-Карло из ISAR Sample Risk Calculator (Excel-шаблон, который был в материалах к занятию).

**Формула ожидаемого ущерба** (детерминированная аппроксимация Монте-Карло):

$$E[\text{ущерб}] = P \times (\text{Min} + 4 \cdot \text{ML} + \text{Max}) / 6$$



где **P** — вероятность срабатывания (0–1), **Min / ML / Max** — пессимистичная / наиболее вероятная / оптимистичная оценки ущерба в чел-днях команды (бюджет PoC = 4 нед × 5 чел = 100 чел-дн).

| ID   | Риск                                                | P    | Min | ML | Max | E[ущерб] | Лимит | Статус             |
|------|-----------------------------------------------------|------|-----|----|-----|----------|-------|--------------------|
| R-01 | GA без сырых событий                                | 0.85 | 5   | 15 | 30  | 13.5     | 15    | ⚠️ близко к лимиту |
| R-02 | Bitrix-монолит, ограничения интеграции              | 0.65 | 10  | 25 | 60  | 18.4     | 15    | ❌ превышает        |
| R-03 | Галлюцинации LLM в generative descriptions          | 0.50 | 3   | 10 | 25  | 5.7      | 8     | ✓ OK               |
| R-04 | ПДн в публичных LLM (152-ФЗ)                        | 0.30 | 5   | 15 | 40  | 5.3      | 10    | ✓ OK               |
| R-05 | Нет DS-команды у клиента (деградация after-handoff) | 0.70 | 10  | 30 | 90  | 25.7     | 20    | ❌ превышает        |

**Вывод по количественному анализу:**

- **R-02 и R-05 превышают лимит толерантности** — требуют **усиленной митигации до старта PoC**: для R-02 — week 0 ADR с CTO и согласование read-replica доступа; для R-05 — пункт в контракт на managed-сервис до начала работ.
- **R-01 на грани** — план «SDK сбора кликов с week 1» критичен; без него ущерб уйдёт за лимит.
- R-03 и R-04 — в пределах толерантности, стандартный план митигации достаточен.

*Полная имитационная модель Монте-Карло с расчётом персентилля 95% и вероятности превышения лимита — см. ISAR Sample Risk Calculator (Excel-файл от OTUS, не коммитится в репо, см. .gitignore).*

**Шаг 4. Roadmap — что я показываю CEO через 3 месяца**

CEO хочет видеть результат к 14-й неделе, иначе закрывает проект. Поэтому всё, что не критично для decision gate, уходит «на потом». В 3 месяца помещается ровно одно: **PoC** (1 мес — доказать, что персонализированный recsys в принципе работает на ваших данных) + **MVP-1** (2 мес — онлайн A/B, доказать рыночный эффект). Омниканальность, push-рассылки, расширение generative descriptions — это всё MVP-2 / Production, после защиты MVP.

**Месяц 1. PoC (4 нед.)**

**Цель:** доказать, что персонализированный recsys даёт лифт **vs** текущие 0.5 % CTR rule-based.

| Поле                         | Значение                                                                                                                                                                                                                                                                                                                                                                                        |
|------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Scope</b>                 | Один экран — главная; один сегмент — залогиненные онлайн-пользователи; офлайн-оценка                                                                                                                                                                                                                                                                                                            |
| <b>Архитектурные решения</b> | AI как отдельный микросервис в YC; чтение из read-replica MySQL; SDK сбора кликов на серверах TechnoMart с week 1; ALS / item-based collab-filtering на заказах 1C + накопленные клики                                                                                                                                                                                                          |
| <b>Технологии</b>            | Python + LightGBM/implicit ALS + Qdrant; локально и в YC dev-окружении                                                                                                                                                                                                                                                                                                                          |
| <b>DoD</b>                   | <ul style="list-style-type: none"> <li>• Golden set <math>\geq 1\,000</math> оценок релевантности (собран на маркетологе TechnoMart)• <b>Recall@10 <math>\geq 0.3</math></b> на тестовой выборке• Отчёт по данным: что есть, чего нет, что качаем со second-party• <b>ADR с СТО:</b> «AI-сервис не трогает ядро» — подписан до week 0• Презентация для CEO на week 4 с decision gate</li> </ul> |

### Месяц 2–3. MVP-1 (8 нед.)

**Цель:** запустить онлайн A/B на главной и доказать **3x лифт** конверсии блока (с 0.5 % до  $\geq 1.5$  %).

| Поле                         | Значение                                                                                                                                                                                                                                                                                                                             |
|------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Scope</b>                 | Web + мобильное приложение, главная + карточка товара, <b>A/B на 5 % трафика</b> ; первая итерация generative descriptions для <b>одной категории</b> SKU (например, ноутбуки — высокий чек)                                                                                                                                         |
| <b>Архитектурные решения</b> | FastAPI + Qdrant + Redis-cache; деплой в YC Managed K8s; MLflow для версий моделей; self-hosted Saiga / T-lite на A100 (YC) для LLM; PII-mask на входе                                                                                                                                                                               |
| <b>Guardrails</b>            | Output validator для LLM-описаний (regex по числовым атрибутам); фильтр 18+, нулевые остатки, заблокированные SKU                                                                                                                                                                                                                    |
| <b>Observability</b>         | Prometheus + Grafana; Langfuse для трейсинга LLM-запросов; cost/request дашборд                                                                                                                                                                                                                                                      |
| <b>DoD</b>                   | <ul style="list-style-type: none"> <li>• Онлайн A/B 2 нед: <b>CTR блока <math>\geq 1.5</math> %</b>, <math>p &lt; 0.05</math>• <b>Latency p95 &lt; 200 мс</b>• 100 generative descriptions провалидированы маркетингом (<math>\geq 90</math> % ассепт)• OpEx в рамках утверждённого бюджета• Защита перед CEO + СТО + СМО</li> </ul> |

### После 3 месяцев — Production / MVP-2 (откладываем на потом)

- Омниканальность: матчинг онлайн/оффлайн через программу лояльности
- СМО push-рассылки с AI-рекомендациями (отдельный батч-пайплайн)
- Расширение generative descriptions на все категории
- Cold-start для новых пользователей (контекстная модель)
- Миграция критичных нагрузок на on-prem GPU (после закупки)
- HA / DR (multi-zone)