

Стратегия внедрения системы AI-рекомендаций — TechnoMart

Студент: Зубик Александр <azubik@mtbank.by> Курс: OTUS AI-Architect — Д3-03

Кейс: «Ритейлер и AI-рекомендации» — компания **TechnoMart** (топ-5 ритейлер бытовой техники, 2 млн MAU, 50 000+ SKU, 150 оффлайн-магазинов).

Постановка задачи

Разработать стратегию внедрения AI-системы рекомендаций для TechnoMart: выбрать контрактную модель, оценить риски и подготовить дорожную карту для согласования с заказчиком (CEO / CTO / CMO).

По условию необходимо:

- 1. **Анализ требований** — сформулировать 5–7 уточняющих вопросов клиенту, без ответа на которые нельзя начинать проект.
- 2. **Выбор контракта** — обосновать модель (**T&M / FP / гибрид**) для этапа PoC и для основной разработки; пояснить, почему это выгодно обеим сторонам.
- 3. **Оценка рисков** — составить матрицу рисков (минимум 5, специфичных для AI) с планом митигации.
- 4. **Roadmap** — дорожная карта с критериями успеха (**DoD**) для этапов **PoC** (проверка гипотезы), **MVP** (выход на пользователей) и **Production** (масштабирование).

Критерии «Принято»: обоснованность контракта · полнота Roadmap (все 3 стадии) · реалистичность AI-рисков · читаемая для бизнеса структура.

Контекст проекта

Параметр	Значение
Масштаб	2 млн MAU, 50K+ SKU, 150 оффлайн-магазинов
Текущая конверсия блока «с этим покупают»	0.5 % (rule-based)
Бизнес-цель	AOV +10 %, персонализация главной + рассылок, generative описания подборок
Стек As-Is	Bitrix-монолит на PHP + MySQL (БД «задыхается»), 1C (синк раз в 15 мин), GA — только агрегаты
Команда клиента	Сильные PHP-разработчики; нет DS, нет DE
Сроки	Первый результат через 3 месяца, иначе проект закрывают
Бюджет	Разработка — ОК; GPU-серверы — закупка до 2 мес, лучше стартовать в облаке
Безопасность	ПДн (ФИО, телефоны, адреса). Запрет на публичные LLM
Стейкхолдеры	CEO (хайп, нетерпелив), CTO (скептик, защищает монолит), CMO (ежедневный AI-push)

Шаг 1. Уточняющие вопросы клиенту (7)

1. **KPI и горизонт.** AOV +10 % — за какой период считаем (квартал / полгода / год)? Текущий baseline AOV? Дополнительно: целевая конверсия блока рекомендаций (сейчас 0.5 %, какой минимум на MVP считается успехом — 1.5 % / 2 % / 3 %)?
 2. **Кликстрим и данные о поведении.** Какая глубина истории доступна в GA, можно ли получить выгрузку «сырых» событий за 90+ дней? Готовы ли вы поставить наш SDK для сбора кликов на свои сервера **с первой недели проекта** (без этого PoC опирается только на заказы из 1С)?
 3. **Омниканальность и user_id.** Какой % оффлайн-покупателей идентифицируется через программу лояльности / карту / телефон? Эти связи есть в 1С? Какой допустимый лаг сопоставления онлайн/оффлайн (15 мин / час / сутки)?
 4. **Каталог и атрибуты SKU.** Что есть в ежедневном XML кроме базовых полей: бренд, категория, остатки, маржа, изображения, текстовые описания? Какой % SKU имеет качественные описания (нужно для generative descriptions и content-based)?
 5. **Безопасность и допустимые модели.** Запрет на «публичные нейросети типа ChatGPT» — относится ли он к **российским managed-LLM** (Yandex GPT, GigaChat) при подписанном DPA, или строго self-hosted? Это решающий ADR.
 6. **Эксплуатация после релиза.** Нет DS/DE в команде. Планируете ли наём (когда, в каком составе) или **managed-сервис от нас** (6–12 мес) с переходом на ваших ребят? Это сильно влияет на стек (managed-friendly vs DIY).
 7. **Приоритет в рамках 3 месяцев.** Что важнее показать к decision gate: **умная лента на главной** (рост конверсии — нравится CEO/СМО) или **generative descriptions** для push-рассылок (быстрая «вау-демо» — нравится СМО)? Кто принимает решение при конфликте приоритетов CEO / СТО / СМО?
-

Шаг 2. Выбор контрактной модели

Рекомендация

Этап	Длит.	Модель	Cap / FP-бюджет	Чем закрываем
PoC	4 нед	T&M with a cap	Cap $\approx$ 15 % от плановой стоимости MVP	Подбор моделей, EDA, проверка гипотез на реальных данных. Без cap CEO не согласует, без T&M мы не возьмёмся — R&D-неопределённость по качеству GA-данных слишком высокая.
MVP-1	8 нед	Гибрид: FP на инфра+API+интеграцию с Bitrix через события, T&M на ML-составляющую	FP-часть фиксирована; ML — почасово с подекадной отчётностью	Интеграция и сервис-обвязка прогнозируемы; модель и метрики — продолжающийся R&D с A/B-валидацией.
Production / scale	После защиты MVP	FP по фичам + T&M-абонемент на ML-эксплуатацию	Подписывается отдельно после demo dec.gate	Scope известен. Эксплуатация (retraining, мониторинг, реакция на дрейф) — регулярный R&D.

Защита перед стейкхолдерами

Перед CEO (нетерпелив, хайп): «Вы платите за **результат**, а не за гипотезы. PoC с потолком в N руб. — если данных не хватает или модель не вытягивает, закрываем на 4 неделе, дальше не платите. После PoC — FP по фичам, цена фиксирована, никаких сюрпризов.»

Перед СТО (защищает монолит): «**Ядро Bitrix мы не трогаем.** AI — это отдельный микросервис в облаке, подписан на события из MySQL через очередь (read-only replica). Вызов из сайта — HTTP-API с timeout. Если AI отвалится — сайт работает как сейчас. Откатиться = снять флаг.»

Перед СМО (хочет push): «В PoC берём в работу один экран — главную. Push-рассылки с generative descriptions — параллельный трек MVP-2 (после защиты MVP-1) либо ускоренная фича по CR.»

Шаг 3. Карта рисков (AI-специфика + кейс-специфика)

Шкала 1–5; **Score = Вер. × Влияние.**

Критичные и высокие риски (Score ≥ 16)

ID	Категория	Описание риска	Вер.	Влияние	Score	Стратегия	План митигации
R-01	Data	GA не отдаёт сырые события → невозможно обучить персонализированную модель на детальном кликстриме	5	5	25 Critical	Mitigate	Неделя 1: ставим свой SDK сбора событий на сервера TechnoMart. К PoC накопится 2–3 недели сырья. Для холодного старта PoC — surrogate сигнал из заказов 1C.
R-02	Architecture	Bitrix-монолит «задыхается» — нельзя нагружать его дополнительными запросами / write-операциями	5	5	25 Critical	Avoid	AI как отдельный сервис в YC: чтение через read-replica MySQL + очередь событий, hot-path рекомендаций — Redis precomputed + Qdrant. Никаких write в Bitrix. ADR подписать с СТО на week 0.
R-03	LLM Quality	Generative Descriptions выдают неверные факты («32 GB RAM» когда 16 GB) → репутационный риск, конфликт с маркетингом	4	5	20 Critical	Mitigate	Constrained generation: LLM пишет только обёртку, факты из каталога подставляются по шаблону. Validation-слой проверяет упоминания цифр/брендов. Fallback на rule-based, если validate fails.
R-04	Security / Legal	ПДн (ФИО, телефон, адрес) попадают в публичные LLM (152-ФЗ, ГОСТ)	4	5	20 Critical	Avoid	Self-hosted RU-LLM (Saiga / T-lite / Qwen на арендованной A100 в YC). Anonymization-слой на входе: маскируем PII перед отправкой в LLM. Логирование промптов с маскированием.
R-05	Team / Org	Нет DS / DE на стороне клиента — после нашего ухода система деградирует за 2–3 месяца	5	4	20 Critical	Mitigate	В контракт включён managed-сервис 6–12 мес : ретрейн по расписанию, on-call. Runbook + документация. Параллельно — поддержка найма (JD, скрининг).
R-06	Cost	GPU-аренда + LLM-инференс при 2 млн MAU вылетают за OpEx-бюджет	4	4	16 High	Mitigate	recsys на CPU (LightGBM / ALS); GPU только для generative descriptions в офлайн-batch + кэш в Redis; FinOps-ревью 1 раз в 2 нед.

Средние риски (Score < 16)

ID	Категория	Описание риска	Вер.	Влияние	Score	Стратегия	План митигации
R-07	Scope	CEO под влиянием хайпа расширяет scope после первой демо («давайте ещё голос / видео / агент»)	4	3	12 Medium	Accept (Contract)	Change Management в FP-контракт MVP: новые модальности — через CR с переоценкой стоимости и сроков (шаблон A6 из ур.2).
R-08	Stakeholder	Конфликт СМО (ежедневный push) и СТО (любое касание ядра = риск)	3	4	12 Medium	Mitigate	Push реализуем как отдельный сервис в облаке , не интегрируется с ядром Bitrix; маркетинг получает доступ к админке с превью генерации. СТО видит, что монолит не трогаем.
R-09	Performance	Latency p95 > 200 мс — рекомендации тормозят сайт, CTR падает	3	4	12 Medium	Mitigate	Precompute top-N для всех логин-юзеров офлайн (раз в час), online — только подмешивание контекста; cache в Redis с TTL 1 ч; нагрузочный тест за 2 нед до production.
R-10	Data Quality	Каталог в XML с лагом в сутки → новые товары попадают в рекомендации с задержкой, остатки рассинхронизированы	3	3	9 Medium	Mitigate	Постпроцессинг: фильтрация SKU по остаткам из 1C (синк 15 мин); согласовать с клиентом переход на event-driven обновление каталога в Roadmap (MVP-2).

Количественная оценка критичных рисков (3-точечная PERT)

Качественная шкала ВхВ даёт ранжирование, но не отвечает на вопрос «насколько риск может выбить нас из бюджета». Для рисков **Score ≥ 20** дополнительно делаю **количественную оценку ущерба по 3-точечному методу PERT** — методология взята из ISAR Sample Risk Calculator (имитационное моделирование с треугольным распределением).

Формула ожидаемого ущерба (детерминированная аппроксимация Монте-Карло):

$$E[\text{ущерб}] = P \times (\text{Min} + 4 \cdot \text{ML} + \text{Max}) / 6$$

где **P** — вероятность срабатывания (0–1), **Min / ML / Max** — пессимистичная / наиболее вероятная / оптимистичная оценки ущерба в **чел-днях команды** (бюджет PoC = 4 нед × 5 чел = 100 чел-дн).

ID	Риск	P	Min	ML	Max	E[ущерб]	Лимит	Статус
R-01	GA без сырых событий	0.85	5	15	30	13.5	15	⚠️ близко к лимиту
R-02	Bitrix-монолит, ограничения интеграции	0.65	10	25	60	18.4	15	❌ превышает
R-03	Галлюцинации LLM в generative descriptions	0.50	3	10	25	5.7	8	✓ OK
R-04	ПДн в публичных LLM (152-ФЗ)	0.30	5	15	40	5.3	10	✓ OK
R-05	Нет DS-команды у клиента (деградация after-handoff)	0.70	10	30	90	25.7	20	❌ превышает

Вывод по количественному анализу:

- **R-02 и R-05 превышают лимит толерантности** — требуют **усиленной митигации до старта PoC**: для R-02 — week 0 ADR с CTO и согласование read-replica доступа; для R-05 — пункт в контракт на managed-сервис до начала работ.
- **R-01 на грани** — план «SDK сбора кликов с week 1» критичен; без него ущерб уйдёт за лимит.
- R-03 и R-04 — в пределах толерантности, стандартный план митигации достаточен.

Полная имитационная модель Монте-Карло с расчётом персентилля 95% и вероятности превышения лимита — см. ISAR Sample Risk Calculator (Excel-файл от OTUS, не коммитится в репо, см. .gitignore).

Шаг 4. Дорожная карта (3 месяца — критический горизонт CEO)

Месяц 1. PoC (4 нед.)

Цель: доказать, что персонализированный recsys даёт лифт **vs** текущие 0.5 % CTR rule-based.

Поле	Значение
Scope	Один экран — главная; один сегмент — залогиненные онлайн-пользователи; офлайн-оценка
Архитектурные решения	AI как отдельный микросервис в YC; чтение из read-replica MySQL; SDK сбора кликов на серверах TechnoMart с week 1; ALS / item-based collab-filtering на заказах 1C + накопленные клики
Технологии	Python + LightGBM/implicit ALS + Qdrant; локально и в YC dev-окружении
DoD	• Golden set $\geq 1\,000$ оценок релевантности (собран на маркетологе TechnoMart)• Recall@10 ≥ 0.3 на тестовой выборке• Отчёт по данным: что есть, чего нет, что качаем со second-party• ADR с СТО: «AI-сервис не трогает ядро» — подписан до week 0• Презентация для CEO на week 4 с decision gate

Месяц 2–3. MVP-1 (8 нед.)

Цель: запустить онлайн A/B на главной и доказать **3x лифт** конверсии блока (с 0.5 % до ≥ 1.5 %).

Поле	Значение
Scope	Web + мобильное приложение, главная + карточка товара, A/B на 5 % трафика ; первая итерация generative descriptions для одной категории SKU (например, ноутбуки — высокий чек)
Архитектурные решения	FastAPI + Qdrant + Redis-cache; деплой в YC Managed K8s; MLflow для версий моделей; self-hosted Saiga / T-lite на A100 (YC) для LLM; PII-mask на входе
Guardrails	Output validator для LLM-описаний (regex по числовым атрибутам); фильтр 18+, нулевые остатки, заблокированные SKU
Observability	Prometheus + Grafana; Langfuse для трейсинга LLM-запросов; cost/request дашборд
DoD	• Онлайн A/B 2 нед: CTR блока ≥ 1.5 %, $p < 0.05$• Latency p95 < 200 мс• 100 generative descriptions провалидированы маркетингом (≥ 90 % ассепт)• OpEx в рамках утверждённого бюджета• Защита перед CEO + СТО + СМО

После 3 месяцев — Production / MVP-2 (откладываем на потом)

- Омниканальность: матчинг онлайн/оффлайн через программу лояльности
- СМО push-рассылки с AI-рекомендациями (отдельный батч-пайплайн)
- Расширение generative descriptions на все категории
- Cold-start для новых пользователей (контекстная модель)
- Миграция критичных нагрузок на on-prem GPU (после закупки)
- HA / DR (multi-zone)