

Стратегия внедрения системы AI-рекомендаций — TechnoMart

Студент: Зубик Александр <azubik@mtbank.by> Курс: OTUS AI-Architect — Д3-03

Кейс: «Ритейлер и AI-рекомендации» — компания **TechnoMart** (топ-5 ритейлер бытовой техники, 2 млн MAU, 50 000+ SKU, 150 оффлайн-магазинов).

Постановка задачи

Разработать стратегию внедрения AI-системы рекомендаций для TechnoMart: выбрать контрактную модель, оценить риски и подготовить дорожную карту для согласования с заказчиком (CEO / CTO / CMO).

По условию необходимо:

- 1. **Анализ требований** — сформулировать 5–7 уточняющих вопросов клиенту, без ответа на которые нельзя начинать проект.
- 2. **Выбор контракта** — обосновать модель (**T&M / FP / гибрид**) для этапа PoC и для основной разработки; пояснить, почему это выгодно обеим сторонам.
- 3. **Оценка рисков** — составить матрицу рисков (минимум 5, специфичных для AI) с планом митигации.
- 4. **Roadmap** — дорожная карта с критериями успеха (**DoD**) для этапов **PoC** (проверка гипотезы), **MVP** (выход на пользователей) и **Production** (масштабирование).

Контекст проекта

Из RFP вижу следующую картину:

Параметр	Значение
Масштаб	2 млн MAU, 50K+ SKU, 150 оффлайн-магазинов
Текущая конверсия блока «с этим покупают»	0.5 % (rule-based)
Бизнес-цель	AOV +10 % , персонализация главной + рассылок, generative описания подборок
Стек As-Is	Bitrix-монолит на PHP + MySQL (БД «задыхается»), 1C (синк раз в 15 мин), GA — только агрегаты
Команда клиента	Сильные PHP-разработчики; нет DS, нет DE
Сроки	Первый результат через 3 месяца , иначе проект закрывают
Бюджет	Разработка — ОК; GPU-серверы — закупка до 2 мес , лучше стартовать в облаке
Безопасность	ПДн (ФИО, телефоны, адреса). Запрет на публичные LLM
Стейкхолдеры	CEO (хайп, нетерпелив), CTO (скептик, защищает монолит), CMO (ежедневный AI-push)

Если коротко — что меня цепляет в этих вводных. При масштабе 2 млн MAU и каталоге 50K+ SKU **конверсия блока 0.5 %** — это в 2–3 раза ниже среднерыночного для ритейла, и руководство об этом прекрасно знает. То есть мы заходим в ситуацию «теряем покупателей буквально каждый день». При этом — 3 месяца на первый результат и **нет DS-команды у клиента**. Это меняет всё:

- скорость важнее «академически правильной» архитектуры;
- мы заходим с managed-сервисом, иначе после нашего ухода система просто рухнет за 2–3 месяца;
- инфра — облачная (YC / Cloud.ru), потому что GPU они физически не успеют купить за 3 месяца.

Дальше — что я хочу выяснить у клиента, какой контракт предлагаю, какие риски вижу и как разложу это на 3 месяца.

Шаг 1. С чем я иду к клиенту: 7 вопросов

Прежде чем что-то проектировать, мне нужно снять основные неизвестные. Вот что я задал бы на первой встрече — по приоритету: первые три определяют, **можно ли вообще делать PoC**, остальные — на чём базируется MVP.

1. **Про KPI и горизонт.** AOV +10 % — за какой период считаем (квартал, полгода, год)? И от какого baseline стартуем? Заодно сразу хочу зафиксировать минимум по конверсии блока для MVP — сейчас 0.5 %, целимся в 1.5 %, 2 % или 3 %? Эту цифру важно закрыть на берегу, иначе на decision gate начнутся споры «достигли / не достигли».
2. **Про кликстрим.** GA отдаёт только агрегаты — а есть ли сырые события за 90+ дней или их нужно начинать копить с нуля? Если с нуля — пустите ли вы наш SDK на свои сервера прямо **с первой недели** проекта? От этого зависит, на чём строить PoC: на свежем кликстриме или на surrogate-сигнале из заказов 1C.
3. **Про омниканальность.** У вас 150 оффлайн-магазинов плюс онлайн. Какой % оффлайн-покупателей идентифицирован (программа лояльности, карта, телефон при покупке)? Эти связки лежат в 1C? Без сшивки онлайн+оффлайн вытащить «умную ленту с учётом оффлайн-покупок» из RFP мы не сможем — это нужно понимать сразу.
4. **Про каталог.** В ежедневном XML — что там кроме базовых полей? Бренд, категория, остатки, маржа — хорошо. А **описания товаров и картинки**? Без них не получится ни content-based фолбэк для холодного старта, ни generative descriptions, которых хочет маркетинг.
5. **Про допустимые модели.** Запрет на «публичные нейросети типа ChatGPT» — он распространяется на **российские managed-LLM** (Yandex GPT, GigaChat) при подписанном DPA? Или строго self-hosted? Это **решающий ADR** — от него зависит вся остальная архитектура инференса.
6. **Про эксплуатацию после нашего ухода.** Команды DS/DE у вас нет. Что планируете дальше — нанимать (когда, в каком составе) или **managed-сервис от нас** на 6–12 мес с постепенным переходом? Это сильно меняет стек: managed-friendly решения и DIY-стек — разные миры.

7. **Про приоритет на 3 месяца.** Что вам важнее увидеть к decision gate — **умную ленту на главной** (рост конверсии, на это смотрит CEO) или **generative descriptions** для push-рассылок (быстрая «вау-демо», нравится СМО)? Если выбирать — кто принимает решение при конфликте CEO / СТО / СМО?

Шаг 2. Контракт — почему гибрид

Главная сложность кейса с точки зрения контракта — у CEO жёсткий 3-месячный дедлайн, и при этом куча R&D-неопределённости: непонятно качество данных, не факт что AOV +10 % вообще достигим за квартал, не ясно как Bitrix-монолит переживёт интеграцию. Одной моделью это не закрыть — либо клиент платит за наши гипотезы (плохо для него), либо мы закладываем все риски в цену (плохо для нас, клиент не подпишет). Поэтому делю на 3 этапа, каждому — своя контрактная форма.

Рекомендация

Этап	Длит.	Модель	Cap / FP-бюджет	Чем закрываем
РoC	4 нед	T&M with a cap	Cap ≈ 15 % от плановой стоимости MVP	Подбор моделей, EDA, проверка гипотез на реальных данных. Без cap CEO не согласует, без T&M мы не возьмёмся — R&D-неопределённость по качеству GA-данных слишком высокая.
MVP-1	8 нед	Гибрид: FP на инфра+API+интеграцию с Bitrix через события, T&M на ML-составляющую	FP-часть фиксирована; ML — почасово с подекадной отчётностью	Интеграция и сервис-обязка прогнозируемы; модель и метрики — продолжающийся R&D с A/B-валидацией.
Production / scale	После защиты MVP	FP по фичам + T&M-абонемент на ML-эксплуатацию	Подписывается отдельно после demo dec.gate	Scope известен. Эксплуатация (retraining, мониторинг, реакция на дрейф) — регулярный R&D.

Защита перед стейкхолдерами

Перед CEO (нетерпелив, хайп): «Вы платите за **результат**, а не за гипотезы. РoC с потолком в N руб. — если данных не хватает или модель не вытягивает, закрываем на 4 неделе, дальше не платите. После РoC — FP по фичам, цена фиксирована, никаких сюрпризов.»

Перед СТО (защищает монолит): «Ядро Bitrix мы не трогаем. AI — это отдельный микросервис в облаке, подписан на события из MySQL через очередь (read-only replica). Вызов из сайта — HTTP-API с timeout. Если AI отвалится — сайт работает как сейчас. Откатиться = снять флаг.»

Перед СМО (хочет push): «В PoC берём в работу один экран — главную. Push-рассылки с generative descriptions — параллельный трек MVP-2 (после защиты MVP-1) либо ускоренная фича по CR.»

Шаг 3. Риски — где я ожидаю боль

Выписал 10 рисков, специфичных именно для кейса — не общие «AI-проекты непредсказуемы», а конкретные: «GA не отдаёт сырьё», «Bitrix задыхается», «у клиента нет команды». Шкала 1–5, Score = Вер. × Вли. Сначала критичные (≥ 16) — то, на что трачу время до старта, потом средние.

Критичные и высокие риски (Score ≥ 16):

R-01 · Data — Score 25 (Critical) · Mitigate. GA не отдаёт сырые события → невозможно обучить персонализированную модель на детальном кликстриме. Вер. 5 / Вли. 5.

- **Триггер:** к week 2 PoC собрано $< 50K$ событий или $< 60\%$ сессий с user_id.
- **План:** неделя 1 — ставим свой SDK сбора событий на сервера TechnoMart. К PoC накопится 2–3 недели сырья. Для холодного старта — surrogate сигнал из заказов 1С.

R-02 · Architecture — Score 25 (Critical) · Avoid. Bitrix-монолит «задыхается» — нельзя нагружать его дополнительными запросами / write-операциями. Вер. 5 / Вли. 5.

- **Триггер:** СТО отказывает в доступе к read-replica, либо MySQL latency на тест-запросах > 100 мс.
- **План:** AI как **отдельный сервис** в YC — чтение через read-replica MySQL + очередь событий, hot-path — Redis precomputed + Qdrant. Никаких write в Bitrix. ADR подписать с СТО на week 0.

R-03 · LLM Quality — Score 20 (Critical) · Mitigate. Generative Descriptions выдают неверные факты («32 GB RAM» когда 16 GB) → репутационный риск, конфликт с маркетингом. Вер. 4 / Вли. 5.

- **Триггер:** validation-слой блокирует $> 10\%$ генераций на golden set, либо маркетинг отклоняет $> 20\%$ описаний при ручной проверке.
- **План:** constrained generation — LLM пишет только обёртку, факты из каталога подставляются по шаблону. Validation-слой проверяет упоминания цифр/брендов. Fallback на rule-based, если validate fails.

R-04 · Security / Legal — Score 20 (Critical) · Avoid. ПДн (ФИО, телефон, адрес) попадают в публичные LLM (152-ФЗ, ГОСТ). Вер. 4 / Вли. 5.

- **Триггер:** в audit-логе LLM-запросов найден незамаскированный PII, либо обращение от регулятора.

- **План:** self-hosted RU-LLM (Saiga / T-lite / Qwen на A100 в YC). Anonymization-слой на входе: маскируем PII перед отправкой в LLM. Логирование промптов с маскированием.

R-05 · Team / Org — Score 20 (Critical) · Mitigate. Нет DS / DE на стороне клиента — после нашего ухода система деградирует за 2–3 месяца. Вер. 5 / Вли. 4.

- **Триггер:** managed-сервис не подписан в основном контракте MVP, либо JD на DS-роль не открыт через 4 нед после старта MVP.
- **План:** в контракт включён **managed-сервис 6–12 мес** — ретрейн по расписанию, on-call. Runbook + документация. Параллельно — поддержка найма (JD, скрининг).

R-06 · Cost — Score 16 (High) · Mitigate. GPU-аренда + LLM-инференс при 2 млн MAU вылетают за OpEx-бюджет. Вер. 4 / Вли. 4.

- **Триггер:** прогноз OpEx > 120 % утверждённого бюджета на следующий месяц, либо cost/request > 0.5 ₽.
- **План:** recsys на **CPU** (LightGBM / ALS); GPU только для generative descriptions в **офлайн-batch** + кэш в Redis; FinOps-ревью 1 раз в 2 нед.

Средние риски (Score < 16):

R-07 · Scope — Score 12 (Medium) · Accept (Contract). CEO под влиянием хайпа расширяет score после первой демо («давайте ещё голос / видео / агент»). Вер. 4 / Вли. 3.

- **Триггер:** > 2 неформальных запросов на новые фичи без CR за 2 недели подряд.
- **План:** Change Management в FP-контракт MVP — новые модальности через CR с переоценкой стоимости и сроков (шаблон A6 из ур. 2).

R-08 · Stakeholder — Score 12 (Medium) · Mitigate. Конфликт СМО (ежедневный push) и СТО (любое касание ядра = риск). Вер. 3 / Вли. 4.

- **Триггер:** СМО/СТО не согласовали скоуп push-фичи к финальному review MVP-1.
- **План:** push реализуем как **отдельный сервис в облаке**, не интегрируется с ядром Bitrix; маркетинг получает доступ к админке с превью генерации. СТО видит, что монолит не трогаем.

R-09 · Performance — Score 12 (Medium) · Mitigate. Latency p95 > 200 мс — рекомендации тормозят сайт, CTR падает. Вер. 3 / Вли. 4.

- **Триггер:** на нагрузочном тесте p95 > 150 мс (запас 50 мс до SLA).
- **План:** precompute top-N для всех логин-юзеров офлайн (раз в час), online — только подмешивание контекста; cache в Redis с TTL 1 ч; нагрузочный тест за 2 нед до production.

R-10 · Data Quality — Score 9 (Medium) · Mitigate. Каталог в XML с лагом в сутки → новые товары попадают в рекомендации с задержкой, остатки рассинхронизированы. Вер. 3 / Вли. 3.

- **Триггер:** > 5 % жалоб от пользователей «товара нет в наличии» из рекомендаций.
- **План:** постпроцессинг — фильтрация SKU по остаткам из 1С (синк 15 мин); согласовать с клиентом переход на event-driven обновление каталога в Roadmap (MVP-2).

Категории Score: **20–25** Critical · **16–19** High · **9–15** Medium · **≤ 8** Low.

Количественная оценка критичных рисков — PERT

Качественная шкала ВxВ даёт ранжирование, но не отвечает на вопрос «**насколько риск может выбить нас из бюджета PoC**». Поэтому для топ-5 рисков я делаю количественную оценку по 3-точечному методу — это упрощённая, детерминированная версия модели Монте-Карло из ISAR Sample Risk Calculator (Excel-шаблон, который был в материалах к занятию).

Формула ожидаемого ущерба (детерминированная аппроксимация Монте-Карло):

$$E[\text{ущерб}] = P \times (\text{Min} + 4 \cdot \text{ML} + \text{Max}) / 6$$

где **P** — вероятность срабатывания (0–1), **Min / ML / Max** — пессимистичная / наиболее вероятная / оптимистичная оценки ущерба в **чел-днях команды** (бюджет PoC = 4 нед × 5 чел = 100 чел-дн).

ID	Риск	P	Min	ML	Max	E[ущерб]	Лимит	Статус
R-01	GA без сырых событий	0.85	5	15	30	13.5	15	⚠️ близко к лимиту
R-02	Bitrix-монолит, ограничения интеграции	0.65	10	25	60	18.4	15	❌ превышает
R-03	Галлюцинации LLM в generative descriptions	0.50	3	10	25	5.7	8	✓ OK
R-04	ПДн в публичных LLM (152-ФЗ)	0.30	5	15	40	5.3	10	✓ OK
R-05	Нет DS-команды у клиента (деградация after-handoff)	0.70	10	30	90	25.7	20	❌ превышает

Вывод по количественному анализу:

- **R-02 и R-05 превышают лимит толерантности** — требуют **усиленной митигации до старта PoC**: для R-02 — week 0 ADR с CTO и согласование read-replica доступа; для R-05 — пункт в контракт на managed-сервис до начала работ.
- **R-01 на грани** — план «SDK сбора кликов с week 1» критичен; без него ущерб уйдёт за лимит.
- R-03 и R-04 — в пределах толерантности, стандартный план митигации достаточен.

Шаг 4. Roadmap — что я показываю CEO через 3 месяца

CEO хочет видеть результат к 14-й неделе, иначе закрывает проект. Поэтому всё, что не критично для decision gate, уходит «на потом». В 3 месяца помещается ровно одно: **PoC** (1 мес — доказать, что персонализированный recsys в принципе работает на ваших данных) + **MVP-1** (2 мес — онлайн A/B, доказать рыночный эффект). Омниканальность, push-рассылки, расширение generative descriptions — это всё MVP-2 / Production, после защиты MVP.

Месяц 1. PoC (4 нед.)

Цель: доказать, что персонализированный recsys даёт лифт **vs** текущие 0.5 % CTR rule-based.

Поле	Значение
Scope	Один экран — главная; один сегмент — залогиненные онлайн-пользователи; офлайн-оценка
Архитектурные решения	AI как отдельный микросервис в YC; чтение из read-replica MySQL; SDK сбора кликов на серверах TechnoMart с week 1; ALS / item-based collab-filtering на заказах 1C + накопленные клики
Технологии	Python + LightGBM/implicit ALS + Qdrant; локально и в YC dev-окружении
DoD	• Golden set $\geq 1\,000$ оценок релевантности (собран на маркетологе TechnoMart)• Recall@10 ≥ 0.3 на тестовой выборке• Отчёт по данным: что есть, чего нет, что качаем со second-party• ADR с СТО: «AI-сервис не трогает ядро» — подписан до week 0• Презентация для CEO на week 4 с decision gate

Месяц 2–3. MVP-1 (8 нед.)

Цель: запустить онлайн A/B на главной и доказать **3x лифт** конверсии блока (с 0.5 % до ≥ 1.5 %).

Поле	Значение
Scope	Web + мобильное приложение, главная + карточка товара, A/B на 5 % трафика ; первая итерация generative descriptions для одной категории SKU (например, ноутбуки — высокий чек)
Архитектурные решения	FastAPI + Qdrant + Redis-cache; деплой в YC Managed K8s; MLflow для версий моделей; self-hosted Saiga / T-lite на A100 (YC) для LLM; PII-mask на входе
Guardrails	Output validator для LLM-описаний (regex по числовым атрибутам); фильтр 18+, нулевые остатки, заблокированные SKU
Observability	Prometheus + Grafana; Langfuse для трейсинга LLM-запросов; cost/request дашборд
DoD	• Онлайн A/B 2 нед: CTR блока ≥ 1.5 % , $p < 0.05$ • Latency p95 < 200 мс • 100 generative descriptions провалидированы маркетингом (≥ 90 % ассепт)• OpEx в рамках утверждённого бюджета• Защита перед CEO + СТО + СМО

После 3 месяцев — Production / MVP-2 (откладываем на потом)

- Омниканальность: матчинг онлайн/оффлайн через программу лояльности
- СМО push-рассылки с AI-рекомендациями (отдельный батч-пайплайн)
- Расширение generative descriptions на все категории
- Cold-start для новых пользователей (контекстная модель)
- Миграция критичных нагрузок на on-prem GPU (после закупки)

- HA / DR (multi-zone)