

ДЗ 9. Фиксация архитектурных решений (ADR) и подготовка к защите

Задание

Цель: зафиксировать архитектурное решение о выборе способа хостинга LLM в формате ADR для обоснования перед техническим руководством.

Дилемма: где hostить LLM — проприетарная облачная модель (**SaaS**, напр. GPT-5) или Open-Source модель (**Llama 3**) на своих серверах (**Self-hosted**)?

Шаги:

1. **Анализ** — сравнить варианты по критериям: Стоимость, Безопасность данных (Privacy), Качество ответов, Latency, Сложность поддержки.
2. **Решение** — сделать выбор.
3. **ADR** — оформить решение: Title, Status, Context, Decision, Consequences (Pros/Cons).
4. **Pitch** — короткий текст (1 абзац) для СТО: почему решение единственно верное в текущих условиях.

Формат сдачи: документ ADR (Markdown/PDF). Рекомендуемый срок — **08.06.2026**.

Цели

- Составить Architecture Decision Record (ADR) для обоснования ключевого решения.
- Аргументированно защитить решение (в формате самопроверки / подготовки к ревью — «СТО Challenge», [[../webinars/09-verifikaciya-cto-challenge]]).

Критерии приёмки

- ☒ **Структура ADR** — соблюден стандартный формат (Title, Status, Context, Decision, Consequences).
- ☒ **Аргументация** — решение обосновано фактами (расчёт TCO, юрисдикция, sizing), а не эмоциями.
- ☒ **Честность** — в Consequences честно указаны минусы принятого решения (trade-offs).

Решение

Подход

Решение о хостинге LLM в моём проекте **уже принято и зафиксировано** как боевой **ADR-0001 «Self-hosted open-weight LLM вместо облачного API»** (status: accepted) — это не учебный пример, а реальное решение для **Суфлёра** (публичная копия решения для ЗАО МТБанк, zubriq.by). Ниже — версия ADR под формулировку ДЗ, дополненная **сравнением по 5 критериям** и **питчем для СТО**, которых требует задание.

Про модель: в формулировке ДЗ self-hosted-вариант назван «Llama 3» как пример. В моём проекте конкретный open-source выбор — Qwen3.5-27B (dense, Apache 2.0; tool-calling и длинный контекст под RAG/агентов; см. [ADR-0002](#)), а не Llama 3 (у которого лицензия Llama Community и слабее tool-calling). Поэтому дальше фигурирует Qwen3.5-27B как реальная замена «Llama 3» из вводной.

Важное отличие от учебной вводной: моя организация в **Республике Беларусь** под санкциями, поэтому SaaS-вариант не просто «дороже/рискованнее», а **юридически и платёжно недоступен** — это и есть «текущие условия», которые делают выбор однозначным.

Артефакты

- ADR (ниже) — основной артефакт сдачи.
- Боевой [ADR-0001](#) финального проекта (тот же выбор, продакшн-формулировка).
- Связанные ADR стека: [0002 выбор модели](#), [0006 квантование и sizing GPU](#).
- TCO-обоснование: final-project/economics/tco.md.

ADR-009. Хостинг LLM: Self-Hosted Open-Source вместо SaaS API

- **ID:** ADR-009 (учебный; боевой эквивалент — ADR-0001 финального проекта)
- **Status:** Accepted
- **Date:** 2026-06-03
- **Deciders:** Зубик Александр
- **Tags:** llm, deployment, security, belarus-99z, sanctions, tco, self-hosted

Context

Проектируем ядро корпоративного RAG-ассистента («Суфлёр») для подсказок операторам по внутренним регламентам. Это набор **ограничений**, а не «нам нужна LLM»:

- **Privacy / закон:** база знаний содержит ПДн и коммерческую тайну. Организация в **РБ** → применим **Закон № 99-З «О защите персональных данных»** (регулятор НЦЗПД), трансграничная передача ПДн ограничена → данные **не должны покидать контур**.
- **Санкции:** РБ под санкциями → OpenAI/Anthropic/Azure OpenAI закрыты их же ToS и платёжно — это не «риск нестабильности», а **практическая недоступность** SaaS.
- **Железо:** on-prem сервер с **2x NVIDIA H100 NVL 94 GB** (≈188 GB, NVLink) уже закуплен → **CapEx на GPU закрыт**.
- **SLA:** целевая latency ответа ≤ 10 сек (P95); канал — внутренний.
- **Команда:** есть DevOps; ML/MLOps-компетенции — начальные.

Decision

Используем **self-hosted open-weight LLM** — Qwen3.5-27B (dense, Apache 2.0) на движке инференса (vLLM/SGLang) внутри изолированного контура; выбор модели обоснован в [ADR-0002](#). Внешние SaaS-API (GPT-5 и аналоги) **запрещены**.

Сравнение вариантов по критериям задания:

Критерий	SaaS (GPT-5 / проприетарный API)	Self-Hosted (Qwen3.5-27B, on-prem) 
Стоимость	OpEx, pay-per-token — растёт с нагрузкой, непредсказуем; CapEx=0	CapEx на GPU (уже закрыт), OpEx ≈ электричество + поддержка → предсказуемый TCO
Безопасность (Privacy)	 данные уходят провайдеру → нарушение № 99-З и тайны	 данные не покидают контур, полный контроль PII
Качество ответов	★★★★★ эталон	★★★☆☆ (ниже на сложных рассуждениях; митигируется RAG-grounding + guardrails)
Latency	сетевая задержка + лимиты провайдера + недоступность из РБ	контролируемая, в LAN; зависит от железа (2x H100 → запас по T_token)
Сложность поддержки	низкая (только API)	высокая — нужен MLOps (мониторинг GPU, обновления, безопасность весов)

Дополнительный решающий фактор: SaaS из РБ **недоступен** (санкции/ToS/оплата) → варианты SaaS и гибрид — **Rejected** (нарушают № 99-З и/или недоступны), независимо от качества.

Consequences

Положительные (Pros):

- Соответствие № 99-З и ТЗ (air-gapped): данные не покидают контур.
- Независимость от санкций и зарубежных провайдеров; нет платы за токены → предсказуемый TCO (по [tco.md](#) — OPEX ≈ 15% от CapEx разработки за год).
- Контроль над latency и доступностью (нет внешней зависимости в критическом пути).

Отрицательные / риски (Cons) — честно:

- **Качество ниже GPT-класса** → риск неверных ответов на сложных запросах. *Митигация*: строгий RAG-grounding, ответ «не знаю» как валидный, дисклеймер, eval на golden set (RAGAS).
- **Нужны MLOps-компетенции** (мониторинг, обновление весов, безопасность) — команда сейчас на начальном уровне. *Митигация*: делегирование операционного контроля TL, Model Card, runbook.
- **Throughput и длина контекста ограничены железом** (2x H100). *Митигация*: квантование + sizing — [ADR-0006](#).
- **Ответственность за безопасность модели — на нас** (jailbreak/toxicity). *Митигация*: output-guardrails как постфильтр.

Pitch для СТО (1 абзац)

«Вопрос не в том, что лучше отвечает — GPT-5 объективно умнее. Вопрос в том, что **облачный SaaS нам просто недоступен**: мы в РБ под санкциями, а база знаний — это ПДн и коммерческая тайна под Законом № 99-З, которые по закону не могут уйти за периметр. Поэтому реальный выбор не «SaaS или self-hosted», а **«self-hosted или проекта нет»**. При этом железо (2x H100) уже куплено — CapEx закрыт, и каждый месяц на self-hosted мы платим предсказуемые ~15% от стоимости разработки за год вместо непрогнозируемого счёта за токены. Да, Qwen3.5-27B уступает GPT-5 на сложных рассуждениях — это честный trade-off, и мы его закрываем RAG-grounding'ом и guardrails, держа галлюцинации под контролем. Это не компромисс ради экономии — это **единственное решение, которое одновременно законно, доступно и экономически предсказуемо** в наших условиях.»

Сложности и решения

- **Учебная вводная (Llama 3 vs GPT-5) vs мой реальный кейс**: в задании это «дилемма качества/цены», у меня — **жёсткое ограничение доступности** (санкции + № 99-З). Решил не подгонять кейс под нейтральную вводную, а честно показать, что в моих «текущих условиях» (формулировка ДЗ) выбор детерминирован ограничениями → это и есть сильная аргументация «фактами, а не эмоциями».
- **Чтобы не плодить дубль-источник**: боевое решение живёт в [ADR-0001](#); здесь — учебная редакция под формат ДЗ (5 критериев + питч). При расхождении первичен ADR-0001.
- **Честность Consequences**: специально вынес минусы self-hosted (качество, MLOps, throughput) с конкретными митигациями — по критерию приёмки «честно указаны trade-offs».

Обратная связь от преподавателя