

Проектирование и оценка: от требований к плану, рискам и смете

AI-архитектор



Проверить, идет ли запись

Меня хорошо видно & слышно?





Иван Четвериков

AI Architect

- Более 5 лет опыта в разработке и архитектуре
- Специалист в разработке и проектировании AI-приложений в Raft

 @istrebitel_1

 istrebitel.3.12@gmail.com

Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в учебной группе



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Карта курса



СТАРТ

Стратегический
фундамент и
планирование проекта

Проектирование и
документирование
архитектуры

Продвинутые
архитектурные
паттерны

Инфраструктура

Качество, интеграции и
безопасность

Стратегия, лидерство и
экономика

Свой проект

ФИНИШ



Маршрут вебинара

От иллюзий к инженерным спецификациям

Оценка и планирование. Инженерия неопределенности

Управление рисками. Защита бюджета

Смета, FinOps и защита проекта

Шаблоны

Основные тезисы

Цели вебинара

К концу занятия вы сможете

Смысл

Для чего вам это уметь

1. Переводить абстрактные бизнес-запросы в измеримые требования и критерии приемки

чтобы исключить субъективность при сдаче проекта и бесконечный Scope Creep

2. Освоить методы планирования стохастических R&D-задач (PERT, воронка неопределенности)

чтобы перейти к математически обоснованным диапазонам сроков, учитывающим риски экспериментов с данными


3. Сформировать навык расчета полной стоимости владения (TCO) и себестоимости разработки (через коэффициентную модель)

чтобы аргументированно защищать перед бизнесом бюджеты на инфраструктуру, управление и митигацию рисков

TARGET AUDIENCE: SENIOR / LEAD ARCHITECT

Проектирование и оценка AI-систем

Как превратить вероятностный хаос в управляемый инженерный
план



От иллюзий к инженерным спецификациям

Дилемма архитектора

Фундаментальные противоречия при проектировании AI-систем в корпоративной среде.



Боль 1: Конфликт природы

БИЗНЕС ХОЧЕТ
Детерминизм (Сроки, Бюджет, Да/Нет)



AI ДАЕТ
Стохастику (Вероятности, Дрейф)



Боль 2: Ловушка точности

✖ Требование
«Система не должна ошибаться»

✔ Реальность
Любая ML-модель ошибается.
Вопрос в **цене ошибки**.



Боль 3: Скрытый R&D

Продаем как **Интеграцию API**, а попадаем в **Исследование на 3 месяца**.

Ответственность

Архитектор — человек, способный перевести вероятности на язык денег до подписания контракта.



ROLE RESPONSIBILITY

Трансформация требований

Уровни абстракции и трассировка

1

BUSINESS GOAL (BR)

«Сократить Support L1 на 50%»



2

PRODUCT CONSTRAINT

«Бот должен отвечать голосом»



ARCHITECTURAL DECISION

«Использование LLM с RAG + Whisper (STT) + ElevenLabs (TTS)»

4

ENGINEERING TASK

«Оптимизация latency пайплайна до 1.5 сек»



⚠ Проблема

Бизнес-требования (BR) в AI часто невыполнимы из-за ограничений вероятностных моделей.

⚙ Инструмент

Impact Mapping

Если BR не бьется с текущими возможностями SOTA (State of the Art) моделей — блокируем проект на старте.



РЕКОМЕНДУЕМАЯ ЛИТЕРАТУРА

Karl Wiegers "Software Requirements", 3rd Ed.

Глава 12: The subtle line between requirement and design

Нефункциональные требования (NFR)

В AI-проектах функционал («бот отвечает») вторичен. Первично — **КАК** он отвечает.



Performance Efficiency

SUB-CHARACTERISTIC: TIME BEHAVIOUR

Традиционный **RPS** (Requests Per Second) недостаточен для LLM.

Критические метрики:

- ⚡ TTFT (Time to First Token)
- ⌚ Total Generation Latency



Reliability & Security

SUB-CHARACTERISTIC: FAULT TOLERANCE

Система должна быть устойчива к состязательным атакам.

Критические проверки:

- 🔴 Prompt Injection (Jailbreaking)
- 🟡 Устойчивость к дрейфу данных



Compatibility

SUB-CHARACTERISTIC: INTEROPERABILITY

Способность работать с существующим IT-ландшафтом.

Критические интеграции:

- 🟦 Legacy Knowledge Base (SharePoint)
- 🟦 Confluence / Jira



Пример провала (Anti-pattern)

Не уточнили Latency → Бот «думает» 10 секунд → Пользователи вешают трубку → **Бизнес-цель не выполнена (BR Failed)**

Специфичные метрики качества AI



REFERENCE

"Building LLM Powered Applications"

«Сделайте умного бота» — это не метрика. Измеряем качество через AI-Driven NFRs.



TECHNICAL METRIC

Faithfulness

Ответ соответствует контексту и не содержит галлюцинаций. Проверка фактов из Knowledge Base.

Target Score

Ragas Score > 0.8



TECHNICAL METRIC

Answer Relevance

Ответ точно соответствует заданному вопросу, без "воды" и ухода от темы.

Target Score

Cos Sim > 0.85



TECHNICAL METRIC

Bias & Fairness

Отсутствие дискриминации по полу, возрасту или другим признакам в ответах модели.

Target Metric

Disparate Ratio $\approx$ 1.0



Стратегия внедрения метрик в контракт

</> Для команды (Technical Metrics)

Фиксируем Ragas/BLEU/Rouge. Используем для CI/CD пайплайнов и автоматического тестирования качества моделей.



Для бизнеса (Proxy Metrics)

Фиксируем бизнес-KPI: «% переоткрытых тикетов», «CSI бота», «Время обработки обращения».

Архитектурные драйверы

⚠ Ограничения жестче функций

Ключевые факторы, определяющие выбор технологий и структуру системы, которые нельзя изменить на этапе разработки.



01

Data Privacy

Юридические и безопасностные ограничения на перемещение данных (152-ФЗ, GDPR).

QUESTION

Можно данные в облако?

OpenAI / Claude

YES Serverless Architecture

NO Self-hosted LLM + GPU



02

Latency

Допустимое время ожидания ответа пользователем или системой.

QUESTION

Режим работы?

Real-time vs **Batch**

<200ms Small Models, Caching

Offline Heavy Models (GPT-4), CoT



03

Cost

Экономическая модель владения и масштабирования (OpEx vs CapEx).

QUESTION

Тип нагрузки?

Token vs **Compute**

SaaS API Pay-as-you-go

Own GPU Cluster (Rent/Buy)

Definition of Done (DoD) в AI-проектах

Как формализовать приемку результата, когда «идеальный» ответ субъективен.



Боль заказчика

«Мне не нравится, как он отвечает», хотя код работает без ошибок. Субъективная оценка качества блокирует подписание актов.



Golden Dataset

Эталонный набор данных для валидации (Ground Truth)

Состав

Набор из 100-500 пар:

```
{"question": "Как оформить отпуск?",  
  "answer": "Зайдите на портал..." }
```



Условие

Должен быть утвержден и подписан заказчиком **ДО** старта разработки (на этапе Discovery).



Критерий приемки (Acceptance Criteria)

Модель проходит Golden Dataset с метрикой **Semantic Similarity > 85%**



ЗАКОН АРХИТЕКТОРА



Нет Золотого датасета



Нет критериев приемки



Нет Fixed Price контракта

"Если вы не можете измерить успех, вы не можете его продать."

Работа с ограничениями

Треугольник компромиссов в GenAI


В Generative AI невозможно получить всё сразу. Любое архитектурное решение — это компромисс между тремя вершинами.

- ⚠️ **Cost:** Цена инференса (token/sec)
- 🧠 **Quality:** «Ум» модели и контекст
- ⌚ **Latency:** Скорость ответа (TTFT)



Задача архитектора

Визуализировать этот трейд-офф заказчику на первой встрече. Не обещайте GPT-5 со скоростью 100ms за копейки.



Юридический помощник



ПРЯМОЙ ЗАПРОС КЛИЕНТА

«Хотим загрузить все договора за 10 лет и искать риски. Точность 100%. Данные из контура выносить нельзя.»

ANALYSIS



Requirement

Ловушка точности

Требование «100% точности» технически невыполнимо для вероятностных моделей.

РЕШЕНИЕ

Augmented Intelligence

Не "автоматизация", а "подсветка рисков" с ссылкой на параграф для юриста.



Security

Контур данных

Запрет на облачные API (OpenAI/Anthropic) из-за NDA или 152-ФЗ.

DRIVER

On-premise / Self-hosted

Llama 3 / Mistral / Qwen на собственном GPU кластере.



Scale

Объем данных

«Все договора за 10 лет» — это миллионы токенов контекста.

ARCHITECTURE DECISION

RAG vs Fine-tuning?

Требуется оценка Retrieval (поиск) или Knowledge Injection (обучение).

Вопросы



если есть вопросы



если вопросов нет

Оценка и планирование. Инженерия неопределенности

Воронка неопределенности

Инженерия неопределенности: почему точная дата релиза в начале проекта — это ложь.


UNCERTAINTY

4x

Multiplier at project start

Эволюция точности оценки

Cost & Time Variance



Проблема "Точной Даты"

Заказчик требует точный срок («число и месяц») до того, как вы увидели данные.

Вы думаете: 1 месяц



Реальность: 4 месяца

✂ Инструмент переговорщика

Никогда не давайте Point Estimate (одно число). Используйте **Range Estimate**.

"От 2 до 5 месяцев"



Правило архитектора

Сужение воронки возможно **только** после этапа **Data Discovery**.

Пока не открыли датасет — воронка максимальная.

Разделяй и властвуй: Engineering vs R&D



TYPE 1: DETERMINISTIC

Engineering Tasks

Стандартные задачи разработки с предсказуемым результатом. Мы точно знаем, как это сделать.

ПРИМЕРЫ ЗАДАЧ:

- ✓ Поднять Vector DB (Chroma/Qdrant)
- ✓ Написать API обертку (FastAPI)
- ✓ Сверстать чат-виджет
- ✓ Настроить CI/CD пайплайны

Estimation Method



Bottom-Up

Оценка в часах или Story Points.
Риск низкий.



TYPE 2: STOCHASTIC

R&D Tasks

Исследовательские задачи с вероятностным исходом. Результат зависит от данных и качества моделей.

ПРИМЕРЫ ЗАДАЧ:

- 🔍 Собрать качественный датасет
- 🔍 Prompt Engineering (подобрать промпт)
- 🔍 Fine-tuning (дообучение модели)
- 🔍 Повысить точность RAG с 70% до 85%

Estimation Method



PERT (3-point)

Диапазон (Optimistic - Pessimistic).
Риск экстремальный.

VS

Метод PERT

Program Evaluation and Review Technique

USE CASE

R&D Tasks (Stochastic)

Expected Duration (E)

Средневзвешенное

$$E = \frac{0 + 4M + P}{6}$$

Учитывает "тяжелый хвост" распределения вероятностей.
Наиболее вероятный исход (M) имеет вес x4.

Standard Deviation (σ)

Уровень риска

$$\sigma = \frac{P - 0}{6}$$

Мера неопределенности. Чем больше разброс между
Оптимистичным и Пессимистичным, тем выше риск.

INPUT PARAMETERS (THREE POINTS)

O

Optimistic

Всё пошло идеально. Данные чистые, модель завелась с первого раза.

M

Most Likely

Реалистичный сценарий. Пара мелких багов, обычные задержки.

P

Pessimistic

Всё плохо. Данные мусор, архитектуру нужно менять. (Не включает форс-мажор типа пожара).


i

Как читать прогноз:

- **Plan (E):** Целевая дата для команды.
- **Commitment (E+2 σ):** Обещание бизнесу.

 $E \pm 2\sigma$

Диапазон уверенности 95% (2-Sigma)



Пример: Оценка Fine-tuning

Расчет сроков задачи «Дообучить Qwen-3 на базе знаний компании» по методу PERT.

→ Вводные данные (Inputs)

Optimistic (O)

3 дня

Данные чистые, лосс падает сразу, гиперпараметры подошли с первого раза.

Most Likely (M)

7 дней

Стандартный процесс: 2-3 перезапуска, небольшая чистка данных, валидация.

Pessimistic (P)

25 дней

Данные «мусор», модель переобучилась (overfitting), нужно менять архитектуру или разметку с нуля.

📊 Расчет (Calculation)

EXPECTED DURATION (E)

$$(3 + 4 \times 7 + 25) / 6$$

= 9.3 дняSTANDARD DEVIATION (Σ)

$$(25 - 3) / 6$$

= 3.6 дня

🚩 Итог для заказчика

ПЛАНОВЫЙ СРОК (BASELINE)

9 дней

Оптимистично, но реалистично

RISK BOUNDARY

95% Confidence **$9 + (2 \times 3.6) \approx 16$ дней**

"Мы закончим за 9 дней, но с вероятностью 95% уложимся в 16."




Insight

Разница между 7 днями (M) и 16 днями (95%) — это ваш **резерв**, который нужно защитить перед бизнесом.

WBS в AI-проекте

Структура работ с контрольными точками (Kill Gates)



Влияние "Kill Gates" на бюджет

Остановка проекта на ранней стадии экономит до 90% средств



Стратегия "Fail Fast" через PoC

Правило PoC: сначала Prompt Engineering, потом RAG, и только в конце Fine-tuning.

1

Start Here

Prompt Engineering

Попытка решить задачу через Few-Shot prompting, CoT (Chain of Thought) и системные инструкции.

АРГУМЕНТ

Самый дешевый и быстрый способ проверки гипотезы (1-2 дня).

2

Add Context

RAG (Retrieval)

Добавление внешней базы знаний через векторный поиск, если модели не хватает фактов.

АРГУМЕНТ

Решает проблему галлюцинаций и актуальности данных без переобучения.

3

Last Resort

Fine-tuning

Дообучение весов модели. Применяется только если нужно изменить стиль или формат ответа.

АРГУМЕНТ

Самый дорогой и рискованный путь. "Забывает" старые знания.



Стратегия PoC (Proof of Concept)

Делаем на **самой умной модели** (Claude 3.5 Sonnet / GPT-4o / O1). Не смотрим на цену (\$) и скорость (ms). Цель — проверить решаемость задачи в принципе.

ЭВРИСТИКА АРХИТЕКТОРА

«Если GPT-5 не может решить эту задачу с вашими данными, то Llama-8B тем более не сможет».

Data Engineering («Скрытая часть айсберга»)

Статистика неумолима: в AI-проектах работа с данными занимает львиную долю времени.

Visible Scope (~20%)

ModelTraining

Hidden Scope (~80%)

WHAT STAKEHOLDERS SEE

Model Selection

Prompt Engineering

WHAT ACTUALLY HAPPENS



Sanitization

Удаление PII, паролей, API-ключей (Data Privacy).



Formatting

Превращение PDF таблиц в Markdown/JSON (ETL).



Annotation

Инструкции для ассессоров, валидация разметки.



Versioning

Настройка DVC (Data Version Control) и lineage.



СОВЕТ АРХИТЕКТОРА

Всегда умножайте оценку времени на работу с данными на **x2**. Если кажется, что данные чистые — вам кажется.

Вопросы



если есть вопросы



если вопросов нет

Управление рисками. Защита бюджета

Анатомия риска. От "страха" к "деньгам"

Бизнес не понимает слово «страшно». Бизнес понимает слово «дорого».

RISK (Риск)



Неопределенное событие, которое **может** произойти в будущем.

Future / Uncertainty

ISSUE (Проблема)



Риск, который **уже реализовался**. Требуется немедленной реакции.

Present / Fact



Задача Архитектора — не допустить превращения Risk в Issue.

THE MONEY FORMULA

$$\text{Risk Exposure (₽)} = P \times I$$

P = Probability (%)

I = Impact (₽ Cost)

Example Scenario **Риск: «Инференс модели окажется дороже плана»**

Probability

30%

×

Impact (Monthly)

₽ 1,000,000

=

Risk Exposure

₽ 300,000/month

→ Эту сумму (300к) необходимо добавить в резерв бюджета проекта.



ПРАВИЛО АРХИТЕКТОРА

Не приходите с проблемами. Приходите со стоимостью их решения.

Классификация AI-рисков



OWNER: CLIENT / DATA OWNER

1. Data Risks

- **Scarcity:** Данных слишком мало для обучения (Cold Start problem).
- **Quality:** Данные грязные, неструктурированные или без разметки.
- **Bias:** Смещение в выборке (например, только успешные кейсы).
- **Rights:** Нет юридических прав на использование для ML.



OWNER: DATA SCIENCE TEAM

2. Model Risks

- **Performance:** Не достигается целевая метрика (Accuracy/Recall).
- **Hallucinations:** Модель выдумывает факты в RAG.
- **Forgetting:** Модель забывает общие знания после дообучения.
- **Drift:** Деградация качества со временем (Concept Drift).

AI RISKS



OWNER: ARCHITECT / DEVOPS

3. Infrastructure Risks

- **GPU Shortage:** Дефицит H100/A100 у провайдера.
- **Cost Surge:** Неконтролируемый рост расходов на инференс.
- **Latency:** Задержки при пиковой нагрузке (Cold boot).
- **Dependencies:** Ломающие обновления библиотек (PyTorch/CUDA hell).



OWNER: SECURITY / LEGAL

4. Security & Legal Risks

- **Data Leakage:** Утечка PII через промпты или логи.
- **Prompt Injection:** Атаки типа "Jailbreak" (DAN mode).
- **IP Violation:** Генерация контента, защищенного авторским правом.
- **Compliance:** Нарушение GDPR/152-ФЗ при трансграничной передаче.

Стратегии работы с рисками

Архитектурные паттерны для обработки неопределенности



1. Avoid

ИЗБЕЖАТЬ

Изменение архитектуры или плана таким образом, чтобы риск исчез полностью. Радикальное устранение источника.

EXAMPLE SCENARIO

Риск утечки PII в OpenAI Cloud.

→ On-prem Qwen-3



2. Mitigate

СНИЗИТЬ

Уменьшение вероятности возникновения или степени влияния риска до приемлемого уровня.

EXAMPLE SCENARIO

Риск галлюцинаций модели в ответах.

→ RAG + Guardrails



3. Transfer

ПЕРЕДАТЬ

Перекалывание ответственности за риск на третью сторону (страховка, аутсорс, вендор).

EXAMPLE SCENARIO

Сложность и сроки разметки данных.

→ Outsource + SLA



4. Accept

ПРИНЯТЬ

Осознанное решение не предпринимать действий, кроме создания финансового резерва.


EXAMPLE SCENARIO

Простой дорогого GPU-кластера ночью.

→ Reserve Budget

Матрица рисков

Матрица — это не документ в стол, а навигационная карта. Риски пересматриваются на каждом Sprint Review.



RED ZONE

Проект/фича блокируется.
Требуется план митигации до старта.

YELLOW ZONE

Активный мониторинг.
Включение в Risk Budget.

GREEN ZONE

Приемлемый риск.
Периодическая проверка.

CASE STUDY: R1



Риск "Дефицит GPU"

START (T0)

● Green: "Поставщик обещает поставку H100 через 2 недели."



SPRINT 2
(T+1M)

RED ALERT

Vendor прекратил поставки. Риск реализовался (Issue).

ARCHITECTURAL MITIGATION

Внедрение **Cloud Bursting**. Если On-prem кластер недоступен, нагрузка автоматически переключается в Yandex/Sber (дороже, но сервис жив).

Контрактная защита

Fixed Price vs Reality: Как не подписаться на бесконечное "обучение"



ОПАСНАЯ ЗОНА: FIXED PRICE НА R&D

Fixed Price контракт для задач обучения моделей (Fine-tuning) или повышения качества RAG — это путь к финансовому убытку. Вы не можете гарантировать результат стохастического процесса (AI) фиксированным бюджетом.



ДЛЯ РОС/MVP

1. Capped T&M

Time & Materials с потолком бюджета

Мы работаем по часам, но гарантируем заказчику, что этап не превысит оговоренную сумму. Риск делится пополам.

ФОРМУЛИРОВКА:

"Оплата по факту затраченных часов, но не более ₹ 5,000,000 за этап РоС. Если сделаем быстрее — вы платите меньше."



ВЫСОКАЯ НЕОПРЕДЕЛЕННОСТЬ

2. Фазирование (Phasing)

Контрактуем только видимый горизонт

Запрет на оценку всего проекта сразу. Подписываем договор только на Discovery/Audit. Следующий этап оценивается по его итогам.

ФОРМУЛИРОВКА:

"Этап 1: Аудит данных (Fixed Price). Результат Этапа 1 — точная смета на Этап 2. Мы не можем оценить стройку, не видя грунта."



ДЛЯ R&D / FINE-TUNING

3. Фиксация Процесса

Fix the Process, not the Result

Вместо гарантии "Точность 99%" (которая может быть недостижима), мы продаем количество итераций экспериментов.

ФОРМУЛИРОВКА:

"Предметом договора является проведение 3-х циклов обучения модели и предоставление отчета о метриках. Достижение точности 99% не гарантируется."

Вопросы



если есть вопросы




если вопросов нет

Смета, FinOps и защита проекта

Айсберг бюджета AI-проекта

AI-проект не заканчивается релизом. Он только начинает тратить деньги на инференс и поддержку.



VISIBLE COSTS (CAPEX)



Labor (ФОТ)

Data Scientists, DE, ML Ops salaries.

30-40%



Data Acquisition

Разметка, покупка датасетов, очистка.

10-20%

OPEX REALITY

HIDDEN RECURRING COSTS (OPEX)



Compute (Training)

Разовое обучение или Fine-tuning (CapEx/OpEx mix).



Compute (Inference)

Ежемесячные расходы на токены (API) или аренду GPU.

Largest Cost



ФИНАНСОВЫЙ ИНСАЙТ

Все считают зарплаты (ФОТ), но забывают эксплуатацию.

AI-проект начинает тратить основные деньги только после релиза.

Анатомия трудозатрат

Почему 100 часов кодинга $\neq$ 100 часов бюджета

MANAGEMENT OVERHEADS

Total Estimate ~ 1,450h

RISK BUFFER
~210h

Confirmed Risks
from Register

GOVERNANCE
PM + Arch

Project Mgmt &
Tech Oversight

TECHNICAL LEADS
TL + AI Lead

Code Review, R&D
Control

WBS BASE
854h

Pure Engineering
(Dev + QA + Ops)

ПРОБЛЕМА «ДЫРЯВОЙ СМЕТЫ»

Если посчитать только часы написания кода, проект станет убыточным. Коммуникация, контроль качества R&D и архитектурный надзор «съедают» всю маржу.

КОЭФФИЦИЕНТЫ (OVERHEADS)

TL

Team Lead

Code Review, Tech Design

+30%

AI

AI Lead

Валидация гипотез, R&D контроль

+30%

PM

Project Manager

Коммуникация, отчетность

+15-20%

AR

Architect

Авторский надзор, Governance

+10-15%

THE GOLDEN FORMULA

Total = (Base Hours $\times$ 1.45) + Risk Buffer

TCO (Total Cost of Ownership)

Почему важна стоимость одного запроса, а не только сервера

THE GOLDEN FORMULA

$$TCO = CapEx + (OpEx \times 36m)$$

CapEx (Разовые)

Training, Data, R&D

OpEx (Ежемесячные)

Inference, MLOps, APIs



Architectural Solution

Model Distillation: Перенос знаний из дорогой "учительской" модели (GPT-5) в дешевую "студенческую" (Llama-3-8B).

→ Снижение стоимости запроса в ~10-50 раз

Unit Economics Breakdown

1 User / Month

Scenario: SaaS Subscription Model

REVENUE (PLAN)

\$10.00

per month

COST (API)

\$12.00

100 req × \$0.12 (GPT-5)

GROSS MARGIN:

-\$2.00 / user



Inference: Cloud (SaaS) vs Self-hosted (On-prem)

Поиск точки безубыточности (Break-even Point) для высоких нагрузок

SCENARIO: 10,000 req/day (2k tokens avg)

Вариант А: SaaS (API)

OpenAI / Anthropic / Bedrock



- ✓ **No DevOps:** Не нужно настраивать CUDA, драйверы, балансировку.
- ✓ **Infinite Scale:** Легко держит пики нагрузок.
- ✗ **Linear Cost:** Платишь за каждый токен. 10k req ≈ \$1,500/мес.

Вариант Б: On-premise

Self-hosted GPU (H100/A100)



- ✓ **Fixed Cost:** Сервер куплен (\$20k) и работает 3-5 лет.
- ✓ **Privacy:** Данные не покидают контур.
- ✗ **Idle Risk:** Ночью GPU простаивает, но амортизация капает.
- ✗ **DevOps Heavy:** Нужна команда поддержки.

CUMULATIVE COST OVER TIME (3 YEARS)



FinOps паттерны для архитектора

Как снизить смету инференса, не снижая качество продукта



01

Model Routing

Implementation: AI Gateway

Маршрутизация запросов в зависимости от сложности. Простые вопросы идут на дешевые модели, сложные — на SOTA.

**70%**

COST SAVINGS

Example: "Hi" vs "Analyze Contract"




02

Semantic Caching

Implementation: Vector DB (Redis/Qdrant)

Если новый вопрос семантически близок к предыдущему (Cosine Sim > 0.95), возвращаем кэшированный ответ.

**30%**

COST & LATENCY REDUCTION

Best for: FAQ, Support Bots



03

Quantization

Implementation: 4-bit / AWQ

Снижение точности весов с 16-bit до 4-bit. Позволяет запускать тяжелые модели на дешевом железе.

**4x**

LOWER VRAM USAGE

Run Llama-70B on 2×3090 instead of A100

Резервы бюджета

Смета AI-проекта без резерва — это провал.



TYPE 1

Known Unknowns

Известные риски

Риски, которые мы идентифицировали в реестре, но не знаем точно, сработают ли они.

$$\Sigma (\text{Risk Exposure from Register})$$

ПРИМЕР

"Риск задержки разметки" (30% × 500к) + "Риск доп. итераций" (50% × 200к) = **₽ 250,000**



TYPE 2

Unknown Unknowns

Управленческий резерв

События, которые мы даже не можем представить сейчас (например, выход GPT-6 завтра, меняющий архитектуру).

$$(\text{Base Estimate}) \times 15\% \dots 20\%$$

ПРИМЕР

Бюджет проекта 10 млн. Резерв на "черных лебедей" = **₽ 1,500,000**

TOTAL BUDGET FORMULA

Budget = Base + Reserves

Total Contingency

~25–30%



Change Management

Любое изменение функционала — это изменение бюджета.

Scope Creep = Budget Creep

"Хочу еще распознавание картинок" = "Нужен Vision Model + Vector DB + \$\$\$"

1



Change Request

Клиент просит новую фичу.
"А давайте добавим..."

2



Impact Assessment

Архитектор считает TCO Delta.
(Infra + License + Dev Hours)

3



Approval (CR)

Подписание Доп. соглашения.
Выделение бюджета.

4



Implementation

Тикет уходит в разработку.
Фича попадает в бэклог.

ПРАВИЛО



Нет тикета в Jira с оценкой в деньгах — нет фичи в проде.

Разработчик не имеет права брать задачу без ссылки на утвержденный CR (Change Request).

Защита проекта перед стейкхолдерами

Матрица интересов C-Level: На каком языке говорить?



MONEY

CFO

Финансовый директор

- ✓ ROI (Return on Investment)
- ✓ TCO (Total Cost of Ownership)
- ✓ Payback Period

AB "CapEx vs OpEx", "Margin Impact"



TECH

CTO

Технический директор

- ✓ Tech Stack & Governance
- ✓ Security (GDPR/PII)
- ✓ Scalability & SLA

AB "Tech Debt", "Latency", "Compliance"



VISION

CEO

Генеральный директор

- ✓ Time-to-Market
- ✓ Competitive Advantage
- ✓ Strategic Asset Building

AB "Growth", "Innovation", "Market Share"




ШПАРГАЛКА: НЕУДОБНЫЕ ВОПРОСЫ

💰 ВОПРОС: "ПОЧЕМУ ТАК ДОРОГО?"

"Мы строим Актив (Data Asset), а не просто пишем код. 40% сметы — это подготовка наших уникальных данных, которые останутся у компании навсегда и создадут "рвы" (moats) от конкурентов."

⌚ ВОПРОС: "ПОЧЕМУ ТАК ДОЛГО?"

"Это R&D проект. Мы платим временем за снижение риска выпустить 'глупого' бота. Быстрый запуск ML-модели = Технический долг в виде галлюцинаций, который убьет репутацию бренда."



Вопросы



если есть вопросы



если вопросов нет

Итоги занятия

Рефлексия

Итоговый чек-лист

5 шагов для превращения AI-хаоса в управляемый инженерный проект.

01



Требования формализованы (NFR & Golden Dataset)

«Сделайте умно» заменено на метрики (DeepEval, Semantic Similarity). Создан и утвержден Золотой датасет для приемки.

02



R&D оценен диапазонами (PERT)

Никаких точных дат на старте. Трехточечная оценка (Optimistic / Most Likely / Pessimistic).

03



Риски оцифрованы в деньгах (Exposure)

Риски переведены с языка страхов на язык бюджета: $Risk Exposure = Probability \times Impact (P)$.

04



Смета включает ТСО и Резервы

Посчитан не только CapEx (разработка), но и OpEx (инференс на 3 года). Заложены резервы на Unknown Unknowns.

05



Управление изменениями

Любое расширение скоупа через CR с пересчетом бюджета. $Scope Creep = Budget Creep$.

READY TO START

Architecture Assessment



NEXT STEPS:

- ☐ Sign Discovery Contract
- ☐ Data Audit
- ☐ PoC Launch

Summary & Next Steps

“**Не начинайте писать код,
пока не договорились:
как измерять успех
и кто платит за ошибки.**”

Архитектура AI-системы — это не выбор фреймворка. Это превращение вероятностного хаоса в управляемый инженерный план с предсказуемым бюджетом.

Architect's Toolkit

FREE RESOURCES



Сканируйте и забирайте шаблоны



Калькулятор трудозатрат

Excel Model with PERT formulas



NFR Checklist (ISO 25010)

PDF / Notion Template



Risk Register Template

Heatmap & Mitigation Strategies



**Отправьте в чат эмодзи, который
отражает ваше настроение
после занятия**



**Продолжите высказывание: теперь
я умею/знаю...**



**Что планируете использовать
в работе?**

По этой теме вы можете изучить:

- **Книга:** Steve McConnell, *"Software Estimation: Demystifying the Black Art"* (Главы про Воронку неопределенности).
- **Сайт:** NIST AI Risk Management Framework (nist.gov/itl/ai-risk-management-framework) — стандарт управления рисками.
- **Мануал:** ISO/IEC 25010 (Quality Models) — база для составления NFR.
- **Статья:** Google Research: *"The Hidden Technical Debt in Machine Learning Systems"* (Классика про то, почему код — это лишь верхушка айсберга).
- **Видео:** Chip Huyen: *"Building LLM Applications for Production"* (Разбор метрик и инфраструктуры).
- **Приложение:** *"LLM VRAM Calculator"* (HuggingFace Spaces) — для быстрого сайзинга железа.



Заполните, пожалуйста, опрос о занятии

Мы читаем все ваши сообщения
и берем их в работу 🖋️❤️

OTUS

