

Архитектура данных для AI систем

AI Архитектор



Проверить, идет ли запись

Меня хорошо видно & слышно?





Лавров Денис

Старший архитектор @MTS AI

- 17 лет в ИТ
- занимался архитектурой инструментов модельного инференса в Сбере
- распиливал монолиты на микросервисы
- строил аналитические хранилища и средства визуализации отчетности
- преподаватель курсов «Инфраструктурная платформа на основе Kubernetes», «Микросервисная архитектура» и «SoftwareArchitect» в ОТУС



@roflmaoinmysoul

Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в учебной группе **#канал
группы**



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Маршрут вебинара

Знакомство

Классическая BigData

Специфика пайплайнов для AI
решений

Feature Store

Data Governance

Проектирование пайплайнов для
ML



Цели вебинара

К концу занятия вы

1. Будете понимать основные паттерны
BigData

2. Будете знать специфические решения
в построении пайплайнов данных под AI
решения

3. Сможете спроектировать
верхнеуровнево end-to-end pipeline для
обучения и инференса ML модели



Классическая BigData

OLTP и OLAP

- **OLTP** – исторически первый подход к работе с данными, операционная работа приложений, в основном реляционные СУБД
- Гарантии транзакционности, преимущественно нормализованные данные
- **OLAP** – подход к обработке большого количества данных в целях аналитики, принятия решений, построения прогнозных моделей и тд
- Часто специализированные СУБД, хорошо работающие именно с OLAP профилем нагрузки, преимущественно денормализованные данные
- Часто характерны неструктурированные данные




Классический ETL

- Системы источники данных (OLTP) многочисленны и разрозненны
- СУБД, подходящие для OLTP операций, часто плохо работают с OLAP операциями
- Целесообразно собрать все данные, требующиеся для аналитических операций в одном месте, и выбрать подходящую СУБД
- Данные необходимо извлечь (Extract) из систем источников
- Преобразовать (в памяти или в временном хранилище) – Transform
- Загрузить в целевое хранилище - Load



DWH





ELT


- Невозможность знать заранее, какие данные потребуются для аналитики (особенно Research задачи)
- Постоянно изменяющиеся бизнес-требования приводят к необходимости регулярно перевыгружать данные из систем источников за прошлые периоды
- Целесообразно иметь постоянно хранящийся слой «сырых» данных, которые в последствии используются для расчета витрин
- Данные выгружаются из систем-источников (Extract)
- В сыром, либо слабо преобразованном виде загружаются в stage-слой – Load
- При необходимости построения витрин и отчетов данные преобразуются из stage слоя - transform




ETL vs ELT





DataLake



Lakehouse



Batch vs Stream




Data Governance

Data Governance / Data Management

- Фреймворк, описывающий набор правил, ролей и формализующих процессы работы с данными ИТ ландшафте
- Рассматривает данные как актив, определяет владельцев конкретных данных, ответственных за них
- Каталог данных / MDM
- Data Quality как одна из целей
- Data Lineage – отслеживание происхождения и жизненного пути данных
- Data Security



DAMA DMBOK2



Специфика для AI решений

Специфика для AI решений

- Преимущественно использование ELT подхода и DataLake / Lakehouse как источника данных для экспериментов и обучения
- Часто требуется использовать данные в т.ч и для исполнения моделей, что порождает НФТ, несвойственные для классических BigData решений
- Необходимость версионировать данные / датасеты, и потребность в инструментах, позволяющих удобно это делать



FeatureStore

Возможные способы подготовки датасета

- Выгрузить требуемые данные из существующей витрины DWH
- Написать самостоятельно скрипт выгрузки требуемых данных из stage area / data lake
- Самостоятельно собрать требуемые данные из различных систем источников
- ... ???



Проблемы

- В уже существующих витринах DWH зачастую нет требуемых данных
- Доработка существующих витрин обычно слишком долго и зачастую нецелесообразно для просто эксперимента
- Самостоятельный сбор датасета по сути всегда «одноразовый» процесс без возможности переиспользовать
- Потенциальные проблемы с Data Quality и Data Lineage при самостоятельной сборке датасета
- Данные собранные для обучения могут отличаться от данных, которые впоследствии будут использоваться для инференса (training-serving skew)




FeatureStore

- Централизованная система, предназначенная для управления, хранения и предоставления признаков (features) для обучения и инференса моделей
- Признак (feature) – измеримое свойство какого либо объекта или явления (entity)
- Используется как для обучения моделей так и для их инференса, предотвращает training-serving skew
- Позволяет переиспользовать фичи между разными проектами / задачами



FeatureStore



Популярные решения

- Feast – open-source решение, on-prem, слабо подходит для enterprise без доработок
- Hopsworks – часть большой ML-платформы, On-prem или cloud,
- Databricks / SageMaker / Vertex – managed-решения составе ML-платформ
- Tecton – managed-решение, Enterprise-ready
- Самописные решения под ваши потребности



Когда стоит применять

- Для инференса требуются семантически те же данные, что и используются при обучении модели
- Высокие требования к latency получения данных (online инференс)
- Много зрелых моделей в продакшен, соответствующие критериям выше
- Высокий запрос на переиспользование фичей между разными командами / проектами



Проектирование пайплайна для ML

Проектирование пайплайна

- Определение и анализ источников (stream vs batch)
- Сбор, очистка, преобразование данных, контроль качества (ETL vs ELT, Expectations/Profiling для обеспечения качества)
- Хранение данных (DWH/Lake, Vector DB)
- Выделение фичей (Feature store, нужен или нет)
- Формирование датасета, разделение на обучающую / валидационную / тестовые выборки (формат, версионирование)
- Data Security (приватные, маскированные, синтетические данные, доступ к ним)
- Data Lineage, особенно если не используется feature store
- Учесть необходимость данных при инференсе модели



Вопросы?

Заполните, пожалуйста, опрос о занятии

Мы читаем все ваши сообщения
и берем их в работу 🖋️❤️