

ДЗ-17 · Sizing: расчёт ресурсов инфраструктуры и стоимости инференса

Студент: Александр Зубик · **Курс:** AI Architect (OTUS) · **Задача:** Llama-3-70B (FP16 и INT4) под 1000 RPM **Артефакт:** [калькулятор \(xlsx → Google Таблица\)](#) — 6 листов, все расчёты живыми формулами; жёлтые ячейки — входные параметры, зелёные — вычисления.

Шаг 1 · Hardware Sizing (формула лекции: VRAM = Параметры × Точность + KV cache + Overhead)

Модель: Llama-3-70B — 70.6 млрд параметров, 80 слоёв, GQA 8 KV-голов × head_dim 128. Нагрузка: 1000 RPM = 16.7 RPS; допущения: вход 800 токенов, выход 250 токенов.

Величина	FP16	INT4 (AWQ/GPTQ)
Веса (N × байт/парам.)	70.6 × 2 = 141.2 ГБ	70.6 × 0.55 = 38.8 ГБ (0.5 + ~10% scales)
KV-кэш на токен (2×80×8×128×2 Б)	0.33 МБ	0.33 МБ (KV оставлен FP16)
Одновременных запросов (Little: RPS × время обслуживания)	~156	~121
KV-кэш суммарно (× средний контекст 925 ток.)	47.1 ГБ	36.6 ГБ
ИТОГО (+10% overhead)	≈207 ГБ	≈83 ГБ

Сколько и каких GPU (по памяти):

GPU	FP16	INT4	Вердикт
A100 80GB	3 → 4 (TP=4)	2 (TP=2, NVLink)	базовый выбор
T4 16GB	13	6	непригодна: Turing — нет FlashAttention (нужен Ampere+), нет BF16, слабые INT4-ядра, PCIe
L4 24GB	9	4	по памяти проходит в INT4, но 300 ГБ/с (в 6.7 раза медленнее A100) и в RU-облаках почти отсутствует

Проверка по пропускной способности (компьютер-потолок ≈ TFLOPS × утилизация 50% / 2N): FP16 на 4× A100 ≈ 4 400 ток/с ≈ **1 060 RPM** — одна реплика держит

нагрузку впритык; INT4 на 2× A100 $\approx 2\,200$ ток/с $\approx$ **530 RPM** — нужно **2 реплики (4× A100 всего)**, зато с HA из коробки.

Шаг 2 · Cloud Selection (цены публичных прайсов, зафиксированы 07.07.2026)

Yandex Cloud и Cloud.ru публикуют GPU-цены только в JS-калькуляторах (в статических доках их нет), поэтому взяты два облака с открытым прайсом — методика переносится 1:1:

Сценарий	immers.cloud	Intelion Cloud («от»)
INT4 · 2 реплики × 2× A100 NVLink (1000 RPM) ★	$2 \times 439.97 \text{ ₽/ч} \times 730 = \mathbf{642\,356 \text{ ₽/мес}}$	$2 \times 346 \text{ ₽/ч} \times 730 = \mathbf{505\,160 \text{ ₽/мес}}$; годовой резерв (−25%) = 378 870 ₽/мес
FP16 · 4× A100 (1 реплика, без запаса)	$879.13 \text{ ₽/ч} \rightarrow 641\,765 \text{ ₽/мес}$	$692 \text{ ₽/ч} \rightarrow 505\,160 \text{ ₽/мес}$
FP16 · 8× A100 (прод-запас ×2)	$1\,677.58 \text{ ₽/ч} \rightarrow \mathbf{1\,224\,633 \text{ ₽/мес}}$	$2 \times 692 \text{ ₽/ч} \rightarrow 1\,010\,320 \text{ ₽/мес}$ (−25% $\rightarrow 757\,740$)
Антипример: 20× T4 (5 реплик 4× T4, INT4)	$5 \times 105.84 \text{ ₽/ч} \rightarrow 386\,317 \text{ ₽/мес}$	—

Источники: immers.cloud/gpu/a100 (2× A100 NVLink 439.97 ₽/ч; 4× 879.13; 8× NVLink 1 677.58; 4× T4 105.84), intelion.cloud/tesla-a100-80gb (A100 80GB от 173 ₽/ч; скидки 3/6/12 мес = 8/15/25%). T4-флот на бумаге дешевле, но это ~20 карт с латентностью декодинга ~15 ток/с на запрос против ~40 у A100, без FlashAttention и с рисками совместимости INT4-ядер — «дешёвая карта ≠ дешёвый флот».

Шаг 3 · Optimization: батчинг и vLLM

Сценарий INT4 на репликах 2× A100 (immers.cloud):

Режим	Реплик	₽/мес	Экономия
Без батчинга (batch=1, последовательно): 8.3 запр/мин на реплику	~121 (242 GPU!)	~38.9 млн	—
Статичный батчинг (простой на выравнивании длин)	~4	~1.28 млн	~97%
vLLM: continuous batching + PagedAttention ★	2	642 тыс	~98.3%

Прогноз: continuous batching — главный множитель (×60 к числу карт против последовательной обработки); PagedAttention дополнительно убирает до 90% потерь KV-VRAM от наивной преаллокации (слайд лекции), что и позволяет

держат ~120 одновременных запросов в 160 ГБ. Резерв на будущее: FP8/INT8-квантование KV-кэша удваивает конкурентную ёмкость без новых карт.

Шаг 4 · Вывод (рекомендация)

Llama-3-70B INT4 (AWQ/GPTQ) под vLLM на 2 репликах × 2× A100 80GB NVLink (итого 4× A100): ~505–642 тыс ₽/мес, при годовом резерве — ~379 тыс ₽/мес.

- Квантование INT4 снижает VRAM-требование с 207 до 83 ГБ (–60%) → вместо одного сервера 4× A100 (или 8× для запаса) — две независимые пары карт: дешевле, доступнее в облаках, HA из коробки (отказ реплики = деградация до 530 RPM, а не даунтайм), масштабирование шагом ~530 RPM.
- FP16 оправдан только если офлайн-eval покажет недопустимую деградацию качества INT4 — тогда 8× A100 ≈ 1.0–1.2 млн ₽/мес (×2 дороже при том же SLA).
- T4 непригодна технически, L4 — ниша моделей 7–8B; обе «экономии» разбиваются о пропускную способность памяти.
- Радикальная опция при мягких требованиях к качеству: дистилляция/младшая модель (Llama-3.1-8B) — влезает в 1× L4/A10 и меняет класс стоимости, но это уже продуктовое решение, не инфраструктурное.

Сдача: `xlsx` импортируется в Google Таблицы (Файл → Импортировать → Загрузить, формулы сохраняются), доступ по ссылке — «Читатель».