

Архитектура MLOps-конвейеров


AI Архитектор



Проверить, идет ли запись

Меня хорошо видно & слышно?





Николай Осипов

MLOps Engineer

- 5+ лет в области Data Science
- MLOps, DS инфраструктура, табличные данные
- Преподаватель курса LLM-DD
- Выступаю преподавателем и наставником на курсах: MLOps, ML Advanced/Basic, DevOps

Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в учебной группе



Задаем вопрос
в чат



Вопросы вижу в чате,
могу ответить не сразу

Карта курса



СТАРТ

Стратегический фундамент и планирование проекта

Проектирование и документирование

Качество, интеграции
безопасность

Продвинутые
архитектурные
паттерны

Инфраструктура

Стратегия, лидерство
и экономика

Проектная работа

ФИНИШ



Маршрут вебинара

Знакомство

Блок 1: MLOps-конвейеры

Блок 2: Model Drift

Блок 3: Практика

Итоги

Q&A



Цели вебинара

К концу занятия вы сможете

1. Понимать, что такое MLOps. Объяснить роли инструментария MLOps
2. Понимать принципы построения ML-пайплайнов, учитывая model drift
3. Спроектировать MLOps-пайплайн для RAG-системы с автообновлением векторной базы



Смысл

Это нужно уметь чтобы:

1. Понимать, зачем нужны MLOps-процессы в команде

2. Чтобы внедрять лучшие практики в свои процессы

3. Иметь базовые знания проектирования MLOps



**Что такое MLOps и в чем
отличие от DevOps?**



DevOps и MLOps практики

DevOps

объединяет разработку и эксплуатацию ПО: CI/CD, инфраструктура как код, мониторинг сервисов. Артефакт — работающий сервис, который либо работает, либо нет.

MLOps

добавляется третье измерение: данные и качество модели. Сервис может «работать» технически, но деградировать из-за data drift — и это нужно отслеживать отдельно. Отсюда версионирование датасетов, feature stores, мониторинг метрик модели и переобучение по расписанию.

Автоматизированные MLOps- конвейеры

MLOps-конвейер – это

автоматизированная цепочка шагов:

(1) сбор данных → (2) обучение → (3) валидация →
(4) деплой → (5) мониторинг, которая запускается
без ручного вмешательства

Три инструмента MLOps-стека



Airflow — оркестрация.
Управляет порядком задач, расписанием, retry-логикой.
Контролирует выполнение, но не знает ничего про ML.



MLflow — память системы. Логирует параметры, метрики, артефакты.
Версионирование моделей и продвижение их Staging → Production.



Kubeflow — масштабирование. ML-платформа на K8s.

Apache Airflow

Оркестратор пайплайнов через Python DAG

- Гибкость DAG на Python, богатая экосистема операторов, встроенный UI-мониторинг, легкая интеграция с множеством сервисов.

Минусы: нет нативной поддержки ML-артефактов, требует DevOps-настройки, не заточен под эксперименты.



Screenshot of the Apache Airflow web interface showing a DAG named `toy_chain_linear_vs_chain_complex`.

The interface includes a sidebar with navigation links: Home, Dags, Assets, Browse, and Admin.

The main view displays a list of DAG tasks and their execution status across multiple runs. The tasks listed are:

- end_chain_linear__1
- start_chain
- start_chain__1
- start_chain_linear
- chain_linear_t0
- chain_linear_t1
- chain_linear_t2
- chain_linear_t3
- chain_linear_t4
- chain_linear_t5
- chain_linear_t6
- chain_linear_t7
- chain_linear_t8
- chain_linear_t9
- chain_t10
- chain_t11
- empty_1
- end_chain_linear
- chain_t12
- chain_t13
- chain_t14
- chain_t15
- chain_t16
- chain_t17
- empty_2
- chain_t18
- chain_t19
- end_chain

The execution status is visualized using a grid of colored circles: green for successful, red for failed, and orange for warning. A bar chart on the right shows the duration of the tasks in seconds.

The right sidebar provides an overview of the DAG's execution history, including a table with columns for Schedule, Latest Run, and Next Run. The latest run is shown as 2025-04-21, 13:11:17 with a green checkmark indicating success.

Below the overview, there is a section for "Failed Tasks" showing a bar chart of the last 14 dag runs. The chart shows a significant increase in failure rate, with the last run failing at 7.52 seconds and the previous run failing at 0.51 seconds.

The "Recent Failed Task Logs" section displays the details of the failed tasks, including the task name, timestamp, and the exception message: "Task failed with exception: Random failure".

MLflow

Система учёта экспериментов и реестр моделей

- Логирование: параметры, метрики, артефакты каждого запуска. Model Registry: Staging → Production. Сравнение экспериментов.
Без MLflow: никто не знает, какая модель обучена на каких данных и с какими параметрами. С MLflow: у каждой модели полная lineage.




Kubeflow Pipelines


ML-платформа поверх Kubernetes

- Нативная поддержка ML-экспериментов, версионирование артефактов, масштабирование на GPU/TPU.

Минусы: тесная привязка к Kubernetes, сложная первоначальная настройка, высокий порог входа.



Пайплайн переобучения



Когда запускать переобучение

1. Триггеры по времени

- Еженедельно
(стабильные данные).
- Ежедневно
(быстро меняющаяся среда).
- По количеству новых сэмплов.

2. Триггеры по качеству

- Падение метрик ниже порога
- $\text{Data drift} > \text{threshold}$
- Жалобы пользователей / аномалии.

Какой деплой модели можно выбрать

Blue-Green:

Две полные среды (v1 и v2). Мгновенное переключение трафика. Быстрый откат — просто переключить роутер обратно.

Canary:

Постепенный перевод 5%→25%→100%.
Контроль метрик на каждом шаге.
Меньше риск, но дольше.

Вопросы



если есть вопросы



если вопросов нет



Блок 2: Мониторинг Model Drift

**Что такое model drift и
почему он опасен?**



Model Drift – это

деградация качества ML-модели в продакшне из-за того, что реальные данные перестают соответствовать обучающим данным



Основные типы Дрейфа Моделей



Data Drift: статистика входных фич изменилась — другое распределение, выбросы, пропуски.



Concept Drift: связь между фичами и таргетом изменилась — модель обучена на «старой реальности».

Data Drift vs Concept Drift

Data Drift

Что меняется:

распределение входных данных [X].

Пример:

изменился портрет пользователя, другой регион.

Concept Drift

Что меняется:

связь между данными и их использованием $[X \rightarrow Y]$.

Пример:

поведение пользователей изменилось из-за внешних событий.

Инструменты обнаружения дрейфа

Статистические тесты

KS-test, PSI, Chi-square — сравниваем train vs prod

Evidently AI

Готовые отчёты по дрейфу данных и деградации модели

Prometheus + Grafana

Метрики в реальном времени: latency, prediction distribution, feature stats

Алертинг и автоответ

Почта/PagerDuty + Автозапуск retrain DAG в Airflow при превышении порога



Стек мониторинга дрейфа



Evidently AI:

Open-source инструмент для генерации отчётов о дрейфе данных. Интегрируется с Airflow.



Prometheus:

Сбор метрик inference-сервера: latency, throughput, prediction distribution через /metrics endpoint.



Grafana:

Визуализация метрик + настройка алертов. Dashboard: model performance over time.

Пример: реакция на дрейф в проде

1. Evidently фиксирует $PSI > \text{порога}$ → генерирует JSON-отчёт.
2. Срабатывает Grafana-алерт → приходит уведомление команде.
3. Airflow DAG автоматически запускает retrain с данными последних 30 дней.
4. После валидации — деплой модели на часть пользователей.

Кейс: сервис рекомендаций.
После праздников распределение товарных категорий резко изменилось. PSI (Population Stability Index) > 0.2




Вопросы



если есть вопросы



если вопросов нет



Блок 3: Практика. MLOps для RAG

RAG (Retrieval Augmented Generation) – это

архитектура LLM-систем, где ответ генерируется на основе релевантных документов, извлеченных из векторной базы

Задача: MLOps-пайплайн для RAG

Автоматически обновляет векторную базу при появлении новых документов

- У нас есть LLM-чат-бот на основе RAG. Список документов обновляется еженедельно на облачном хранилище (S3).

Проблема: когда добавляются новые документы, нужно пересчитать эмбединги и обновить векторную БД (*Chroma/FAISS/Qdrant*).

**Задача: спроектировать
схему MLOps-
пайплайна, который
делает это
автоматически**



**Что должно входить в
MLOps-пайплайн для RAG?**

Архитектура MLOps-пайплайна для RAG

Trigger:

Вариант 1: новый документ в S3 bucket.

Вариант 2: cron расписание.

Шаг 1: Airflow DAG запускает загрузчик документов.

Шаг 2: Chunking + Embedding (OpenAI / HuggingFace).

Шаг 3: Upsert в Chroma / Qdrant / FAISS.

Шаг 4: Smoke-test — поиск по 5 тестовым запросам.

Шаг 5: Версионирование снимка векторной базы.

Мониторинг: retrieval latency, hit rate, user feedback score

Расширенный мониторинг: Deereval-фреймворк с метриками precision, f1-score, recall, contextual precision/contextual recall



Псевдокод для DAG Airflow

```
1 dag = DAG("rag_update", schedule_interval="@daily", **kwargs)
2
3 ▾ def load_new_docs(**ctx):
4     ...
5
6 ▾ def chunk_and_embed(**ctx):
7     ...
8
9 ▾ def upsert_vector_db(**ctx):
10    ...
11
12 ▾ def smoke_test(**ctx):
13    ...
14
15 wait_for_new_files = S3KeySensor(
16     task_id="wait_for_new_files",
17     bucket_name="my-rag-bucket",
18     bucket_key="docs/pending/*",
19     dag=dag,
20 )
21
22 t_load = PythonOperator(task_id="load_new_docs", python_callable=load_new_docs, dag=dag)
23 t_embed = PythonOperator(task_id="chunk_and_embed", python_callable=chunk_and_embed, dag=dag)
24 t_upsert = PythonOperator(task_id="upsert_vector_db", python_callable=upsert_vector_db, dag=dag)
25 t_smoke = PythonOperator(task_id="smoke_test", python_callable=smoke_test, dag=dag)
26
27 wait_for_new_files >> t_load >> t_embed >> t_upsert >> t_smoke
```

Компонент 1: Источники данных

1. **Document Store (S3)** — место хранения исходных документов.
2. **Crawler / Loader** — автоматический сбор новых файлов (LangChain DocumentLoader).
3. **Preprocessor** — очистка текста, разбивка на chunks (512-1024 токена).
4. **Metadata tagger** — добавление source, date, version к каждому чанку.
5. **Change detector** — отслеживает новые/изменённые/удалённые документы.



Компонент 2: Эмбединги и векторная база

1. **Embedding модель:** text-embedding-3-small (OpenAI) или all-MiniLM (HuggingFace).
2. **Batch inference:** обрабатываем чанки пачками для экономии API-вызовов и уменьшения latency.
3. **Vector DB:** Qdrant / Weaviate с поддержкой upsert.
4. **Версионирование:** каждый rebuild — новая версия снимка базы с датой.
5. **Smoke test:** 5-10 тестовых запросов проверяют релевантность до переключения на новую версию данных.




Компонент 3: Мониторинг и автотриггеры

1. **Retrieval latency:** среднее и P99 время поиска в векторной базе.
2. **Hit rate:** доля запросов с similarity score > threshold (напр. 0.75).
3. **User feedback:** “лайк/дизлайк” от пользователей LLM-чат-бота.
4. **Auto-trigger:** при hit rate ниже 0.6 или при N+ новых документах → запуск DAG.
5. **Rollback:** при падении метрик делаем автоматический откат к предыдущей версии базы.



Архитектура



Вопросы



если есть вопросы



если вопросов нет

**Подведём
итоги занятия**

Теперь вы сможете:

Отправьте в чат номера достигнутых целей

1. Понимаю принципы MLOps

Чтобы знать зачем нужны MLOps-процессы в команде

2. Понимаю принципы построения ML-пайплайнов, учитывая model drift

Чтобы внедрять лучшие практики в свои процессы

3. Проектировать MLOps-пайплайны

Чтобы иметь опыт проектирования MLOps



Ключевые тезисы занятия

1. MLOps **не заменяет** DevOps – это соседняя дисциплина. Без governance, мониторинга, feature store, CI/CD стек будет неполный.
2. В любом AI проекте необходимо учитывать риски **model drift** на этапе проектирования и иметь понимание их отработки.
3. Минимальный MLOps стек – real-time мониторинг модели, контроль версий модели/данных, настроенные политики обновления версий.





**Отправьте в чат эмодзи, который
отражает ваше настроение
после занятия**




**Продолжите высказывание: теперь
я умею/знаю...**



**Что планируете использовать
в работе?**

Полезные материалы:

1. <https://airflow.apache.org> - Apache Airflow
2. <https://mlflow.org> - ML Flow
3. <https://www.kubeflow.org> - Kubeflow
4. <https://habr.com/ru/companies/otus/articles/773320/> - статья про MLOps
5. <https://habr.com/ru/articles/908216/> - статья о выборе MLOps процессов
6. <https://github.com/GokuMohandas/mlops-course> - open-source курс по MLOps (на английском)
7. <https://ml-ops.org/> - сайт с материалами по MLOps



Заполните, пожалуйста, опрос о занятии

Мы читаем все ваши сообщения
и берем их в работу 🖋️❤️

OTUS

