

# Архитектура для High-Load и Low-Latency инференса

AI Архитектор



Проверить, идет ли запись

# Меня хорошо видно & слышно?





## Лавров Денис

Старший архитектор @MTS AI

- 17 лет в ИТ
- занимался архитектурой инструментов модельного инференса в Сбере
- распиливал монолиты на микросервисы
- строил аналитические хранилища и средства визуализации отчетности
- преподаватель курсов «Инфраструктурная платформа на основе Kubernetes», «Микросервисная архитектура» и «SoftwareArchitect» в ОТУС



@roflmaoinmysoul

# Правила вебинара



Активно  
участвуем



Off-topic обсуждаем  
в учебной группе **#канал  
группы**



Задаем вопрос  
в чат или голосом



Вопросы вижу в чате,  
могу ответить не сразу

# Маршрут вебинара

Знакомство

Highload

Специфика highload для AI

Edge вычисления

Практическое задание

Основные тезисы



# Цели вебинара

К концу занятия вы сможете

1. Что такое Highload

2. Какие архитектурные паттерны можно применить для достижения low latency

3. Когда может помочь Edge computing

# Смысл

Для чего вам это уметь

Проектировать высоконагруженные AI системы с высокими требованиями к latency



# Highload

---

# Highload – это

комбинация НФТ к системе, при которых приходится применять различные сложные и компромиссные архитектурные решения в части достижения требуемой производительности, масштабируемости и отказоустойчивости





# Основные паттерны

- Горизонтальное масштабирование / репликация
- Кэширование
- Балансировка нагрузки
- Шардирование и партиционирование
- Асинхронность и параллелизм
- Геораспределенность и CDN



# Специфика паттернов для AI

---

# Балансировка нагрузки

- Инстансы моделей чаще всего не являются в полной мере "stateless»
- Необходимость батчевания поступающих запросов
- Запросы часто очень сильно отличаются по сложности друг от друга
- Принципиально разные требования для Prefill и Decode фаз у LLM
- Зачастую требуется использование специфичных балансировщиков или написание своих для достижения максимальной производительности



# Автомасштабирование

- Старт нового инстанса модели занимает значительно больше времени, чем для обычного прикладного сервиса
- Модель после старта зачастую необходимо «прогреть», либо первые запросы будут обрабатываться очень медленно
- Редкие сценарии, когда доступно простаивающее оборудование с GPU




# Кэширование

- Сложное определение индекса для кэша, при котором cache hit rate будет приемлемым
- Часто размер кэша превышает традиционный
- Часто нетривиальные алгоритмы прогрева кэша или отказ от прогрева вовсе
- Специфичные виды кэша (KV кэш) и необходимость доставки его в память GPU требуют глубокой интеграции с движком инференса и специальных инструментов



# Semantic cache




# Semantic cache. Что нужно учитывать

- Дополнительные накладные расходы на эмбеддер
- Если все запросы пользователей уникальны, эффект будет отрицательным
- Сложный и долгий прогрев кэша
- Безопасность при наличии в ответах модели персональной информации
- Возможность отдачи пользователю нерелевантных ответов из за ошибок семантического поиска



# Использование KV cache





# Использование KV cache (prefix cache)


- Используется при генерации токенов в рамках одного запроса
- Может использоваться внешнее хранилище кэша для его использования между различными похожими запросами
- Дает существенный прирост при больших запросах, у которых повторяется системный промпт и контекст
- Возможна распределенная реализация для использования несколькими инстансами



# Edge AI

---

# Архитектура Edge computing



# Плюсы Edge вычислений

- Значительное снижение нагрузки на серверную инфраструктуру
- Меньшее время ответа системы пользователю
- Уменьшение передаваемого по сети трафика
- Более простая и надежная работа с конфиденциальными данными
- Автономность и возможность работать без связи с сервером



# Минусы Edge вычислений

- Ограниченная вычислительная мощность edge устройств
- Качество генерации / предсказаний моделями на edge может быть ниже
- Ограниченный выбор совместимых устройств
- Сложность доставки обновлений / дообучения
- Стоимость edge устройств может превышать стоимость апгрейда серверного оборудования



# Типовые сценарии применения

- Умные колонки и голосовые ассистенты
- Системы автопилота и умного круиз-контроля в автомобилях
- Системы видеонаблюдения
- IoT и системы умного дома
- Носимые медицинские устройства



# Аппаратные платформы

- **Nvidia Jetson** – пионер и лидер рынка
- **x86 (intel, amd)** – второй самый крупный игрок на рынке serverless
- **RockChip** – глубокая интеграция в инструменты Google
- **Yandex Cloud Functions** – отечественное решение, пока не имеет поддержки GPU для serverless вычислений
- **Knative** - on-prem решение, устанавливающееся в кластер K8s и позволяющее реализовать serverless подход на базе кластера
- **OpenFaaS, KEDA, Fission, KubeElasti ...**



# Пример архитектуры

---




# Требования к системе

- Синтез речи в потоковом режиме
- Минимальное время от момента поступления запроса на синтез, до отправки первого чанка аудио
- Большое количество однотипных запросов на синтез, но с разными параметрами синтезируемого голоса
- Неравномерная нагрузка на систему и необходимость масштабироваться в пиковые моменты



# Высокоуровневая архитектура



# Основные проблемные места

- Нарезка текста на фрагменты должна учитывать много факторов – быть пригодной для кэша, не терять семантический смысл фраз, не превышать размер контекста модели синтеза
- Синтез всего аудио должен производиться на одном экземпляре модели
- Максимальная оптимизация доставки эмбедингов голосов в модель синтеза и прогрев их кэша
- Частота попадания в кэш аудио очень зависит от алгоритма нарезки
- Большой размер кэша синтезированного аудио



# Вопросы



если есть вопросы



если вопросов нет

---

**Подведём  
итоги занятия**

---

# Теперь вы сможете

1. Что такое Highload

2. Какие архитектурные паттерны можно  
применить для достижения low latency

3. Когда может помочь Edge computing

Проектировать высоконагруженные AI  
системы с высокими требованиями к  
latency



# Заполните, пожалуйста, опрос о занятии

---

Мы читаем все ваши сообщения  
и берем их в работу 🖋️❤️

OTUS

