

Гибридная и мультиоблачная архитектура для AI

AI Архитектор

 REC

Проверить, идет ли запись

Меня хорошо видно
&
слышно?





Андрей Носов

Ведущий AI-архитектор, Рафт

- 13 лет в разработке решений на основе NLP и GenAI
- PhD Communication Sciences, Tampere University
- Руководитель школы AI-архитекторов OTUS

 @parallelnominded

 andrey.nosoff@gmail.com



Правила вебинара



Активно
участвуем




Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Правила вебинара




Off-topic обсуждаем
в закрытом чате в Telegram

Кто еще не присоединился,
сканируйте QR код :)



Блок 1: Стратегия и Экономика (Почему гибрид?)

On-Premise Servers
Локальные мощности



Cloud Instances
Облачные инстансы

Прагматичный путь к AI-суверенитету: Гибридная и мультиоблачная архитектура

Реальность R&D (Прошлые)

- Бесконтрольные затраты на облачные API (SaaS) 
- Нулевая предсказуемость бюджетов (TCO) 
- Риски утечки ПДн (нарушения 152-ФЗ и КИИ) 

Индустриальный стандарт 2026 (Настоящее)

- Оптимизация Time-to-Market (TTM) 
- Строгая юнит-экономика 
- Внедрение открытых моделей (Qwen-3.5, Gemma-4) 

Blueprint Архитектуры (Будущее)

- Гибридный контур без привязки к вендору (Zero Vendor-Lock) 
- CapEx для базовой нагрузки (локальные мощности) 
- OpEx для эластичности (YandexGPT 5 Pro / Cloud.ru) 

Аппаратный профиль: VRAM диктует правила масштабирования



Бенчмарк: Типовая RAG-система, 1000 токенов на 1 запрос.

Оплата по API (Pay-as-you-go)

- ~0.3 руб. за 1000 токенов = ~3 млн руб. / год.
- Безоговорочный лидер для проверки гипотез и запуска MVP. Time-to-Market: 2 дня.

Аренда GPU VM (Облако)


- ~900 тыс. руб. / мес. = 10.5 млн руб. / год (OpEx).
- Железо простаивает 90% времени.

Свой кластер L40S (On-premise)

- ~12 млн руб. (CapEx) + 800 тыс. руб. (поддержка) = 13.4 млн руб. / год.
- Худший выбор для старта.

Аппаратный профиль и Экономика: VRAM диктует правила

TCO Matrix – 50 million requests/year workload




Скрытые финансовые мультипликаторы

- Паттерн RAG: x1.3 расхода токенов (из-за внутренних ретраев)
- ReAct Агенты: x3 расхода токенов (циклы Thought/Action)

Вывод: On-Premise является единственным устойчивым сценарием для базовой нагрузки.

Узкое горлышко архитектуры MoE — объем и пропускная способность VRAM, а не TFLOPS.

Инфлексия масштабирования: Трехлетний TCO на 50 млн запросов



Эффект масштаба

При выходе на продуктивное плато (50 млн запросов) оплата по API становится финансовой черной дырой, вытягивая 15 млн руб. ежегодно.

Амортизация On-premise


Локальная инфраструктура достигает паритета стоимости с облачными API в течение 3-4 лет. На дистанции 5-7 лет экономия достигает 30-50%.

Инфраструктурный Императив


Стабильная продуктовая нагрузка требует капитализации. Локальный инференс — единственный способ удержать юнит-экономику под контролем.

Блок 2: Инфраструктурный фундамент (Оркестрация)


Паттерн Split MLOps: Гибрид как золотая середина




Фундамент инфраструктуры: Deckhouse, Karmada и Kueue




Фундамент инфраструктуры: Deckhouse, Karmada и Kueue



Фундамент инфраструктуры: Deckhouse, Karmada и Kueue



Платформенный фундамент: Deckhouse Kubernetes Platform



Управление парком

Развертывание и управление разнородными GPU-нодами требует надежного энтерпрайз-оркестратора.

Скорость

Deckhouse EE сокращает время подготовки изолированной среды разработки в 15 раз.

Эффективность (Day 2)

Автоматизирует до 80% ручных операций по эксплуатации и мониторингу ML-контуров.

Надежность

Встроенные технологии высокой доступности (HA) обеспечивают SLA инфраструктуры до 99.99%.

Блок 3: Управление данными и обучение (Data & MLOps)

Управление данными и Платформа MLOps: Преодоление Data Gravity

ЦОД (On-Premise)

Массивные терабайтные датасеты и Исходный код



S3 (MinIO)



Платформа ClearML

- ClearML: On-Premise трекинг экспериментов.
- Отказ от SaaS ради комплаенса 152-ФЗ.
- Автоматическая Docker-упаковка.

Облако (Cloud)

`dvc push --remote cloud`

Передача исключительно измененных файлов (Diffs).
Радикальная экономия сетевого трафика.




Облачный S3 Бакет

Сквозная воспроизводимость: Полная интеграция пайплайнов с очередями Кueue и отказ от парадигмы «на моем ноутбуке работало».


Распределенное обучение и CI/CD: От матриц к релизу

Обучение: Kubeflow DDP



- Kubeflow Training Operator (CRD: PyTorchJob)
- Координация Master и Worker узлов
- Интеграция планировщика (schedulerName: kueue)
- Авто-перезапуск с последнего чекпоинта при сбоях

Релиз: CI/CD Pipeline (TTM = 5 минут)




- Триггер запуска из ClearML
- Односторонняя репликация только файлов .safetensors в Облако
- ArgoCD применяет манифесты
- ArgoCD применяет манифесты к Managed K8s (GitOps)
- Мгновенный rollback одной кнопкой при деградации метрик

Сквозная воспроизводимость: Полная интеграция пайплайнов с очередями Kueue и отказ от парадигмы «на моем ноутбуке работало».

Блок 4: Высокопроизводительный инференс (Serving)

Эластичное расширение: Управляемые сервисы Cloud.ru



Гибридная стратегия

Хранение чувствительных ПДн и базовый инференс остаются в частном контуре. Обучение моделей и пиковые нагрузки эластично уходят в публичное облако.

Эффективность Shared GPU

Технология разделения vRAM повышает утилизацию мощностей в облаке на 15-45% в сравнении с классической арендой выделенного GPU.

Pay-as-you-go и Scale-to-zero

Тарификация начинается только в момент фактического обращения к модели, позволяя масштабироваться до нуля во время простоя инфраструктуры.

Оркестрация инференса: KServe и паттерн Scale-to-Zero

FinOps Правило №1: GPU тарифицируется только в момент активной генерации токенов.



- **Serverless Архитектура:** KServe поверх Knative.
- **Оптимизация Cold Start:** Интеграция JuiceFS кэширования сокращает загрузку весов с минут до секунд.
- **Safe Canary Deployments:** Маршрутизация через Istio (бесшовный A/B тест новых моделей на 5% трафика).

Программный слой: Ускорение инференса (KServe & vLLM)

■ Единый API-шлюз KServe


Предоставляет OpenAI-совместимые эндпоинты для бесшовной интеграции с корпоративными приложениями на проде.

■ Continuous Batching

Динамическое объединение входящих запросов в батчи для максимизации общей пропускной способности системы.


PagedAttention

Стандартная фрагментация KV Cache



Стандартная фрагментация KV Cache

Оптимизация PagedAttention (vLLM)



Оптимизация PagedAttention (vLLM)

■ vLLM Runtime

Ключевой движок оптимизации, позволяющий локальным сборкам конкурировать по throughput с облачными A100.

■ KV Cache Offloading

Умная разгрузка кэша для обработки экстремально длинных контекстов в RAG-системах при нехватке VRAM.


Движок генерации: vLLM и Speculative Decoding

Классическая авторегрессия



Медленная, последовательная генерация по одному токенту

Speculative Decoding (vLLM)




Результат: Одобренный блок токенов

Бизнес-результат: Увеличение Tokens Per Second (TPS) в 2.2 раза.

Фундамент vLLM: Paged Attention (управление K-V кэшем как виртуальной памятью) и Continuous Batching. Обслуживание 50 млн запросов на вдвое меньшем парке серверов (CapEx).

Продвинутые паттерны: Сплит-Контекст RAG

Проблема: Запрет на размещение корпоративных векторных индексов в публичном облаке.




Облако выступает исключительно как «лингвистический калькулятор». Векторы и знания остаются в ЦОД.

Блок 5: Надежность, безопасность и агенты

Информационная безопасность: COMPLIANCE 152-FZ и защита КИИ

Цель: Защита от атак инверсии модели (Model Inversion).



IAM, RBAC и Защита цепочки поставок (Supply Chain)

Контроль доступов (Federated Identity)



Единый RBAC поверх инфраструктурного зоопарка. Использование короткоживущих STS-токенов для S3 (валидность 1 час) вместо статических паролей.

Защита от Model Poisoning



.safetensors

Утилита Cosign ставит цифровую подпись на хэш .safetensors.




Kyverno
(Admission Controller)
развернут в K8s.



Кувэрно аппаратно блокирует запуск пода в KServe, если файл изменен хотя бы на 1 байт.


Автономные AI-Агенты и Stateful Инференс

Проблема: Внутренние циклы агентов (LangGraph/AutoGen) быстро сжигают облачные бюджеты.



Экономия совокупной стоимости владения (ТСО) на 85%.

Угрозы AI Supply Chain: Уроки инцидента LiteLLM



Разбор инцидента


- **Кейс LiteLLM:** Подмена пакетов популярного шлюза (более 480 млн скачиваний).
- Malicious code внедрен минуя проверки публичного Git-репозитория.
- Трехэтапный бэкдор: исполнение при запуске Python, кража ключей, латеральное движение (Lateral movement) внутри кластера.

Вывод для Архитектора

Использование AI-моделей с чувствительными ПДн требует жестко изолированного частного on-premise контура. Прямой доступ production-серверов в интернет и загрузка пакетов без проверки Supply Chain недопустимы.

Защита от Vendor-lock: API Gateway (LiteLLM)

Абстракция L7: Полный запрет на хардкод vendor SDK в бизнес-логике корпоративных приложений.




Обеспечение непрерывности бизнеса и независимости от провайдера.


Блок 6: Эксплуатация (Day 2 Operations)

Observability и AI FinOps: Управление Зоопарком GPU


Аппаратный и финансовый аудит



Снижение TCO при Enterprise-подходе



Инженерный Blueprint: Гибридная ИИ-архитектура



Master Blueprint гибридной архитектуры и Источники

The Hybrid AI Stack

Routing (LiteLLM API Gateway)

Inference Engine (vLLM / KServe)

Data & MLOps (S3 / DVC / ClearML)

Orchestration & Batch (Karmada / Kueue)

Infrastructure (Deckhouse K8s)

Hardware (RTX 4090 / L40S on-prem & L4 Cloud)

Бизнес-итоги: Паттерн Split MLOps

- Zero Vendor-Lock
- Гарантированный комплаенс 152-ФЗ
- Радикальное снижение TTM и TCO

Список литературы:

- The LiteLLM Supply Chain Poisoning Incident — A Full-Link Analysis (CloudSecurity, 2026).
- Batch Scheduling on Kubernetes: Comparing Apache YuniKorn, Volcano.sh, and Kueue.
- Исследование Cloud.ru «Гибрид здорового человека» (2026).
- Исследование Cloud.ru «Гибрид здорового человека» (2026).
- Исследование Cloud.ru «Гибрид здорового человека» (2026).
- ТСО для СТО: Экосистема Deckhouse Kubernetes Platform.
- (Препринт) arXiv:2509.02596 (Оптимизация гибридных ИИ-архитектур).

Вопросы?
