

Ethical AI by Design и архитектура для Governance

AI-Архитектор



Проверить, идет ли запись

Меня хорошо видно & слышно?





Иван Четвериков

AI Architect

- Более 5 лет опыта в разработке и архитектуре
- Специалист в разработке и проектировании AI-приложений в Raft

 @istrebitel_1

 istrebitel.3.12@gmail.com

Правила вебинара



Активно
участвуем



Off-topic обсуждаем
в учебной группе



Задаем вопрос
в чат или голосом



Вопросы вижу в чате,
могу ответить не сразу

Карта курса



СТАРТ

Стратегический фундамент и планирование проекта

Проектирование и документирование

Инфраструктура

Продвинутые архитектурные паттерны

Качество, интеграции безопасность

Стратегия, лидерство и экономика

Проектная работа

ФИНИШ



Маршрут вебинара

Знакомство

Принципы Responsible AI

Архитектура для Governance

Создание Model card

Итоги и ДЗ

Q&A

Цели вебинара

К концу занятия вы сможете

1. Встраивать принципы Responsible AI в архитектуру

2. Проектировать механизмы Governance для моделей и данных

3. Создавать Model Card и системы логирования для аудита



Смысл

Это нужно уметь чтобы:

1. Выстраивать юридическую защиту, 152-ФЗ, избегать репутационных рисков

2. Понимать, как выстраивать процесс верно с самого начала разработки, а не после

3. Знать, как работает модель, исключить “черный ящик” из архитектуры



**Встречали ли вы AI-системы,
принимающие несправедливые
или непрозрачные решения?**



Возможные последствия отказа от Responsible AI

Утечки персональных данных → штрафы и блокировки

Суды → признание решений незаконными

Дискриминация от модели → репутационные потери



Регуляторный ландшафт в РФ

* <https://swordfish-security.ru/articles/regulirovanie-ii-obzor>

152-ФЗ

ФСТЭК № 117

ГОСТ Р
59276-2020

Приказ
Росздравнадзора №
4472 от 21.07.2025

Принципы Responsible AI

Responsible AI — это

подход, при котором прозрачность, справедливость и подотчетность встроены в архитектуру с самого начала, а не добавлены после основной фазы разработки

Принципы Responsible AI



Прозрачность

Пользователи и аудиторы должны понимать, как AI принимает решения. Объяснимые модели, документация



Справедливость

Модель не должна дискриминировать по признаку пола, расы, возраста. Метрики fairness: равная точность по группам.



Подотчетность

За каждое AI-решение должен быть ответственный. Логи, аудит, механизмы обжалования.

Прозрачность (Transparency)

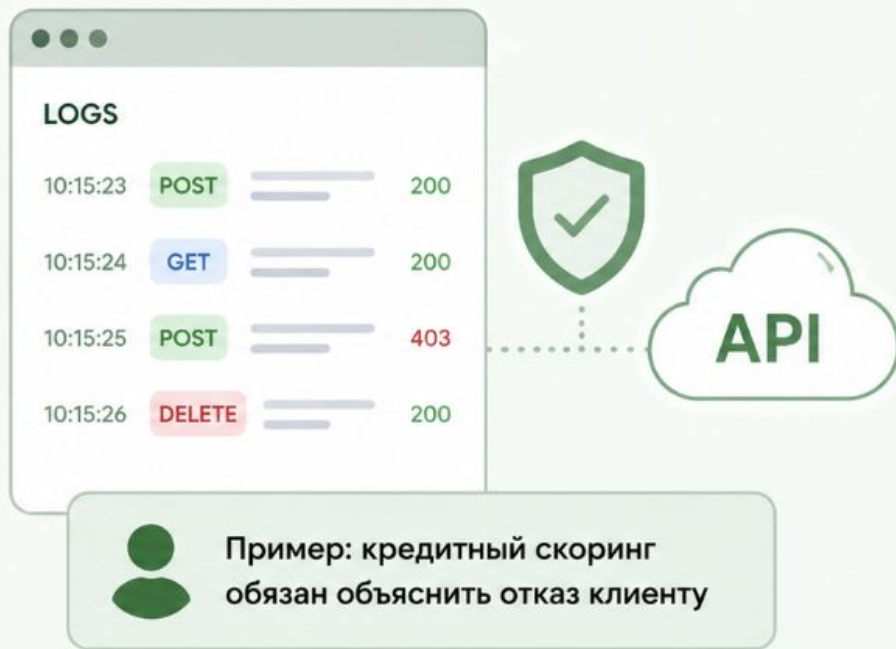
Как AI объясняет свои решения?

- **Explainability:**
SHAP (**SH**apley **A**dditive **ex**Planations) – это метод, который объясняет прогноз модели, показывая вклад каждого признака (фактора) в итоговое решение
LIME (**L**ocal **I**nterpretable **M**odel-agnostic **E**xplanations) – объясняет, почему модель приняла конкретное решение для одного конкретного примера
- **Model Cards:** документация о назначении, ограничениях, данных модели – “Паспорт”

MODEL CARDS & EXPLAINABILITY



LOGS & API AUDIT



- **Логи решений:** каждое AI-решение записывается с контекстом
- **API аудита:** внешние аудиторы могут запросить объяснение любого решения

Справедливость (Fairness)

Как AI может быть “справедливым” без понимания морали

- **Demographic parity:** одинаковый процент одобрений по группам
- **Equalized odds:** уравненные шансы, одинаковый recall и TPR/FPR по группам
- **Bias analysis:** анализ данных обучения на дисбалансы (“предвзятости”)
- **Fairness constraints:** конкретные правила, встроенные в процесс разработки модели

Пример: алгоритм найма должен приглашать на интервью 50/50 мужчин и женщин



Как встроить Fairness в пайплайн

1. До обучения

- Oversampling/Reweighting групп с недостаточным кол-вом данных

2. Во время обучения

- Fairness penalty в функции потерь (напр, “штраф” в MSE)
- Adversarial debiasing (снижение нежелательных смещений)

3. После обучения

- Корректировка threshold по группам: группа А — порог 0.5, группа В — порог 0.45




Подотчетность (Accountability)

Кто отвечает за решения AI?

- **Ownership matrix:** у каждой модели – владелец (напр., ML-инженер + бизнес)
- **Decision log:** полная трассировка каждого AI-решения (напр., langfuse/phoenix)
- **Appeal mechanism:** процесс обжалования решений AI (UI)
- **Governance board:** комитет по этике AI в организации

Пример: медицинская AI –
ответственность врача, не алгоритма



AI в найме сотрудников

LinkedIn добавили fairness constraints прямо в функцию ранжирования. Метрика успеха включала не только click-through, но и демографическое разнообразие результатов. Результат: разнообразие групп выросло, качество не упало

В 2018 Amazon закрыл проект* AI-рекрутинга. Модель обучили на 10 годах найма, где большинство принятых были мужчины.

Таким образом, алгоритм начал отбраковывать заявки со словом "женщины". Программу отредактировали, но это не очень помогло.

Наглядный пример data bias, перенесенный в архитектуру.

* <https://www.bbc.com/russian/other-news-45814099>

AI Lifecycle: где встраивать этику

Data Collection

Проверка на ПДн, согласие на обработку, аудит предвзятости датасета

Model Design

Выбор типа модели с учетом понятности решений

Training

Ограничения “справедливости”, сбалансированные батчи тренинга

Evaluation

Метрики справедливости по группам, не только ассурасу

Deployment

Model Card описаны, назначены ответственные, возможно обжалование

Monitoring

Drift detection, периодический аудит предвзятости

Вопросы



если есть вопросы



если вопросов нет

Архитектура для Governance

Governance – это

система правил, процессов и инструментов,
которая обеспечивает:

- **Видимость:** кто, когда и почему принял каждое AI-решение
- **Контроль:** возможность остановить, откатить или изменить модель
- **Подотчетность:** конкретный человек отвечает за каждую модель в продакшене
- **Аудируемость:** внешний аудитор может проверить любое решение за последние N лет



4 уровня Governance-архитектуры

1. Data Layer

Версионирование данных (DVC), data lineage (OpenLineage), Контроль ПДн (152-ФЗ)

2. Model Layer

Model Card, MLflow для версионирования модели, метаданные (кто обучил, когда, на каких данных)

3. Decision Layer

Каждое решение AI логируется с контекстом – например, *timestamp, user_id, input features, prediction, model version*

4. Audit Layer

Хранилище логов, инструменты ретроспективного анализа, compliance-отчёты



Архитектура Decision Audit Log



Пришёл запрос. Мы сохраняем: `user_id`, `timestamp`, `session context`. Важно не сохранять персональные данные в чистом виде – только хэш или ID

Какие признаки были использованы для предсказания и с какими значениями, т.к. это критично для отладки. Если через год клиент оспорит решение, мы должны воспроизвести, что видела модель.

`prediction` (класс или скор), `confidence`, `model_version` (не "production", а конкретный git hash или MLflow `run_id`)

S3 с версионированием, BigQuery. TTL – по требованию к комплаенсу. Это может быть дорого, потому нужна стратегия, какие решения логировать полностью, а какие только агрегированно.

FinOps в контексте AI Governance


Источник затрат	Типичная ошибка	FinOps-решение
Decision Log без TTL	Логи растут бесконечно	Retention policy: hot / cold / delete
GPU-инстансы в dev	Не выключаются ночью и в выходные	Auto-shutdown + Spot Instances для batch
Большая модель для простых задач	Большая модель там, где достаточно маленькой	Model routing по сложности запроса
Полный лог всех inference	Логируем всё одинаково	Стратификация: High-Risk → полный лог; Low-Risk → агрегаты
Хранение сырых фич в Audit Store	Дублирование данных	Feature hashing + ссылка на Feature Store



Готова ли ваша AI-система к деплою?

Data Layer


- Датасет версионирован (DVC или аналог)
- Data Sheet заполнен (источник, разметка, bias)
- ПДн обработаны согласно 152-ФЗ



Готова ли ваша AI-система к деплою?

Model Layer

- Модель зарегистрирована в Model Registry
- Model Card заполнена и подписана (ML Owner + Business Owner)
- Risk level определён (High / Limited / Minimal)



Готова ли ваша AI-система к деплою?

Decision Layer


- Decision Log включен: request_hash, features, prediction, model_version
- ID клиентов — только хэши, без ПДн
- Retention policy задана



Готова ли ваша AI-система к деплою?

Audit Layer

- Audit Store immutable (append-only)
- Appeal mechanism описан с SLA
- Monitoring: drift detection включён



Вопросы



если есть вопросы



если вопросов нет

Создание Model card

Структура Model Card

Концепция была представлена исследователями Google в 2018-2019 годах, сейчас это стандарт на HuggingFace – у каждой публичной модели обязательно есть Model Card.

<https://huggingface.co/docs/hub/model-cards>

	Model Card by Hugging Face
	Model Details Model name, version, authors, license, etc.
	Intended Use Use cases, out-of-scope uses, users
	Training Data Datasets, data collection, preprocessing
	Evaluation Metrics, results, benchmarks, limitations
	Ethics & Bias Bias analysis, fairness, mitigations
	Limitations Known limitations, failure modes, risks
	Technical Details Architecture, parameters, training procedure
	Release Notes Changes, version history

Структура Model Card

Intended Use

Назначение модели, ограничения,
применения

Training Data

Источник данных, разметка,
выявленные смещения

Evaluation Results

Метрики качества

Ethical Considerations

Риски, рекомендации,
owner и контакт

Заполнение Model Card

Intended Use & Limitations

- Конкретная задача
 - Конкретная аудитория
 - Конкретный контекст
 - Конкретный регион/юрисдикция
-
- Сценарии вне scope
 - Граничные случаи
 - Обязательные ограничения
 - Технические ограничения



Заполнение Model Card

Intended Use & Limitations - Модель “Кредитный скоринг”

Модель предназначена для оценки кредитного риска физических лиц 18–70 лет при оформлении потребительских кредитов до 100 тыс. руб. в российских банках-партнёрах. Используется как один из факторов в процессе кредитного решения.

- Не использовать для ипотечных решений (другой риск-профиль, не представлен в обучающих данных)
- Не применять для клиентов без кредитной истории
- Не использовать как единственный критерий отказа при score в диапазоне 0.45 - 0.55
- Не распространяется на юрисдикции за пределами РФ



Заполнение Model Card

Training Data & Bias Analysis

- Источник данных
 - Период сбора данных
 - Объем данных
 - Разметка, её правила
 - Предобработка
 - Разделение train/test + метод
-
- Группы с недостаточным кол-вом данных
 - Временной сдвиг: данные до / после значимых событий
 - Сознательно исключенные признаки
 - Известные источники bias: что не можем измерить



Заполнение Model Card

Training Data & Bias Analysis - Модель “Кредитный скоринг”

- Источник – внутренняя история кредитов организации за 2020 - 2025 гг., ~2М записей, 10 признаков
- Разметка. дефолт = просрочка 90+ дней
- Предобработка. исключены клиенты с < 3 кредитами (cold-start), выбросы по доходу > 99-й перцентиль
- Разделение. 80/20, разделение по категориям граждан
- Клиенты 18–25 лет занимают 3% выборки
- Регионы за пределами городов-миллионников - 10%
- Признак «работодатель» исключен



Заполнение Model Card

Evaluation Results

Метрика	Значение	Примечание
ROC-AUC	0.81	—
Precision@top10%	0.74	—
F1 (threshold 0.50)	0.70	Precision 0.72, Recall 0.68



Заполнение Model Card

Ethical Considerations

⚠

Выявленные риски

Риск	Серьёзность	План митигации
Систематически хуже для клиентов 18–25	Высокая	Отдельный мониторинг recall по группе; review при падении > 5%
Недопредставленность регионов	Средняя	Не рекомендуется для новых регионов без re-evaluation
Correlation признаков	Низкая (признак исключён)	Мониторинг при добавлении новых признаков

👤

Контакты:

ML Owner:

Business Owner:

📄

Механизм обжалования:

Основание:

152-ФЗ

Процесс:

Запрос клиента → логирование ticket → ручная проверка → решение → уведомление

SLA:

30 календарных дней

Контакт:

Документация:



Домашнее задание

Д3: FinOps и Governance: управление стоимостью и этикой AI

1. Model Card для вашей системы
2. FinOps-анализ – найти причины перерасхода.
Plan Cost Optimization (Spot, Distillation, TTL)
3. Результат – документ Model Card + FinOps-отчёт




06.05

рекомендуемый срок
сдачи



Материалы к ДЗ

1. Шаблон Model Card 1: huggingface.co/docs/hub/model-cards
2. Шаблон Model Card 2: arxiv.org/abs/1810.03993
3. FinOps Framework: finops.org/framework



**Подведём
итоги занятия**

Ключевые тезисы занятия

1. Responsible AI = **Прозрачность + Справедливость + Подотчетность**, встроенные в архитектуру
2. Каждое AI-решение должно быть объяснимым
3. За каждое решение ИИ должен быть назначен ответственный (человек/алгоритм, способный объяснить решение)
4. Model Card обновляется при каждом переобучении
5. Decision Log = 4 поля: request, features, prediction, model_version
6. Governance – архитектурный слой



**Оцените каждое утверждение от 1 до 5,
где 1 = плохо, 5 = очень хорошо**

- A.** Я могу объяснить разницу между Transparency, Fairness и Accountability на конкретном примере [из своего проекта]
- Б.** Я понимаю структуру Model Card и могу заполнить все разделы для своей системы
- В.** Я понимаю механизмы Governance для моделей и данных



Отправьте в чат эмодзи, который отражает ваше настроение после занятия



Продолжите высказывание: теперь я умею/знаю...



Что планируете использовать в работе?

Полезные материалы:

1. https://unicri.org/sites/default/files/2024-02/02_Principles_Resp_AI_Innovation_Feb24.pdf
2. <https://www.sciencedirect.com/science/article/pii/S0963868724000672>
3. <https://huggingface.co/docs/hub/model-cards>



Заполните, пожалуйста, опрос о занятии

Мы читаем все ваши сообщения
и берем их в работу 🖋️❤️

OTUS

