

Содержание

ДЗ-30 · FinOps и Governance: управление стоимостью и этикой AI	1
0. Фиксация допущений	1
ЧАСТЬ 1. GOVERNANCE — Model Card	3
1.1. Model Details	3
1.2. Intended Use & Limitations	4
1.3. Training Data & Bias Analysis	6
1.4. Метрики справедливости (Fairness)	10
1.5. Evaluation Results	13
1.6. Ethical Considerations	15
ЧАСТЬ 2. FINOPS — анализ перерасхода и план оптимизации	18
2.1. Ситуация: счёт вспомогательного контура	18
2.2. Причины: три утечки и одна незапланированная работа	19
2.3. План Cost Optimization	19
2.4. Баланс цены и качества: что мы сознательно НЕ режем	21
2.5. On-premise: где у нас на самом деле находится FinOps	21
2.6. Sensitivity: что будет при росте нагрузки x3	22
Условие из ЛК	22
Артефакты	23
Сложности и решения	23
Обратная связь от преподавателя	24

ДЗ-30 · FinOps и Governance: управление стоимостью и этикой AI

Студент: Александр Зубик · **Курс:** AI Architect (OTUS) · **Капстоун блока 6** (уроки 28 «FinOps» + 30 «Ethical AI by Design»)

Объект — сквозной для всех моих работ корпоративный RAG-ассистент «Суфлёр» (ДЗ-20, ДЗ-24, финальный проект): подсказки оператору контакт-центра и ответы по локальным правовым актам (ЛПА) с цитатами. Стек: Qwen3.8-27B (FP8, Apache 2.0, релиз 05.08.2026) за vLLM + Qdrant + hybrid retrieval с реранкингом, on-premise на 2x H100 NVL, air-gapped. Работу со сканами и фотографиями документов обслуживает **собственная дообученная модель Zubr-VL-32B** — QLoRA-адаптер поверх Qwen/Qwen3-VL-32B-Instruct, обученный нами на корпусе права РБ.

Почему в системе две модели. Qwen3.8-27B — свежайшее поколение с сильной агентностью и нативным vision, но «из коробки» она не знает ни правового поля РБ, ни идентичности платформы. Zubr-VL-32B — наоборот, доучена ровно под это. До подтверждения RU-eval на новой базе разделение такое: **генерация ответов по ЛПА** — Qwen3.8-27B, **распознавание и разбор сканов документов** — Zubr-VL-32B; перенос QLoRA на Qwen3.8-27B зафиксирован как upgrade-path.

0. Фиксация допущений

Обе части задания в лоб к нашей системе не применяются, поэтому — три допущения, зафиксированные до начала работы.

Допущение 1. В системе есть и чужие веса, и наше дообучение — карточка трёх-уровневая. Qwen3.8-27B мы берём как есть (Apache 2.0), а Zubr-VL-32B обучили сами

(QLoRA). Классическая Model Card описывает *одну обученную модель*; у нас же предвзятость возникает на трёх разных уровнях, и смешивать их в одном разделе — значит потерять смысл анализа:

Уровень	Что это	Наш контроль
A. Upstream-веса	Qwen3.8-27B, состав обучающих данных вендором не раскрыт	нет — только компенсация архитектурой
B. Наше дообучение	QLoRA-адаптер Zabr-VL-32B: датасет, гиперпараметры, состав смеси известны полностью	полный
C. Корпус ретрива	база ЛПА организации, чанкинг, RBAC-метки	полный

Это не обход требования, а следование его смыслу: **основной измеримый источник bias у нас — уровни B и C**, и именно они разобраны детально.

Допущение 2. Юрисдикция — Республика Беларусь. Опорный закон — № 99-З «О защите персональных данных», а не 152-ФЗ; там, где в лекции стоят ФСТЭК/Росздравнадзор, у нас действуют белорусские ТНПА. Механика (согласие, минимизация, право на обжалование) совпадает.

Допущение 3. Облачного счёта в привычном виде у нас нет. Продуктовый контур on-premise и air-gapped, счёт от провайдера физически не приходит. Поэтому часть 2 сделана на **двух горизонтах**:

- **A. Гибридный вспомогательный контур в Yandex Cloud** — dev/eval-площадка (замеры RAGAS, эксперименты, staging), которая реально тарифицируется. Здесь и разбирается сценарий «счёт превысил бюджет на 50 %»; цифры — модельные, порядок величин взят из наших реальных конфигураций.
- **B. On-premise продуктовый контур** — где счёта нет, но есть **удельная стоимость токена**, и она полностью определяется утилизацией железа.

Разделение принципиально: без него FinOps-часть выродилась бы в пересказ облачных практик, неприменимых к купленному CapEx.

ЧАСТЬ 1. GOVERNANCE — Model Card

1.1. Model Details

Поле	Значение
Название системы	Корпоративный ассистент «Суфлёр»
Версия карточки	v1.0 (соответствует релизу системы sufler-1.0, git tag)
Дата	22.08.2026
Тип системы	Retrieval-Augmented Generation, рекомендательный (advisory) режим
ML Owner	А. Зубик (архитектор AI-платформы) — отвечает за качество ретрива, промпты, guardrails, метрики
Business Owner	руководитель контакт-центра / владелец процесса ЛПА — отвечает за состав базы знаний и приемлемость решений
Risk level	Limited — система не принимает решений о людях, а подсказывает сотруднику; финальное действие всегда за человеком

Компоненты и лицензии:

Слой	Компонент	Лицензия	Роль
Генерация	Qwen3.8-27B (FP8, dense 27B, нативный vision)	Apache 2.0	формулирование ответа строго по контексту
Работа со сканами	Zubr-VL-32B — наш QLoRA поверх Qwen/Qwen3-VL-32B-Instruct	Apache 2.0 (база) + собственный адаптер	распознавание и разбор сканов/фото документов, право РБ
Serving	vLLM (PagedAttention, continuous batching); llama.cpp для GGUF-варианта	Apache 2.0 / MIT	инференс
Retrieval	Qdrant (dense) + BM25, объединение RRF	Apache 2.0	поиск релевантных пунктов ЛПА
Reranking	cross-encoder (bge-reranker-v2-m3 в проде)	MIT / Apache 2.0	переранжирование top-20 → top-5
Guardrails	input (prompt-injection) + output (PII-маска)	собственная разработка	защита периметра запроса и ответа
Доступ	RBAC pre-filter по ролям на уровне фильтра ретрива	собственная разработка	разграничение доступа к ЛПА

Версионирование, привязанное к Decision Log: ответ системы определяется не только весами модели, но и четвёркой (model_version, prompt_version, index_version, retriever_config). Все четыре пишутся в лог решения — иначе воспроизвести прошлый ответ невозможно (см. § 1.6).

1.2. Intended Use & Limitations

Назначение. Система предназначена для **сотрудников организации** (в первую очередь операторов контакт-центра и специалистов бэк-офиса) и отвечает на вопросы по **действующим локальным правовым актам** организации — отпуска, командировки, доступ к ПДн, внутренние процедуры — **с обязательной ссылкой на документ и раздел**. Используется как **справочный инструмент**: подсказка человеку, который принимает решение и несёт за него ответственность. Юрисдикция — Республика Беларусь; язык — русский.

Явно вне области применения (out of scope):

- **не является юридическим заключением** и не заменяет экспертизу юридического отдела или отдела кадров;
- **не принимает и не обосновывает решений в отношении конкретных людей** — приём на работу, увольнение, дисциплинарное взыскание, отказ клиенту;

- **не предназначена для прямого доступа внешних клиентов** — только внутренний контур сотрудников;
- **не работает с документами вне индексируемой базы ЛПА**: если пункта нет в корпусе, корректное поведение — отказ, а не догадка;
- **не обрабатывает персональные данные субъектов в запросе**: ПДн маскируются на входе и выходе, вопросы вида «какой отпуск у Иванова И. И.» находятся вне сценария;
- не применяется к юрисдикциям за пределами РБ и к нормативным актам государственного уровня (только внутренние ЛПА).

Технические ограничения:

Ограничение	Значение	Следствие для пользователя
Актуальность базы	лаг переиндексации до 24 ч после изменения ЛПА	в переходный период возможен ответ по прошлой редакции → в ответе указывается <code>index_version</code> и дата документа
Порог релевантности	ответ формируется только при непустом top-5 после ре-ранкинга	при пустом результате выдаётся отказ «Не нашёл в ЛПА, уточните у профильного отдела»
Контекст	до 5 фрагментов ЛПА на ответ	вопросы, требующие сопоставления многих документов, обслуживаются хуже
Язык	русский	документы и вопросы на других языках вне поддержки
Latency (целевой SLO)	TTFT ≤ 1,5 с, полный ответ p95 ≤ 5 с	при пиковой нагрузке возможна деградация до очереди
Уровень доступа	ответ ограничен ЛПА, доступными роли пользователя	пользователи с узким доступом получают больше отказов — это ожидаемое поведение, а не сбой

Про правовую компетенцию Zubr-VL-32B. Адаптер обучен на законодательстве РБ (28 кодексов и практика их применения), поэтому в продуктивном позиционировании платформы заявлены «ответы со ссылками на статьи 25 кодексов». В «Суфлёр» эта компетенция используется **только как вспомогательная**: ответ по-прежнему формируется по контексту из ЛПА организации, а знание внешнего права помогает корректно читать и интерпретировать сканы документов. **Ответ о законодательстве, не подтверждённый ретривом, юридическим заключением не является** (см. out of scope).

Обязательное условие эксплуатации: ответ системы, не подтверждённый цитатой из ЛПА, **не может использоваться как основание для действия**. Интерфейс всегда показывает источник; отсутствие источника = отсутствие ответа.

1.3. Training Data & Bias Analysis

Уровень А. Upstream — веса Qwen3.8-27B

Параметр	Что известно
Источник	открытые веса Alibaba (Qwen/Qwen3.8-27B, релиз 05.08.2026), Apache 2.0; загрузка через ModelScope-зеркало с фиксацией checksum (HuggingFace из РБ ограничен)
Архитектура	dense 27B, 64 слоя, гибридный layout (Gated DeltaNet + Gated Attention), нативный vision-энкодер (изображения и видео)
Состав обучающих данных	вендором не раскрыт — известны лишь общие сведения о мультязычном корпусе
Разметка и фильтрация	не раскрыты

Неизвестные источники bias (то, что мы не можем измерить). Состав корпуса, доля русского языка, политика фильтрации — непроверяемы. Компенсация архитектурная: **grounding** — модель обязана отвечать только по переданному контексту, системный промпт запрещает выдумывать факты. Остаточный риск — стилистические и оценочные смещения; митигация — шаблонизация ответа и запрет оценочных суждений.

Уровень В. Наше дообучение — QLoRA-адаптер Zubr-VL-32B

Это единственный слой, где мы **сами формировали обучающую выборку**, поэтому он разобран полностью.

Параметр	Значение
База	Qwen/Qwen3-VL-32B-Instruct (Apache 2.0)
Метод	QLoRA (4-bit NF4) — full fine-tune 32B на одной карте не помещается
Гиперпараметры	r = 16, alpha = 32, dropout = 0.05; target-модули q,k,v,o,gate,up,down_proj; lr 1e-4; 1 эпоха ; max_seq_len 4096; batch 1 × grad_accum 16; bf16 + gradient checkpointing
Что не обучалось	vision-башня заморожена — обучался только языковой слой
Оборудование	1× арендованный H100 80 GB (разовый прогон)
Стек	TRL 1.8 / PEFT 0.19.1 / Transformers 5.14 / bitsandbytes
Артефакт	адаптер 256 МБ + слитый GGUF Q4_K_M 18 ГБ

Состав обучающей смеси:

Часть	Объём	Содержание
Правовой корпус РБ	sft_train.jsonl $\approx$ 400 МБ, собран из корпуса 6 302 документа / 133,4 млн символов	законодательство Респу- блики Беларусь и практика его применения
Идентичность платфор- мы	~200 примеров, продуб- лированных x10	модель называет себя «Зубр», знает продукты ZubrIQ и домен РБ (геогра- фия, символы, экономика, ПВТ, культура)
Eval-набор	sft_eval.jsonl $\approx$ 21 МБ	отложенная выборка того же распределения

Структура правового корпуса (по DOCUMENT_LIST.csv):

Источник	Документов	Тип	Что это
etalonline.by (Национальный правовой портал)	757	НПА	официально опубликованные нормативные правовые акты, в том числе 28 кодексов Республики Беларусь — Гражданский, Уголовный, Трудовой, Налоговый (Общая и Особенная части), ГПК, УПК, ХПК, КоАП, ПИКоАП, Банковский, Бюджетный, Жилищный, Земельный, Лесной, Водный, Воздушный, Избирательный, Инвестиционный, Таможенный, о браке и семье, об образовании, о недрах, о культуре, о судостроительстве, об архитектурной деятельности, внутреннего водного транспорта, торгового мореплавания, уголовно-исполнительный
ilex	5 545	аналитические статьи	комментарии, разъяснения и практика применения от авторов правовой базы

Распределение по уровню значимости: tier A — 2 149, tier B — 3 375, tier C — 778. Доминирующие темы: налогообложение (НДС, УСН, подоходный, налог на прибыль), хозяйственный процесс, персональные данные, банковское и трудовое право.

Публичное обещание платформы — «ответы со ссылкам на статьи **25 кодексов»** (zubriq.by) — соответствует составу корпуса и является границей заявленной компетенции модели.

Выявленные смещения дообучения:

Смещение	Проявление	Причина
Перевес аналитики над нормой (88 % / 12 %)	модель усваивает не столько тексты законов, сколько их толкование конкретными авторами ; авторская позиция может воспроизводиться как если бы она была нормой	5 545 статей <i>іlex</i> против 757 официальных НПА
Искусственный перевес идентичности (x10)	склонность подчёркивать, что она «Зубр», и подтягивать тему платформы там, где не спрашивали	200 примеров дублированы десятикратно, чтобы не утонуть в корпусе — сознательный трюк с известной ценой
Тематический перекося	налоги и хозяйственный процесс проработаны заметно лучше редких отраслей	распределение тем корпуса, а не замысел
Доменный сдвиг: право РБ ≠ ЛПА организации	уверенно рассуждает о законодательстве, но внутренние регламенты знает только через ретрив	корпус — внешнее право, а не наши документы
Однократная эпоха на большом корпусе	адаптация неглубокая и неравномерная	1 эпоха, $lr\ 1e-4$
Vision не адаптирован	распознавание сканов работает на «заводских» способностях базы	vision-башня заморожена
Разная правовая природа источников	НПА с <i>etalonline.by</i> — официальные акты, не являющиеся объектом авторского права; статьи <i>іlex</i> — авторский контент с ограничениями на распространение	смешанный корпус; следствие — см. риск в § 1.6

Что мы не можем измерить на этом уровне: долю дословно запоминаемых фрагментов правового корпуса (*memorization*) — специальный тест на извлечение не проводился; и качество на редких отраслях права, не представленных в *eval*-наборе пропорционально.

Уровень С. Корпус ретрива — ЛПА организации

Параметр	Значение
Источник	внутренние локальные правовые акты организации, действующие редакции
Период	действующие на дату индексации редакции (с историей замен)
Объём (MVP)	3 документа-образца (отпуск, командировки, доступ к ПДн); в целевом контуре — весь корпус ЛПА
Разметка	документ, раздел, дата редакции, ACL-метки ролей (RBAC)
Предобработка	recursive-чанкинг по разделам с сохранением заголовков; маскирование ПДн при индексации
«Train/test»	golden set вопросов с эталонными ответами и ссылками на пункты, составляется профильными отделами

Выявленные смещения корпуса:

Смещение	Проявление	Почему возникает
Доменный перекос	подробно описанные процессы (отпуска, командировки) обслуживаются заметно лучше редких процедур	ЛПА написаны неравномерно
Недопредставленность редких сценариев	по нетиповым ситуациям система чаще отказывает	мало текста → слабый ретрив
RBAC-искажение	у ролей с узким доступом выше доля отказов	pre-filter по ACL сужает поиск — требуемое поведение , но измеряется отдельно
Временной сдвиг	ответ по прошлой редакции в окне переиндексации	лаг до 24 ч
Языковой	формальный язык ЛПА против разговорных формулировок операторов	разные регистры речи

Сознательно исключённые признаки: ПДн (ФИО, телефоны, документы, e-mail) маскируются и **не индексируются**; идентификатор пользователя в логах — только хэш. Персонализация по должности и истории обращений намеренно не используется.

Что мы не можем измерить здесь: полноту ЛПА (какие процедуры вообще не описаны) и корректность самих норм. **Граница ответственности:** система отвечает за **верность цитирования**, а не за содержание регламента.

1.4. Метрики справедливости (Fairness)

Ключевая методологическая оговорка. Классические защищённые признаки (пол, возраст, раса) в нашей системе **отсутствуют по построению**: система не знает

демографии пользователя и не персонализирует ответ. Поэтому demographic parity и equalized odds в исходном виде неприменимы. Fairness переопределяется как **равное качество обслуживания по эксплуатационным группам** — это честная адаптация принципа, а не отказ от него.

Группы для замера:

Ось	Группы
Роль / уровень доступа	оператор КЦ · специалист бэк-офиса · руководитель · сотрудник с расширенным доступом
Подразделение	КЦ · HR · бухгалтерия · ИТ
Тематика вопроса	частотные темы (отпуск, командировки) · редкие процедуры
Формулировка	формальная (терминами ЛПА) · разговорная (как спрашивает живой оператор)

Метрики и целевые пороги:

Метрика	Определение	Порог
Equal quality gap	разброс RAGAS faithfulness между группами	≤ 5 п. п.
Equal answer relevancy gap	разброс answer relevancy между группами	≤ 5 п. п.
Coverage parity	разброс доли отказов («не нашёл в ЛПА») между группами, за вычетом отказов, объяснимых RBAC	≤ 7 п. п.
Retrieval parity	разброс recall@5 по тематическим группам на golden set	≤ 10 п. п.
Phrasing robustness	разрыв качества «формальная формулировка» vs «разговорная»	≤ 8 п. п.
Latency parity	разброс p95 между подразделениями (арендаторами)	≤ 15 %

Важная деталь замера: отказы, вызванные RBAC, **исключаются из числителя coverage parity** — иначе метрика будет наказывать систему за корректную работу разграничения доступа. Разделение обеспечивается флагом в Decision Log: причина отказа — acl_filtered или no_relevant_context.

Как встраивается в пайплайн (по схеме урока 30):

- **до индексации** — аудит покрытия корпуса по темам; выявленные «дыры» уходят владельцу процесса как задача на дописывание ЛПА, а не компенсируются трюками в ретриве;
- **во время ретрива** — гибридный поиск (dense + BM25 + RRF) как раз снижает языковой перекоз: BM25 вытягивает точные термины, dense — разговорные переформулировки;
- **после генерации** — пороговая политика: при низкой уверенности ретрива система обязана отказать, а не «дотянуть» ответ.

Статус измерений. Пороги выше — **целевые SLO, зафиксированные до замеров**; на текущем MVP они не измерены. Это осознанная фиксация, а не пропуск: карточка версии v1.0 выпускается вместе с планом первого замера на golden set, и раздел Evaluation Results ниже помечает статус каждой метрики честно.

1.5. Evaluation Results

Метрика	Целевой порог	Текущее значение	Статус
RAGAS faithfulness (ответ следует из контекста)	≥ 0.90	не измерено	◆ замер на golden set запланирован
RAGAS answer relevancy	≥ 0.85	не измерено	◆
RAGAS context precision	≥ 0.80	не измерено	◆
Recall@5 ретрива на golden set	≥ 0.90	не измерено	◆
Refusal correctness (доля корректных отказов при отсутствии основания)	≥ 0.95	не измерено	◆
Source attribution (доля ответов с корректной ссылкой)	1.00 (жёсткое требование)	обеспечено архитектурно	✓ ответ без источника не выдаётся
TTFT p95	≤ 1.5 с	не измерено	◆
Latency p95 (короткий ответ)	≤ 5 с	не измерено	◆
PII leak rate в ответах и логах	0	выборочная проверка на MVP — утечек не выявлено	◆ требуется регулярный автотест
Throughput Zubr-VL-32B (GGUF Q4_K_M, 4x V100 16 GB, llama.cpp)	—	31–33 ток/с , ~27 GiB VRAM при контексте 16k	✓ измерено на проде 21.07.2026
Чтение скана документа Zubr-VL-32B	корректное извлечение текста	проверено вручную на реальных сканах — читает точно	✓ качественная проверка
Memorization test (извлечение фрагментов обучающего корпуса из адаптера)	не более единичных совпадений	не проводился	✗ пробел, см. § 1.6

Инструменты замера: RAGAS + MLflow (сравнение прогонов), трейсы Langfuse как источник реальных запросов для расширения golden set. Публикация значений — обязательное условие перехода карточки из v1.0 в v1.1.

Почему пустые ячейки оставлены пустыми. Проставить правдоподобные цифры было бы проще, но карточка — документ для аудитора: **неизмеренная метрика с честным статусом полезнее выдуманной**. Заполнение — первый пункт плана после сдачи.

1.6. Ethical Considerations

Выявленные риски и план митигации

Ответственные

- **ML Owner:** А. Зубик — качество ретрива и генерации, guardrails, метрики, обновление карточки.
- **Business Owner:** владелец процесса ЛПА (КЦ/HR) — состав и актуальность базы знаний, приемлемость ответов.
- **Governance-ревью:** совместное, ежеквартально, плюс внеочередное при смене модели, промпта или схемы чанкинга.

Механизм обжалования

Параметр	Значение
Основание	№ 99-З (право субъекта на разъяснение), внутренний регламент качества
Процесс	пользователь нажимает «оспорить ответ» → создаётся тикет с request_hash → ML Owner поднимает decision log и воспроизводит контекст → ручная проверка с профильным отделом → решение и уведомление инициатора → при подтверждении дефекта: правка корпуса/промпта + регресс-тест в golden set
SLA	5 рабочих дней (внутренний контур; для запросов субъектов ПДн — в сроки, установленные № 99-З)
Контакт	ML Owner (основной), Business Owner (эскалация)

Governance-архитектура: где это живёт

Слой	Реализовано у нас	Статус
Data	версионирование корпуса ЛПА, index_version, маскирование ПДн при индексации	частично
Model	ADR-пакет, фиксация версии весов и checksum, эта Model Card	✅
Decision	Decision Log: request_hash · features (id чанков + скоры, без сырого текста) · prediction (ответ + источники + confidence) · model_version (git hash + prompt_version + index_version)	💡 к внедрению
Audit	append-only хранилище (MinIO с object lock), retention policy, воспроизведение решения по request_hash	❌ отсутствует — главный пробел

Условия обновления карточки: смена версии модели или квантования · изменение системного промпта · изменение схемы чанкинга или параметров ретрива · существенное расширение корпуса · любой результат аудита fairness. Версия карточки совпадает с git tag релиза — **карточка живёт в репозитории рядом с кодом, а не в вики.**

ЧАСТЬ 2. FINOPS — анализ перерасхода и план оптимизации

2.1. Ситуация: счёт вспомогательного контура

Продуктовый контур on-prem, но **dev/eval-площадка живёт в Yandex Cloud**: там прогоняются RAGAS-замеры, staging-сборки и эксперименты с моделями. Бюджет — **\$2 000/мес**. Пришёл счёт **\$3 006 (+50 %)**.

Статья	Факт, \$/мес	План, \$	Δ	Диагноз
GPU-инстансы (dev/eval, A100)	750	500	+250	подняты для eval-прогонов, не выключаются ночью и в выходные ; средняя утилизация ~12 %
Аренда H100 80 GB (QLoRA-прогон Zubr-VL-32B)	340	0	+340	разовое дообучение на арендованном боксе — работа нужная, но в бюджет месяца не заложенная
LLM API (Foundation Models, judge для RAGAS)	655	350	+305	LLM-судья и простые классификации гоняются на самой большой доступной модели ; прогоны на полном датасете при каждом коммите
Object Storage (трейсы Langfuse, чекпоинты, логи)	421	200	+221	всё лежит в стандартном типе, retention не задан , полные промпты и ответы хранятся бессрочно
Логи и мониторинг	385	300	+85	уровень DEBUG на staging, access-логи без сэмплинга
Managed PostgreSQL / Redis (dev)	180	180	0	в норме
Сеть / egress	150	120	+30	выгрузка артефактов на локальные машины без кэша
Прочее (диски, снапшоты, зомби-тома)	125	100	+25	orphaned volumes от удалённых стендов
Итого	3 006	1 750	+1 256	

2.2. Причины: три утечки и одна незапланированная работа

Перерасход +\$1 256 раскладывается на четыре класса — и три из них ровно те, что разбирались в уроке 28. Ни одна причина не является «дорогим провайдером»:

1. Overprovisioning и zombie-ресурсы (~\$275, 22 %). Dev/eval-GPU работают 24/7, а реально нужны 3–4 часа в сутки; плюс осиротевшие диски от удалённых стендов. Платим за ожидание, а не за вычисления.

2. Дорогие настройки по умолчанию (~\$306, 24 %). Трейсы и логи пишутся полностью, одинаково для всех запросов и хранятся вечно в самом дорогом тире. Это ровно тот случай, который в лекции по governance назван «Decision Log без TTL»: **комплаенс-требование реализовано максимально дорогим способом**, хотя аудиторская ценность лога через 90 дней несопоставима с его ценой.

3. Слишком «умная» модель для простых задач (~\$305, 24 %). LLM-судья RAGAS и вспомогательные классификации (язык, тематика, простые FAQ) обслуживаются флагманской моделью через платный API, хотя качество этих подзадач не деградирует на меньшей модели — а часть решается локально на уже оплаченном железе.

4. Незапланированное, но обоснованное обучение (~\$340, 27 %). Аренда H100 под QLoRA-прогон Zuber-VL-32B — это не утечка: работа дала рабочий адаптер и модель, читающую сканы. Проблема не в трате, а в том, что **разовое обучение не было отдельной строкой бюджета** и всплыло как «перерасход». Разделение этих двух природ перерасхода принципиально: **утечки режем, обучение планируем и удешевляем**.

Остаток (~\$30, 2 %) — выгрузка артефактов без кэша.

2.3. План Cost Optimization

#	Мера	Эффект, \$/мес	Срок внедрения
1	Расписание и Spot для dev/eval-GPU	–450	3 дня
2	TTL + стратификация логов	–300	2–3 дня
3	Model routing по сложности	–400	1–2 недели
4	Уборка зомби-ресурсов и сэмплинг логов	–110	1 день
5	Тегирование и бюджетные алерты	0 (условие остальных)	2 дня
6	Infracost в CI	предотвращение	1 день
7	Spot/preemptible + отдельная строка бюджета под обучение	–150 (на будущий прогон)	1 неделя
Итого		–1 410	

1. Расписание и Spot для dev/eval-GPU (–\$450). Auto-shutdown по расписанию (окно 20:00–08:00 и выходные) + перевод batch-eval на **preemptible/spot** с чекпойнтом каждые 10 минут; прогоны запускаются по триггеру пайплайна, а не держатся постоянно. *Риск*: прерывание spot-инстанса → снимается чекпойнтами и автоперезапуском; интерактивная отладка остаётся на on-demand.

2. TTL и стратификация логов (–\$300). Retention: горячий тир 14 дней → холодный 90 дней → удаление (кроме High-Risk). **Стратификация по риску:** обжалованные и чувствительные решения — полный лог; остальные — агрегаты (хэш запроса, id чанков, скоры, метрики) без сырого текста. *Риск:* потеря глубины ретроспективного анализа → снимается буфером полного лога 14 дней для **всех** решений с последующим прореживанием.

3. Model routing по сложности (–\$400). Классификатор сложности перед генерацией: FAQ и типовые вопросы → малая модель или extractive-ответ по цитате; сложные и агентные → Qwen3.8-27B. Отдельно: **LLM-судья RAGAS переносится с платного API на локальный контур** — железо уже оплачено. *Риск:* деградация качества → роутинг выкатывается канареечно с контролем faithfulness, порог переключения подбирается по golden set.

4. Уборка зомби-ресурсов и сэмплинг логов (–\$110). Lifecycle-политика для дисков и снапшотов, автоудаление orphaned volumes; DEBUG → INFO на staging, sampling 1/10 для healthcheck'ов. *Риск:* минимальный.

5. Тегирование и бюджетные алерты (0). Обязательные теги project / team / env / cost-center на всех ресурсах; алерт при прохождении 80 % бюджета. Прямой экономии не даёт, но **без тегов невозможны ни showback, ни rightsizing** — это фундамент остальных мер.

7. Обучение — на spot и отдельной строкой бюджета (–\$150 на прогон). QLoRA-прогоны переносятся на preemptible-инстансы (чекпоинты каждые 200 шагов уже реализованы в скрипте — прерывание не теряет работу), а аренда H100 планируется как **отдельная статья «эксперименты и дообучение»**, а не размазывается по dev-бюджету. *Риск:* прерывание в конце длинного прогона → снимается чекпоинтингом и возобновлением с последнего шага. **Важно:** эта мера не сокращает объём обучения — она делает его дешевле и предсказуемее.

6. Infracost в CI (предотвращение). Дельта стоимости в merge request по плану OpenTofu, обязательное ревью при росте более \$50/мес. *Риск:* ложные срабатывания на легитимный рост → снимается порогом и требованием обоснования в MR.

Результат: \$3 006 → ~\$1 596/мес — это **–47 % к текущему счёту** и возврат в бюджет (\$2 000) с запасом ~20 %. Цель задания (снижение расходов) перевыполнена, при этом ни одна мера не является «договориться о скидке» — все шесть архитектурные или процессные.

Матрица «импакт x сложность» (по методике урока 28):

- **Быстрые победы** (дни, высокий эффект): расписание GPU (–\$450 за 3 дня), TTL и стратификация логов (–\$300 за 2–3 дня), уборка зомби (–\$110 за день) — **закрывают 61 % экономии за первую неделю**;
- **Ключевые проекты** (недели): model routing (–\$400, 1–2 недели) — требует классификатора и канареечной выкатки; перевод обучения на spot (–\$150) — требует проверки возобновления с чекпоинта;
- **Инфраструктура дисциплины** (не экономит напрямую): тегирование и Infracost — без них экономия разъедется обратно за квартал.

Правило Парето подтверждается: **две меры (расписание GPU + TTL логов) дают 53 % всей экономии за неделю работы**, а вместе с уборкой зомби — 61 % без единой строчки нового кода.

2.4. Баланс цены и качества: что мы сознательно НЕ режем

Это ответ на критерий «зрелость» — граница, за которую оптимизация не идёт:

Не режем	Почему
Полноту логов по High-Risk решениям	обжалование по № 99-З требует воспроизвести решение; экономия здесь — прямой комплаенс-риск. TTL = max(требование аудита, экономическая целесообразность) , а не минимум по цене
Порог faithfulness и обязательность цитаты	дешёвая модель в роутинге допускается только там, где качество подтверждено golden set; при падении faithfulness > 5 п. роутинг откатывается
TTFT p95 ≤ 1,5 с	это UX-контракт с оператором КЦ: подсказка, приходящая позже реплики клиента, бесполезна независимо от цены
Генерацию ответа на малой модели	дистилляция и малые модели применяются к вспомогательным задачам (классификация, роутинг, судья), но не к формулированию ответа по ЛПА — цена ошибки в правовом ответе выше экономии
Резерв второй карты в проде	вторая H100 — HA-резерв и запас throughput; её «утилизация ради экономии» уничтожает отказоустойчивость
Само дообучение	QLoRA-прогон дал модель, читающую сканы документов на праве РБ, — экономия здесь означала бы отказ от возможности, а не оптимизацию. Удешевляем способ (spot, чекпоинты), а не отказываемся от работы

2.5. On-premise: где у нас на самом деле находится FinOps

Для продуктового контура облачные рычаги (spot, lifecycle-тиры, egress) не работают: CapEx уже потрачен, предельная стоимость одного лишнего запроса близка к нулю. Из уравнения $Cost = f(Architecture, Load, Efficiency)$ остаётся **Efficiency**, и метрика ровно одна — **утилизация GPU**.

Из нашего TCO-расчёта: ~\$194 000 за 3 года ≈ **\$65 000/год** амортизированно, лицензии \$0. Удельная цена:

Утилизация	Обслужено токенов/год	Удельная стоимость
25 %	~23,6 млрд	~\$2.75 / 1M токенов
50 % (текущее допущение)	~47 млрд	~\$1.40 / 1M токенов
75 %	~71 млрд	~\$0.92 / 1M токенов

Вывод, обратный облачной интуиции: on-prem экономия достигается не сокращением потребления, а **увеличением полезной загрузки** — перевод на общий инференс-контур второй плоскости (совместные сценарии, батчевые задачи ночью, внутренние eval-прогоны вместо платного API) снижает удельную цену вдвое, ничего не тратя дополнительно. Незагруженный CapEx — худшая модель владения; именно поэтому **утилизация GPU выносится на дашборд рядом с Golden Signals**.

Отсюда же меры 1 и 3 плана получают второе обоснование: перенос eval-судьи и ночных прогонов с платного облачного API на своё железо одновременно **сокращает облачный счёт и повышает утилизацию on-prem** — один шаг улучшает обе части экономики.

2.6. Sensitivity: что будет при росте нагрузки x3

Третий вопрос «золотого правила» из урока 28:

Статья	Поведение при x3	Комментарий
On-prem инференс	стоимость не растёт , удельная цена падает (~\$0.6–0.9 за 1M токенов)	пока хватает ёмкости 2x H100; при исчерпании — очередь и graceful degradation, а не автоскейл (скейлить некуда)
Decision Log / трейсы	растут линейно и становятся первой статьёй	без стратификации и TTL рост x3 съедает всю сегодняшнюю экономию — мера 2 обязательна именно как условие масштабирования
Dev/eval-контур	растёт слабо (не зависит от продуктового трафика)	привязан к частоте релизов, а не к числу запросов
Обжалования и ручные проверки	растут линейно → нагрузка на людей	при x3 понадобится либо второй ответственный, либо автоматизация первичного разбора

Вывод: бюджет при x3 не ломается, но профиль затрат меняет форму — доминирующей статьёй становится хранение аудиторских данных, а не вычисления. Это и есть аргумент, почему governance-часть и FinOps-часть в этом задании неразделимы: **этика создаёт данные, а данные создают счёт**.

Условие из ЛК

Цель: разработать Model Card для AI-системы и план оптимизации облачных затрат с анализом превышения бюджета.

Часть 1. Governance. Создайте «Model Card» для вашей системы: назначение модели и ограничения (Intended Use & Limitations); на каких данных обучалась (Bias analysis); метрики справедливости (Fairness).

Часть 2. FinOps. Вам пришёл счёт за облако, который превысил бюджет на 50 %. Проанализируйте типичные причины (забытые GPU-инстансы, неэффективное хранение логов, слишком «умная» модель для простых задач). Предложите план «Cost Optimization» (Spot Instances, Model Distillation, TTL для данных).

Формат сдачи: документ, содержащий Model Card и FinOps-отчёт с планом действий.

Критерии оценки (статус «Принято»): *Этика* — Model Card заполнен по стандарту, риски предвзятости осознаны; *Экономика* — предложены конкретные технические меры снижения костов (не просто «договориться о скидке»); *Зрелость* — понимание баланса между ценой и качеством.

Вспомогательные материалы: [Model Card](#) · [HuggingFace](#) · [Model Cards for Model Reporting](#) (arXiv:1810.03993) · [FinOps Framework](#).

Дедлайн: 27.08.2026 (на слайде лекции «06.05» — опечатка шаблона презентации).

Артефакты

- ☒ [Zubik_DZ-30_finops-governance.pdf](#) — 16 стр., сборка через [scripts/md-to-pdf.sh](#)
- ☒ Опора на пакет финального проекта: [ADR-0002 \(выбор модели\)](#), [ADR-0006 \(FP8 и sizing\)](#), [TCO](#), [MVP «Суфлёр»](#)

Сложности и решения

- **Три источника предвзятости вместо одного.** В системе одновременно чужие веса (Qwen3.8-27B), наше собственное дообучение (Zubr-VL-32B, QLoRA) и корпус ретрива. Смешивать их в одном разделе — потерять смысл анализа, поэтому карточка разложена на три уровня с разной степенью нашего контроля: от «не можем измерить» у upstream до полностью известной обучающей смеси у адаптера.
- **Честный разбор собственного трюка.** Дублирование 200 примеров идентичности $\times 10$, чтобы они не утонули в сотнях тысяч легал-примеров, — приём рабочий, но он же и создаёт смещение. Записал его в таблицу смещений как **сознательный трюк с известной ценой**, а не спрятал: карточка ценна ровно тем, что в ней есть такие признания.
- **Fairness без защищённых признаков.** Система не знает демографии, поэтому demographic parity неприменим. Переопределил справедливость как равное качество обслуживания по ролям, подразделениям, темам и стилю формулировки — с отдельной тонкостью: отказы, вызванные RBAC, исключаются из метрики покрытия, иначе метрика штрафует за корректную работу разграничения доступа.
- **Незаполненные метрики.** Соклаз проставить правдоподобные цифры был, но карточка — документ для аудитора: неизмеренная метрика с честным статусом полезнее выдуманной. Пороги зафиксированы до замеров, замеры — первый пункт плана.
- **FinOps без облачного счёта.** Продуктовый контур on-prem, счёта нет. Разделил задачу на два горизонта: облачный dev/eval-контур (там разбирается сценарий +50 %) и on-prem, где FinOps сводится не к сокращению трат, а к росту утилизации — и удельная цена токена падает с \$2.75 до \$0.92 при загрузке с 25 % до 75 %.
- **Перерасход бывает двух природ.** Аренда H100 под дообучение формально раздула счёт на 27 % перерасхода, но это не утечка: работа дала рабочую модель. Разделил классы явно — **утечки режим, полезную работу планируем и удешевляем**; без этого разделения FinOps-отчёт превращается в предложение перестать развиваться.
- **Стык двух частей.** Изначально казались разными темами, но сошлись в одной точке: decision log, требуемый governance, — это и есть самая быстрорастущая статья счёта.

Отсюда сквозной тезис работы: **этика создаёт данные, а данные создают счёт**, и TTL задаётся как максимум из требования аудита и экономики, а не как минимум по цене.

Обратная связь от преподавателя

(после проверки)