

Содержание

ДЗ-30 · FinOps и Governance: управление стоимостью и этикой AI	1
0. Фиксация допущений	1
ЧАСТЬ 1. GOVERNANCE — Model Card	2
1.1. Model Details	2
1.2. Intended Use & Limitations	3
1.3. Training Data & Bias Analysis	4
1.4. Метрики справедливости (Fairness)	6
1.5. Evaluation Results	8
1.6. Ethical Considerations	9
ЧАСТЬ 2. FINOPS — анализ перерасхода и план оптимизации	11
2.1. Ситуация: счёт вспомогательного контура	11
2.2. Причины: три канонические утечки	11
2.3. План Cost Optimization	12
2.4. Баланс цены и качества: что мы сознательно НЕ режем	13
2.5. On-premise: где у нас на самом деле находится FinOps	14
2.6. Sensitivity: что будет при росте нагрузки x3	15
Условие из ЛК	15
Артефакты	16
Сложности и решения	16
Обратная связь от преподавателя	16

ДЗ-30 · FinOps и Governance: управление стоимостью и этикой AI

Студент: Александр Зубик · **Курс:** AI Architect (OTUS) · **Капстоун блока 6** (уроки 28 «FinOps» + 30 «Ethical AI by Design»)

Объект — сквозной для всех моих работ корпоративный RAG-ассистент «Суфлёр» (ДЗ-20, ДЗ-24, финальный проект): подсказки оператору контакт-центра и ответы по локальным правовым актам (ЛПА) с цитатами. Стек: Qwen3.5-72B (FP8) за vLLM + Qdrant + hybrid retrieval с реранкингом, on-premise на 2x H100 NVL, air-gapped.

0. Фиксация допущений

Обе части задания в лоб к нашей системе не применяются, поэтому — три допущения, зафиксированные до начала работы.

Допущение 1. Мы не обучаем модель — мы её интегрируем. Веса Qwen3.5-72B взяты как есть (Apache 2.0). Классическая Model Card в понимании Google/HuggingFace описывает *обученную модель*; у нас же вся инженерия — вокруг неё. Поэтому карточка составлена **двухуровневой**:

- **Upstream Model Card** — то, что известно про веса от вендора, включая честное «не можем измерить»;
- **System Card** — карточка *системы* (retrieval + промпт + guardrails + RBAC), где и находится наш собственный вклад в качество и предвзятость.

Это не обход требования, а следование его смыслу: **источник bias у нас — корпус ЛПА и логика ретрива, а не обучающая выборка**, и анализировать надо именно их.

Допущение 2. Юрисдикция — Республика Беларусь. Опорный закон — № 99-З «О защите персональных данных», а не 152-ФЗ; там, где в лекции стоят ФСТЭК/Рос-здравнадзор, у нас действуют белорусские ТНПА. Механика (согласие, минимизация, право на обжалование) совпадает.

Допущение 3. Облачного счёта в привычном виде у нас нет. Продуктовый контур on-premise и air-gapped, счёт от провайдера физически не приходит. Поэтому часть 2 сделана на **двух горизонтах**:

- **А. Гибридный вспомогательный контур в Yandex Cloud** — dev/eval-площадка (замеры RAGAS, эксперименты, staging), которая реально тарифицируется. Здесь и разбирается сценарий «счёт превысил бюджет на 50 %»; цифры — модельные, порядок величин взят из наших реальных конфигураций.
- **В. On-premise продуктовый контур** — где счёта нет, но есть **удельная стоимость токена**, и она полностью определяется утилизацией железа.

Разделение принципиально: без него FinOps-часть выродилась бы в пересказ облачных практик, неприменимых к купленному CapEx.

ЧАСТЬ 1. GOVERNANCE — Model Card

1.1. Model Details

Поле	Значение
Название системы	Корпоративный ассистент «Суфлёр»
Версия карточки	v1.0 (соответствует релизу системы <code>sufler-1.0</code> , git tag)
Дата	22.08.2026
Тип системы	Retrieval-Augmented Generation, рекомендательный (advisory) режим
ML Owner	А. Зубик (архитектор AI-платформы) — отвечает за качество ретрива, промпты, guardrails, метрики
Business Owner	руководитель контакт-центра / владелец процесса ЛПА — отвечает за состав базы знаний и приемлемость решений
Risk level	Limited — система не принимает решений о людях, а подсказывает сотруднику; финальное действие всегда за человеком

Компоненты и лицензии:

Слой	Компонент	Лицензия	Роль
Генерация	Qwen3.5-27B (FP8, dense)	Apache 2.0	формулирование ответа строго по контексту
Serving	vLLM (PagedAttention, continuous batching)	Apache 2.0	инференс
Retrieval	Qdrant (dense) + BM25, объединение RRF	Apache 2.0	поиск релевантных пунктов ЛПА
Reranking	cross-encoder (bge-reranker-v2-m3 в проде)	MIT / Apache 2.0	переранжирование top-20 → top-5
Guardrails	input (prompt-injection) + output (PII-маска)	собственная ботка	защита периметра запроса и ответа
Доступ	RBAC pre-filter по ролям на уровне фильтра ретрива	собственная ботка	разграничение доступа к ЛПА

Версионирование, привязанное к Decision Log: ответ системы определяется не только весами модели, но и четвёркой (model_version, prompt_version, index_version, retriever_config). Все четыре пишутся в лог решения — иначе воспроизвести прошлый ответ невозможно (см. § 1.6).

1.2. Intended Use & Limitations

Назначение. Система предназначена для **сотрудников организации** (в первую очередь операторов контакт-центра и специалистов бэк-офиса) и отвечает на вопросы по **действующим локальным правовым актам** организации — отпуска, командировки, доступ к ПДн, внутренние процедуры — **с обязательной ссылкой на документ и раздел**. Используется как **справочный инструмент**: подсказка человеку, который принимает решение и несёт за него ответственность. Юрисдикция — Республика Беларусь; язык — русский.

Явно вне области применения (out of scope):

- **не является юридическим заключением** и не заменяет экспертизу юридического отдела или отдела кадров;
- **не принимает и не обосновывает решений в отношении конкретных людей** — приём на работу, увольнение, дисциплинарное взыскание, отказ клиенту;
- **не предназначена для прямого доступа внешних клиентов** — только внутренний контур сотрудников;
- **не работает с документами вне индексируемой базы ЛПА**: если пункта нет в корпусе, корректное поведение — отказ, а не догадка;
- **не обрабатывает персональные данные субъектов в запросе**: ПДн маскируются на входе и выходе, вопросы вида «какой отпуск у Иванова И. И.» находятся вне сценария;
- не применяется к юрисдикциям за пределами РБ и к нормативным актам государственного уровня (только внутренние ЛПА).

Технические ограничения:

Ограничение	Значение	Следствие для пользователя
Актуальность базы	лаг переиндексации до 24 ч после изменения ЛПА	в переходный период возможен ответ по прошлой редакции → в ответе указывается <code>index_version</code> и дата документа
Порог релевантности	ответ формируется только при непустом top-5 после ре-ранкинга	при пустом результате выдаётся отказ «Не нашёл в ЛПА, уточните у профильного отдела»
Контекст	до 5 фрагментов ЛПА на ответ	вопросы, требующие сопоставления многих документов, обслуживаются хуже
Язык	русский	документы и вопросы на других языках вне поддержки
Latency (целевой SLO)	TTFT ≤ 1,5 с, полный ответ p95 ≤ 5 с	при пиковой нагрузке возможна деградация до очереди
Уровень доступа	ответ ограничен ЛПА, доступными роли пользователя	пользователи с узким доступом получают больше отказов — это ожидаемое поведение, а не сбой

Обязательное условие эксплуатации: ответ системы, не подтверждённый цитатой из ЛПА, **не может использоваться как основание для действия**. Интерфейс всегда показывает источник; отсутствие источника = отсутствие ответа.

1.3. Training Data & Bias Analysis

Уровень A. Upstream — веса Qwen3.5-27B

Параметр	Что известно
Источник	открытые веса Alibaba (Qwen3.5), лицензия Apache 2.0; загрузка через ModelScope-зеркало с фиксацией checksum (HuggingFace из РБ ограничен)
Состав обучающих данных	вендором не раскрыт — известны только общие сведения о мультязычном корпусе
Разметка и фильтрация	не раскрыты
Отсечка знаний	зафиксирована в карточке модели вендора; для нас не существенна, так как фактология берётся из ретрива, а не из памяти модели

Неизвестные источники bias (то, что мы не можем измерить). Мы не знаем ни состава корпуса, ни доли русского языка, ни политики фильтрации. Следовательно, **любые культурные, языковые и доменные смещения весов для нас — непроверяемая величина.** Компенсирующая мера архитектурная, а не модельная: **grounding** — модель обязана отвечать только по переданному контексту, а системный промпт запрещает выдумывать факты. Это переносит основную ответственность за фактическую предвзятость с весов на наш корпус, который мы контролируем полностью.

Остаточный риск: стилистические и оценочные формулировки (тон ответа, выбор акцентов) всё ещё определяются весами и остаются неизмеримыми. Митигация — шаблонизация ответа и запрет на оценочные суждения в системном промпте.

Уровень В. Наши данные — корпус ЛПА и индекс

Параметр	Значение
Источник	внутренние локальные правовые акты организации, действующие редакции
Период	действующие на дату индексации редакции (с историей замен)
Объём (MVP)	3 документа-образца (отпуск, командировки, доступ к ПДн); в целевом контуре — весь корпус ЛПА
Разметка	метаданные: документ, раздел, дата редакции, ACL-метки ролей (RBAC)
Предобработка	recursive-чанкинг по разделам с сохранением заголовков; маскирование ПДн на этапе индексации
«Train/test»	golden set вопросов с эталонными ответами и ссылками на пункты; формируется профильными отделами, а не разработчиком

Выявленные смещения корпуса:

Смещение	Проявление	Почему возникает
Доменный перекос	процессы, документированные подробно (отпуска, командировки), обслуживаются заметно лучше редких процедур	ЛПА написаны неравномерно: частотные темы расписаны детально
Недопредставленность редких сценариев	по нетиповым ситуациям система чаще отказывает	в корпусе мало текста по этим темам → слабый ретрив
RBAC-искажение	у ролей с узким доступом выше доля отказов и ниже полнота	pre-filter по ACL сужает поисковое пространство — сознательное, требуемое поведение , но его нужно измерять отдельно, чтобы не спутать с деградацией качества
Временной сдвиг	вопросы про недавно изменённые процедуры могут отвечать по старой редакции	лаг переиндексации
Языковой	термины-англицизмы в ЛПА и разговорные формулировки операторов расходятся	документы написаны формальным языком, вопросы задаются бытовым

Сознательно исключённые признаки: персональные данные (ФИО, телефоны, документы, e-mail) маскируются и **не индексируются**; идентификатор пользователя в логах хранится только в виде хэша. Признаки, по которым можно было бы персонализировать ответ (должность конкретного сотрудника, история его обращений), намеренно не используются — это снизило бы прозрачность и создало бы почву для неравного обслуживания.

Что мы не можем измерить в своём корпусе: полноту ЛПА (мы не знаем, какие процедуры вообще не описаны документами) и корректность самих ЛПА — если правовой акт содержит устаревшую или несправедливую норму, система её честно воспроизведёт. **Это не дефект модели, а граница ответственности: система отвечает за верность цитирования, а не за содержание регламента.**

1.4. Метрики справедливости (Fairness)

Ключевая методологическая оговорка. Классические защищённые признаки (пол, возраст, раса) в нашей системе **отсутствуют по построению**: система не знает демографии пользователя и не персонализирует ответ. Поэтому demographic parity и equalized odds в исходном виде неприменимы. Fairness переопределяется как **равное качество обслуживания по эксплуатационным группам** — это честная адаптация принципа, а не отказ от него.

Группы для замера:

Ось	Группы
Роль / уровень доступа	оператор КЦ · специалист бэк-офиса · руководитель · сотрудник с расширенным доступом
Подразделение	КЦ · HR · бухгалтерия · ИТ
Тематика вопроса	частотные темы (отпуск, командировки) · редкие процедуры
Формулировка	формальная (терминами ЛПА) · разговорная (как спрашивает живой оператор)

Метрики и целевые пороги:

Метрика	Определение	Порог
Equal quality gap	разброс RAGAS faithfulness между группами	≤ 5 п. п.
Equal answer relevancy gap	разброс answer relevancy между группами	≤ 5 п. п.
Coverage parity	разброс доли отказов («не нашёл в ЛПА») между группами, за вычетом отказов, объяснимых RBAC	≤ 7 п. п.
Retrieval parity	разброс recall@5 по тематическим группам на golden set	≤ 10 п. п.
Phrasing robustness	разрыв качества «формальная формулировка» vs «разговорная»	≤ 8 п. п.
Latency parity	разброс p95 между подразделениями (арендаторами)	≤ 15 %

Важная деталь замера: отказы, вызванные RBAC, **исключаются из числителя coverage parity** — иначе метрика будет наказывать систему за корректную работу разграничения доступа. Разделение обеспечивается флагом в Decision Log: причина отказа — `acl_filtered` или `no_relevant_context`.

Как встраивается в пайплайн (по схеме урока 30):

- **до индексации** — аудит покрытия корпуса по темам; выявленные «дыры» уходят владельцу процесса как задача на дописывание ЛПА, а не компенсируются трюками в ретриве;
- **во время ретрива** — гибридный поиск (`dense + BM25 + RRF`) как раз снижает языковой перекоз: BM25 вытягивает точные термины, `dense` — разговорные переформулировки;
- **после генерации** — пороговая политика: при низкой уверенности ретрива система обязана отказать, а не «дотянуть» ответ.

Статус измерений. Пороги выше — **целевые SLO, зафиксированные до замеров**; на текущем MVP они не измерены. Это осознанная фиксация, а не пропуск: карточка версии v1.0 выпускается вместе с планом первого замера на golden set, и раздел Evaluation Results ниже помечает статус каждой метрики честно.

1.5. Evaluation Results

Метрика	Целевой порог	Текущее значение	Статус
RAGAS faithfulness (ответ следует из контекста)	≥ 0.90	не измерено	◆ замер на golden set запланирован
RAGAS answer relevancy	≥ 0.85	не измерено	◆
RAGAS context precision	≥ 0.80	не измерено	◆
Recall@5 ретрива на golden set	≥ 0.90	не измерено	◆
Refusal correctness (доля корректных отказов при отсутствии основания)	≥ 0.95	не измерено	◆
Source attribution (доля ответов с корректной ссылкой)	1.00 (жёсткое требование)	обеспечено архитектурно	✔ ответ без источника не выдаётся
TTFT p95	≤ 1.5 с	не измерено	◆
Latency p95 (короткий ответ)	≤ 5 с	не измерено	◆
PII leak rate в ответах и логах	0	выборочная проверка на MVP — утечек не выявлено	◆ требуется регулярный автотест

Инструменты замера: RAGAS + MLflow (сравнение прогонов), трейсы Langfuse как источник реальных запросов для расширения golden set. Публикация значений — обязательное условие перехода карточки из v1.0 в v1.1.

Почему пустые ячейки оставлены пустыми. Проставить правдоподобные цифры было бы проще, но карточка — документ для аудитора: **неизмеренная метрика с честным статусом полезнее выдуманной**. Заполнение — первый пункт плана после сдачи.

1.6. Ethical Considerations

Выявленные риски и план митигации

Риск	Серьёзность	План митигации
Уверенный ответ по неполному контексту — система формулирует правдоподобно, но пункт ЛПА вырван из контекста	Высокая	обязательная цитата + раздел; порог релевантности с отказом; мониторинг faithfulness, ревью при падении > 5 п. п.
Ответ по устаревшей редакции ЛПА	Высокая	вывод даты редакции и index_version в ответе; алерт на рассинхрон индекса > 24 ч; приоритетная переиндексация изменённых документов
Утечка ПДн через логи и кэш — промпт и ответ оседают в трейсах	Высокая	маскирование на входе и выходе; в логах — только хэши; decision log без сырых фич (ссылка на чанк вместо текста); TTL и разграничение доступа к audit store
Prompt injection через документ — вредоносная инструкция внутри ЛПА или вложения	Средняя	input-guardrail; изоляция контекста от инструкций в промпте; ревью источников при добавлении в корпус
Неравное качество по ролям и темам	Средняя	метрики § 1.4, разделение отказов acl_filtered / no_relevant_context, квартальный аудит
Over-reliance оператора — сотрудник перестаёт проверять и цитирует систему как истину	Средняя	формулировка ответа как справки со ссылкой; обучение операторов; в UI — постоянная плашка о рекомендательном характере
Воспроизведение несправедливой нормы ЛПА	Низкая (вне зоны ответственности системы)	канал обратной связи владельцу процесса: система фиксирует спорные обращения, изменение нормы — решение бизнеса
Стилистическая предвзятость весов	Низкая	шаблонизация ответа, запрет оценочных суждений в системном промпте

Ответственные

- **ML Owner:** А. Зубик — качество ретрива и генерации, guardrails, метрики, обновление карточки.
- **Business Owner:** владелец процесса ЛПА (КЦ/HR) — состав и актуальность базы знаний, приемлемость ответов.
- **Governance-ревью:** совместное, ежеквартально, плюс внеочередное при смене модели, промпта или схемы чанкинга.

Механизм обжалования

Параметр	Значение
Основание	№ 99-З (право субъекта на разъяснение), внутренний регламент качества
Процесс	пользователь нажимает «оспорить ответ» → создаётся тикет с request_hash → ML Owner поднимает decision log и воспроизводит контекст → ручная проверка с профильным отделом → решение и уведомление инициатора → при подтверждении дефекта: правка корпуса/промпта + регресс-тест в golden set
SLA	5 рабочих дней (внутренний контур; для запросов субъектов ПДн — в сроки, установленные № 99-З)
Контакт	ML Owner (основной), Business Owner (эскалация)

Governance-архитектура: где это живёт

Слой	Реализовано у нас	Статус
Data	версионирование корпуса ЛПА, index_version, маскирование ПДн при индексации	частично
Model	ADR-пакет, фиксация версии весов и checksum, эта Model Card	✓
Decision	Decision Log: request_hash · features (id чанков + скоры, без сырого текста) · prediction (ответ + источники + confidence) · model_version (git hash + prompt_version + index_version)	◆ к внедрению
Audit	append-only хранилище (MinIO с object lock), retention policy, воспроизведение решения по request_hash	✗ отсутствует — главный пробел

Условия обновления карточки: смена версии модели или квантования · изменение системного промпта · изменение схемы чанкинга или параметров ретрива · существенное расширение корпуса · любой результат аудита fairness. Версия карточки совпадает с git tag релиза — **карточка живёт в репозитории рядом с кодом, а не в вики.**

ЧАСТЬ 2. FINOPS — анализ перерасхода и план оптимизации

2.1. Ситуация: счёт вспомогательного контура

Продуктовый контур on-prem, но **dev/eval-площадка живёт в Yandex Cloud**: там прогоняются RAGAS-замеры, staging-сборки и эксперименты с моделями. Бюджет — **\$2 000/мес**. Пришёл счёт **\$3 006 (+50 %)**.

Статья	Факт, \$/мес	План, \$	Δ	Диагноз
GPU-инстансы (dev/eval, A100)	1 090	500	+590	подняты для eval-прогнозов, не выключаются ночью и в выходные ; средняя утилизация ~12 %
LLM API (Foundation Models, judge для RAGAS)	655	350	+305	LLM-судья и простые классификации гоняются на самой большой доступной модели ; прогоны на полном датасете при каждом коммите
Object Storage (трейсы Langfuse, чекпоинты, логи)	421	200	+221	всё лежит в стандартном тире, retention не задан , полные промпты и ответы хранятся бессрочно
Логи и мониторинг	385	300	+85	уровень DEBUG на staging, access-логи без сэмплинга
Managed PostgreSQL / Redis (dev)	180	180	0	в норме
Сеть / egress	150	120	+30	выгрузка артефактов на локальные машины без кэша
Прочее (диски, снапшоты, зомби-тома)	125	100	+25	orphaned volumes от удалённых стендов
Итого	3 006	1 750	+1 256	

2.2. Причины: три канонические утечки

Перерасход раскладывается ровно на три класса из урока 28 — ни одна из причин не является «дорогим провайдером»:

1. Overprovisioning и zombie-ресурсы (~\$615, 49 % перерасхода). GPU-инстансы работают 24/7, а реально нужны 3–4 часа в сутки под прогоны; плюс осиротевшие

диски от удалённых стэндов. Классический холостой ход: **платим за ожидание, а не за вычисления.**

2. Дорогие настройки по умолчанию (~\$306, 24 %). Трейсы и логи пишутся полностью, одинаково для всех запросов и хранятся вечно в самом дорогом тире. Это ровно тот случай, который в лекции по governance назван «Decision Log без TTL»: **комплаенс-требование реализовано максимально дорогим способом**, хотя аудиторская ценность лога через 90 дней несопоставима с его ценой.

3. Слишком «умная» модель для простых задач (~\$305, 24 %). LLM-судья RAGAS и вспомогательные классификации (определение языка, тематики, простые FAQ-вопросы) обслуживаются флагманской моделью через платный API, хотя качество этих подзадач не деградирует на модели меньшего размера — а часть вообще решается локально на уже оплаченном железе.

2.3. План Cost Optimization

#	Мера	Эффект, \$/мес	Срок внедрения
1	Расписание и Spot для GPU	–700	3 дня
2	TTL + стратификация логов	–300	2–3 дня
3	Model routing по сложности	–400	1–2 недели
4	Уборка зомби-ресурсов и сэмплинг логов	–110	1 день
5	Тегирование и бюджетные алерты	0 (условие остальных)	2 дня
6	Infracost в CI	предотвращение	1 день
	Итого	–1 510	

1. Расписание и Spot для GPU (–\$700). Auto-shutdown по расписанию (окно 20:00–08:00 и выходные) + перевод batch-eval на **preemptible/spot** с чекпоинтом каждые 10 минут; прогоны запускаются по триггеру пайплайна, а не держатся постоянно. *Риск*: прерывание spot-инстанса → снимается чекпоинтами и автоперезапуском; интерактивная отладка остаётся на on-demand.

2. TTL и стратификация логов (–\$300). Retention: горячий тир 14 дней → холодный 90 дней → удаление (кроме High-Risk). **Стратификация по риску**: обжалованные и чувствительные решения — полный лог; остальные — агрегаты (хэш запроса, id чанков, скоры, метрики) без сырого текста. *Риск*: потеря глубины ретроспективного анализа → снимается буфером полного лога 14 дней для **всех** решений с последующим прореживанием.

3. Model routing по сложности (–\$400). Классификатор сложности перед генерацией: FAQ и типовые вопросы → малая модель или extractive-ответ по цитате; сложные и агентные → Qwen3.5-27B. Отдельно: **LLM-судья RAGAS переносится с платного API на локальный контур** — железо уже оплачено. *Риск*: деградация качества → роутинг выкатывается канареечно с контролем faithfulness, порог переключения подбирается по golden set.

4. Уборка зомби-ресурсов и сэмплинг логов (–\$110). Lifecycle-политика для дисков и снапшотов, автоудаление orphaned volumes; DEBUG → INFO на staging, sampling 1/10 для healthcheck'ов. *Риск:* минимальный.

5. Тегирование и бюджетные алерты (0). Обязательные теги project / team / env / cost-center на всех ресурсах; алерт при прохождении 80 % бюджета. Прямой экономии не даёт, но **без тегов невозможны ни showback, ни rightsizing** — это фундамент остальных мер.

6. Infracost в CI (предотвращение). Дельта стоимости в merge request по плану OpenTofu, обязательное ревью при росте более \$50/мес. *Риск:* ложные срабатывания на легитимный рост → снимается порогом и требованием обоснования в MR.

Результат: \$3 006 → ~\$1 496/мес — это **–50 % к текущему счёту** и возврат в бюджет с запасом ~25 %. Цель задания (снижение расходов) перевыполнена, при этом ни одна мера не является «договориться о скидке» — все шесть архитектурные или процессные.

Матрица «импакт x сложность» (по методике урока 28):

- **Быстрые победы** (дни, высокий эффект): TTL и стратификация логов (–\$300 за 2–3 дня), расписание GPU (–\$700 за 3 дня), уборка зомби (–\$110 за день) — **закрывают 74 % экономии за первую неделю**;
- **Ключевой проект** (недели): model routing (–\$400, 1–2 недели) — требует классификатора и канареечной выкатки;
- **Инфраструктура дисциплины** (не экономит напрямую): тегирование и Infracost — без них экономия разъедется обратно за квартал.

Правило Парето подтверждается: **две меры (расписание GPU + TTL логов) дают 66 % всей экономии за неделю работы.**

2.4. Баланс цены и качества: что мы сознательно НЕ режем

Это ответ на критерий «зрелость» — граница, за которую оптимизация не идёт:

Не режем	Почему
Полноту логов по High-Risk решениям	обжалование по № 99-З требует воспроизвести решение; экономия здесь — прямой комплаенс-риск. TTL = max(требование аудита, экономическая целесообразность) , а не минимум по цене
Порог faithfulness и обязательность цитаты	дешёвая модель в роутинге допускается только там, где качество подтверждено golden set; при падении faithfulness > 5 п. роутинг откатывается
TTFT p95 ≤ 1,5 с	это UX-контракт с оператором КЦ: подсказка, приходящая позже реплики клиента, бесполезна независимо от цены
Генерацию ответа на малой модели	дистилляция и малые модели применяются к вспомогательным задачам (классификация, роутинг, судья), но не к формулированию ответа по ЛПА — цена ошибки в правовом ответе выше экономии
Резерв второй карты в проде	вторая H100 — HA-резерв и запас throughput; её «утилизация ради экономии» уничтожает отказоустойчивость

2.5. On-premise: где у нас на самом деле находится FinOps

Для продуктового контура облачные рычаги (spot, lifecycle-тиры, egress) не работают: CapEx уже потрачен, предельная стоимость одного лишнего запроса близка к нулю. Из уравнения $Cost = f(Architecture, Load, Efficiency)$ остаётся **Efficiency**, и метрика ровно одна — **утилизация GPU**.

Из нашего TCO-расчёта: ~\$194 000 за 3 года ≈ **\$65 000/год** амортизированно, лицензии \$0. Удельная цена:

Утилизация	Обслужено токенов/год	Удельная стоимость
25 %	~23,6 млрд	~\$2.75 / 1M токенов
50 % (текущее допущение)	~47 млрд	~\$1.40 / 1M токенов
75 %	~71 млрд	~\$0.92 / 1M токенов

Вывод, обратный облачной интуиции: on-prem экономия достигается не сокращением потребления, а **увеличением полезной загрузки** — перевод на общий инференс-контур второй плоскости (совместные сценарии, батчевые задачи ночью, внутренние eval-прогоны вместо платного API) снижает удельную цену вдвое, ничего не тратя дополнительно. Незагруженный CapEx — худшая модель владения; именно поэтому **утилизация GPU выносится на дашборд рядом с Golden Signals**.

Отсюда же меры 1 и 3 плана получают второе обоснование: перенос eval-судьи и ночных прогонов с платного облачного API на своё железо одновременно **сокращает облачный счёт и повышает утилизацию on-prem** — один шаг улучшает обе части экономики.

2.6. Sensitivity: что будет при росте нагрузки x3

Третий вопрос «золотого правила» из урока 28:

Статья	Поведение при x3	Комментарий
On-prem инференс	стоимость не растёт , удельная цена падает (~\$0.6–0.9 за 1M токенов)	пока хватает ёмкости 2x H100; при исчерпани- и — очередь и graceful degradation, а не автос- кейл (скейлить некуда)
Decision Log / трейсы	растут линейно и стано- вятся первой статьёй	без стратификации и TTL рост x3 съедает всю сего- дняшнюю экономию — ме- ра 2 обязательна именно как условие масштабиро- вания
Dev/eval-контур	растёт слабо (не зависит от продуктового трафика)	привязан к частоте рели- зов, а не к числу запросов
Обжалования и ручные проверки	растут линейно → нагруз- ка на людей	при x3 понадобится либо второй ответственный, ли- бо автоматизация первич- ного разбора

Вывод: бюджет при x3 не ломается, но профиль затрат меняет форму — доминирующей статьёй становится хранение аудиторских данных, а не вычисления. Это и есть аргумент, почему governance-часть и FinOps-часть в этом задании неразделимы: **этика создаёт данные, а данные создают счёт**.

Условие из ЛК

Цель: разработать Model Card для AI-системы и план оптимизации облачных затрат с анализом превышения бюджета.

Часть 1. Governance. Создайте «Model Card» для вашей системы: назначение модели и ограничения (Intended Use & Limitations); на каких данных обучалась (Bias analysis); метрики справедливости (Fairness).

Часть 2. FinOps. Вам пришёл счёт за облако, который превысил бюджет на 50 %. Проанализируйте типичные причины (забытые GPU-инстансы, неэффективное хранение логов, слишком «умная» модель для простых задач). Предложите план «Cost Optimization» (Spot Instances, Model Distillation, TTL для данных).

Формат сдачи: документ, содержащий Model Card и FinOps-отчёт с планом действий.

Критерии оценки (статус «Принято»): *Этика* — Model Card заполнен по стандарту, риски предвзятости осознаны; *Экономика* — предложены конкретные технические

меры снижения кустов (не просто «договориться о скидке»); *Зрелость* — понимание баланса между ценой и качеством.

Вспомогательные материалы: [Model Card](#) · [HuggingFace](#) · [Model Cards for Model Reporting \(arXiv:1810.03993\)](#) · [FinOps Framework](#).

Дедлайн: 27.08.2026 (на слайде лекции «06.05» — опечатка шаблона презентации).

Артефакты

-  [Zubik_DZ-30_finops-governance.pdf](#) — сборка через [scripts/md-to-pdf.sh](#)
-  Опора на пакет финального проекта: [ADR-0002 \(выбор модели\)](#), [ADR-0006 \(FP8 и sizing\)](#), [TCO](#), [MVP «Суфлёр»](#)

Сложности и решения

- **Model Card для чужой модели.** Стандарт Google/HuggingFace описывает обученную модель, а мы интегратор. Решено не подгонять форму, а разделить карточку на upstream-уровень (веса, где честно зафиксировано «не можем измерить») и system-уровень (ретрив, промпт, guardrails) — там, где находится наш реальный вклад в качество и предвзятость.
- **Fairness без защищённых признаков.** Система не знает демографии, поэтому demographic parity неприменим. Переопределил справедливость как равное качество обслуживания по ролям, подразделениям, темам и стилю формулировки — с отдельной тонкостью: отказы, вызванные RBAC, исключаются из метрики покрытия, иначе метрика штрафует за корректную работу разграничения доступа.
- **Незаполненные метрики.** Соблазн проставить правдоподобные цифры был, но карточка — документ для аудитора: неизмеренная метрика с честным статусом полезнее выдуманной. Пороги зафиксированы до замеров, замеры — первый пункт плана.
- **FinOps без облачного счёта.** Продуктовый контур on-prem, счёта нет. Разделил задачу на два горизонта: облачный dev/eval-контур (там разбирается сценарий +50 %) и on-prem, где FinOps сводится не к сокращению трат, а к росту утилизации — и удельная цена токена падает с \$2.75 до \$0.92 при загрузке с 25 % до 75 %.
- **Стык двух частей.** Изначально казались разными темами, но сошлись в одной точке: decision log, требуемый governance, — это и есть самая быстрорастущая статья счёта. Отсюда сквозной тезис работы: **этика создаёт данные, а данные создают счёт**, и TTL задаётся как максимум из требования аудита и экономики, а не как минимум по цене.

Обратная связь от преподавателя

(после проверки)