

Мультиагентная платформа цифровых корпоративных сотрудников

Защищённая платформа анализа корпоративных знаний с графовыми подходами

Александр Зубик · AI Architect · ООО «АртКлауд»


Выпускной проект OTUS AI Architect · сентябрь 2026

Задача из ТЗ и её приёмка


MVP конвейера извлечения знаний из неструктурированных данных **в закрытом контуре**: галлюцинации и потеря контекста → **GraphRAG**; разграничение доступа → **Security-by-Design**.

Критерий ТЗ	Статус
Облачные API не используются	✅ граница контура — правами ключа, до вызова
Диаграммы Deployment и Data Flow	✅ обе — следующие слайды
Реализация GraphRAG (не просто вектор)	✅ + контрольный замер без графа
«Пользователь В» не получает закрытый документ	✅ проверяется контекст модели , не текст ответа
Control Plane / Data Plane	✅ в диаграммах и в коде
State machine, а не линейные скрипты	✅ цикл, ветвление, лимиты, checkpointer
Streaming · тесты на промпты	✅ SSE · golden set с гейтами


С4 · Контейнеры: Control Plane / Data Plane



Deployment · где это физически живёт



Data Flow · где поток решает про безопасность



Четыре решения о доступе — и все четыре **до** того, как данные куда-то уйдут.


Ради чего нужен граф

Вопрос: «Сколько дней основной ежегодный отпуск?»

- ЛПА-01 § 1: «**28** календарных дней» ← это находит вектор
- ЛПА-04 § 1: «с 1 апреля — **30** дней, пункт 1 ЛПА-01 **отменяется**»

(:Документ) – [:СОДЕРЖИТ] → (:Чанк) (:Чанк) – [:ОТМЕНЯЕТ] → (:Чанк)
(:Чанк) – [:ССЫЛАЕТСЯ_НА] → (:Документ) (:Чанк | :Документ) – [:ДОСТУПЕН_РОЛИ] → (:Роль)

Куда вставлен граф



Доказательство: граф не декорация

Контрольный замер. Тест `test_graph_disabled_loses_the_annotation`: выключаем граф — пометка об отмене исчезает.

граф ВКЛЮЧЁН	ЛПА-01 § 1 · пометка: отменён документом ЛПА-04
граф ВЫКЛЮЧЕН	ЛПА-01 § 1 · пометок нет → «28 дней» вместо 30

Метрика в проде: доля ответов со сработавшим ребром `ОТМЕНЯЕТ`. Ноль = граф не работает, как бы хорошо он ни выглядел на демо.

Оговорка: гарантия покрывает только отмены, **известные корпусу**.

Security: критерий «пользователь В»

Один вопрос, две роли. ЛПА-03 «Регламент доступа к ПДн» закрыт (acl: legal, security).

роль all

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-02.3 ЛПА-04.2 ЛПА-01
ЛПА-03 в выдаче: НЕТ

роль legal

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-03.2 ЛПА-03.4 ЛПА-03
ЛПА-03 в выдаче: ДА

Предикат доступа стоит **на каждом узле обхода**, а не на финальной выдаче: иначе закрытый документ утекает через **структуру** — факт существования, название, соседей.

Нарушений ACL на golden set: 0. Тест проходит на обоих путях — одиночном и агентном; мандат роли-агента $\subseteq$ прав пользователя.

Мультиагентный слой: state machine и честный замер

4 роли · маршрутизация **правилами** · лимиты шагов, инструментов и токенов · checkpointer по request_id

Права агента = права пользователя n мандат роли — пересечение считается в инструменте, а не в промпте.

ADR-0015 требовал измерить	Результат
Точность маршрутизации	13 / 13
Прирост качества против монолита	нет (recall 1,0 = 1,0)
Стоимость	×3,7 латентности

Замеры: где время и где деньги

Шаг ответа ask	Qwen3.6 · 12.09	Qwen3.8 · 25.09
Генерация · своя модель	1 611 мс	1 933 мс (+20 %)
Реранк (CPU стенда)	708 мс	1 423 мс
Обход графа	5,5 мс	12 мс · 0,35 %

Смена модели — +322 мс на ответ: плотная 27В быстрее печатает, но дольше до первого токена (1,31 с против 0,59), а у RAG длинный промпт и короткий ответ.

Реранк отдан сервису платформы (ADR-0027): ask на 8 клиентах — **1,79 → 11,03 RPS**, 4 369 → 719 мс. Главное не х6, а характер насыщения: было +36 % на восьмикратном росте клиентов, стало +107 %.

Железо **арендовано** — 1 200 BYN/мес, всё включено. **ТСО ≈ \$29,4k / 3 года**, три четверти — ФОТ. Порог окупаемости против вендора — **~70 % утилизации** (Qwen3.8, потолок 24 запроса; до смены модели — 31 %).

Утилизация измерена за 30 дней: 0,9 %. Фактическая цена 1М выходных токенов — **\$142**, а не \$1,41. На этом трафике контур не окупается по цене токена: покупается юрисдикция.

Своя модель в проде: цифры и рычаги

Реальный трафик ZubrlQ, Qwen3.8, 21–25.09 — метрики vLLM и шлюза, без синтетики.

Первый токен	Вызов модели	Генерация	Кеш шлюза (чат)	Prefix-кеш	Шлюз
1,6 с · p95 9 с	2,3 с	29 ток/с	87 % без GPU	90 %	3 мс

Кто грузит модель: сканер Shield — 57 % вызовов и ~60 % времени модели; чат из-за кеша — лишь 733 вызова из 5 655 запросов. У чата хвост первого токена **18 с** при медиане 1,5.

Рычаг	Эффект
Приоритет чату над Shield в vLLM	хвост первого токена у людей
Shield — вне пиков	до –60 % времени модели в часы людей
Короче контекст RAG	prefill у Qwen3.8 на 16 % медленнее
max_num_seqs 24 → 96	в работе максимум 8 — не рычаг
Перенос на сервис	сервис теперь на CPU: 1,4 → 3,8 с

Итог

108 тестов · 28 ADR · 9 диаграмм · 6 отчётов с цифрами · 3 518 строк кода

Своя дообученная модель `Zubr-VL-32B` (QLoRA на праве РБ, 757 НПА) опубликована; 97,6 % фрагментов корпуса встречаются ровно один раз. **Граф проверен на боевом корпусе:** 25 кодексов, 7 284 статьи.

Четыре отрицательных результата оставлены как есть: мультиагентный слой не дал прироста · чужая цифра, взятая без проверки · рекомендация собственного отчёта оказалась не той · утилизация 0,9 % обесценила посчитанный порог окупаемости.

Чего нет: граф и агентный слой **не встроены** в платформу (собраны, протестированы) · red teaming описан, не применялся · видео-демо: терминальная часть записана, браузерные кадры нет.

Главный урок: архитектура, не подтверждённая замером, — это гипотеза.

Вопросы? Демонстрация: граф в браузере · трейс по `request_id` · дашборд · потоковый ответ.