

Мультиагентная платформа цифровых корпоративных сотрудников

Защищённая платформа анализа корпоративных знаний с графовыми подходами

Александр Зубик · AI Architect · ООО «АртКлауд»


Выпускной проект OTUS AI Architect · сентябрь 2026

Задача из ТЗ и её приёмка


MVP конвейера извлечения знаний из неструктурированных данных **в закрытом контуре**: галлюцинации и потеря контекста → **GraphRAG**; разграничение доступа → **Security-by-Design**.

Критерий ТЗ	Статус
Облачные API не используются	✓ граница контура — правами ключа, до вызова
Диаграммы Deployment и Data Flow	✓ обе — следующие слайды
Реализация GraphRAG (не просто вектор)	✓ + контрольный замер без графа
«Пользователь В» не получает закрытый документ	✓ проверяется контекст модели , не текст ответа
Control Plane / Data Plane	✓ в диаграммах и в коде
State machine, а не линейные скрипты	✓ цикл, ветвление, лимиты, checkpointer
Streaming · тесты на промпты	✓ SSE · golden set с гейтами


С4 · Контейнеры: Control Plane / Data Plane



Deployment · где это физически живёт



Data Flow · где поток решает про безопасность



Четыре решения о доступе — и все четыре **до** того, как данные куда-то уйдут.

Ради чего нужен граф

Вопрос: «Сколько дней основной ежегодный отпуск?»

- ЛПА-01 § 1: «**28** календарных дней» ← это находит вектор
- ЛПА-04 § 1: «с 1 апреля — **30** дней, пункт 1 ЛПА-01 **отменяется**»

```
( :Документ ) - [ :СОДЕРЖИТ ] -> ( :Чанк )      ( :Чанк ) - [ :ОТМЕНЯЕТ ] -> ( :Чанк )  
( :Чанк ) - [ :ССЫЛАЕТСЯ_НА ] -> ( :Документ )  ( :Чанк | :Документ ) - [ :ДОСТУПЕН_РОЛИ ] -> ( :Роль )
```

Retrieval: **вектор → обход 1–2 хопа → rerank**. Отмены попадают в контекст **безусловно**, вне конкуренции за места в top-k.

Доказательство: граф не декорация

Контрольный замер. Тест `test_graph_disabled_loses_the_annotation`: выключаем граф — пометка об отмене исчезает.

граф ВКЛЮЧЁН ЛПА-01 § 1 · пометка: отменён документом ЛПА-04
граф ВЫКЛЮЧЕН ЛПА-01 § 1 · пометок нет → «28 дней» вместо 30

Метрика в проде: доля ответов со сработавшим ребром `ОТМЕНЯЕТ`. Ноль = граф не работает, как бы хорошо он ни выглядел на демо.

Оговорка: гарантия покрывает только отмены, **известные корпусу**.

Security: критерий «пользователь В»

Один вопрос, две роли. ЛПА-03 «Регламент доступа к ПДн» закрыт (acl: legal, security).

роль all

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-02.3 ЛПА-04.2 ЛПА-01

ЛПА-03 в выдаче: НЕТ

роль legal

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-03.2 ЛПА-03.4 ЛПА-03

ЛПА-03 в выдаче: ДА

Предикат доступа стоит **на каждом узле обхода**, а не на финальной выдаче: иначе закрытый документ утекает через **структуру** — факт существования, название, соседей.

Нарушений ACL на golden set: 0. Тест проходит на обоих путях — одиночном и агентном; мандат роли-агента $\subseteq$ прав пользователя.

Мультиагентный слой: state machine и честный замер

4 роли · маршрутизация **правилами** · лимиты шагов, инструментов и токенов · checkpointer по request_id

Права агента = права пользователя $\cap$ мандат роли — пересечение считается в инструменте, а не в промпте.

ADR-0015 требовал измерить	Результат
Точность маршрутизации	13 / 13
Прирост качества против монолита	нет (recall 1,0 = 1,0)
Стоимость	×3,7 латентности

Замеры: где время и где деньги

Шаг ответа	Доля
Генерация · своя модель	68 %
Реранк	30 %
Обход графа	0,3 %

Реранк отдан сервису платформы (ADR-0027): ask на 8 клиентах — **1,79 → 11,03 RPS**, 4 369 → 719 мс. Главное не ×6, а характер насыщения: было +36 % на восьмикратном росте клиентов, стало +107 %.

ТСО закрытого контура ≈ **\$42,5k / 3 года**. Цена 1М токенов: **\$0,89** при утилизации 100 % и **\$17,78** при 5 %.

Итог

103 теста · 28 ADR · 9 диаграмм · 5 отчётов с цифрами · 3 518 строк кода

Три отрицательных результата оставлены как есть: мультиагентный слой не дал прироста · чужая цифра, взятая без проверки · рекомендация собственного отчёта оказалась не той.

Чего нет: граф и агентный слой **не встроены** в платформу (собраны, протестированы) · red teaming описан, не применялся · утилизация инференса не измерена.

Главный урок: архитектура, не подтверждённая замером, — это гипотеза.

Вопросы? Демонстрация: граф в браузере · трейс по `request_id` · дашборд · потоковый ответ.