

# Мультиагентная платформа цифровых корпоративных сотрудников

Защищённая платформа анализа корпоративных знаний с графовыми подходами

Александр Зубик · AI Architect · ООО «АртКлауд»


Выпускной проект OTUS AI Architect · сентябрь 2026

# Задача из ТЗ и её приёмка


MVP конвейера извлечения знаний из неструктурированных данных **в закрытом контуре**: галлюцинации и потеря контекста → **GraphRAG**; разграничение доступа → **Security-by-Design**.

| Критерий ТЗ                                           | Статус                                                 |
|-------------------------------------------------------|--------------------------------------------------------|
| Облачные API не используются                          | ✓ граница контура — правами ключа, до вызова           |
| Диаграммы Deployment и Data Flow                      | ✓ обе — следующие слайды                               |
| <b>Реализация GraphRAG</b> (не просто вектор)         | ✓ + контрольный замер без графа                        |
| <b>«Пользователь В» не получает закрытый документ</b> | ✓ проверяется <b>контекст модели</b> , не текст ответа |
| <b>Control Plane / Data Plane</b>                     | ✓ в диаграммах и в коде                                |
| <b>State machine, а не линейные скрипты</b>           | ✓ цикл, ветвление, лимиты, checkpointer                |
| Streaming · тесты на промпты                          | ✓ SSE · golden set с гейтами                           |


# С4 · Контейнеры: Control Plane / Data Plane



# Deployment · где это физически живёт



# Data Flow · где поток решает про безопасность



Четыре решения о доступе — и все четыре **до** того, как данные куда-то уйдут.

# Ради чего нужен граф


---

Вопрос: «Сколько дней основной ежегодный отпуск?»

- ЛПА-01 § 1: «**28** календарных дней» ← это находит вектор
- ЛПА-04 § 1: «с 1 апреля — **30** дней, пункт 1 ЛПА-01 **отменяется**»

```
( :Документ ) - [ :СОДЕРЖИТ ] -> ( :Чанк )      ( :Чанк ) - [ :ОТМЕНЯЕТ ] -> ( :Чанк )  
( :Чанк ) - [ :ССЫЛАЕТСЯ_НА ] -> ( :Документ )  ( :Чанк | :Документ ) - [ :ДОСТУПЕН_РОЛИ ] -> ( :Роль )
```

# Куда вставлен граф



# Доказательство: граф не декорация

**Контрольный замер.** Тест `test_graph_disabled_loses_the_annotation`: выключаем граф — пометка об отмене исчезает.

граф ВКЛЮЧЁН      ЛПА-01 § 1 · пометка: отменён документом ЛПА-04  
граф ВЫКЛЮЧЕН    ЛПА-01 § 1 · пометок нет    → «28 дней» вместо 30

**Метрика в проде:** доля ответов со сработавшим ребром `ОТМЕНЯЕТ`. Ноль = граф не работает, как бы хорошо он ни выглядел на демо.

Оговорка: гарантия покрывает только отмены, **известные корпусу**.

# Security: критерий «пользователь В»

Один вопрос, две роли. ЛПА-03 «Регламент доступа к ПДн» закрыт (acl: legal, security).

роль all

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-02.3 ЛПА-04.2 ЛПА-01  
ЛПА-03 в выдаче: НЕТ

роль legal

→ ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-03.2 ЛПА-03.4 ЛПА-03  
ЛПА-03 в выдаче: ДА

Предикат доступа стоит **на каждом узле обхода**, а не на финальной выдаче: иначе закрытый документ утекает через **структуру** — факт существования, название, соседей.

**Нарушений ACL на golden set: 0.** Тест проходит на обоих путях — одиночном и агентном; мандат роли-агента  $\subseteq$  прав пользователя.

# Мультиагентный слой: state machine и честный замер

4 роли · маршрутизация **правилами** · лимиты шагов, инструментов и токенов · checkpointer по `request_id`

**Права агента = права пользователя  $\cap$  мандат роли** — пересечение считается в инструменте, а не в промпте.

| ADR-0015 требовал измерить       | Результат                     |
|----------------------------------|-------------------------------|
| Точность маршрутизации           | <b>13 / 13</b>                |
| Прирост качества против монолита | <b>нет</b> (recall 1,0 = 1,0) |
| Стоимость                        | <b>×3,7</b> латентности       |

# Замеры: где время и где деньги

| Шаг ответа              | Доля  |
|-------------------------|-------|
| Генерация · своя модель | 68 %  |
| Реранк                  | 30 %  |
| Обход графа             | 0,3 % |

**Реранк отдан сервису платформы** (ADR-0027): ask на 8 клиентах — **1,79 → 11,03 RPS**, 4 369 → 719 мс. Главное не ×6, а характер насыщения: было +36 % на восьмикратном росте клиентов, стало +107 %.

Железо **арендовано** — 1 200 BYN/мес, всё включено. **TCO ≈ \$29,4k / 3 года**, три четверти — ФОТ. Порог окупаемости против вендора — **31 % утилизации**.

**Утилизация измерена за 30 дней: 0,9 %**. Фактическая цена 1М выходных токенов — **\$142**, а не \$0,61. На этом трафике контур не окупается по цене токена: покупается юрисдикция.

# Итог

---

103 теста · 28 ADR · 9 диаграмм · 5 отчётов с цифрами · 3 518 строк кода

**Четыре отрицательных результата оставлены как есть:** мультиагентный слой не дал прироста · чужая цифра, взятая без проверки · рекомендация собственного отчёта оказалась не той · утилизация 0,9 % обесценила посчитанный порог окупаемости.

**Чего нет:** граф и агентный слой **не встроены** в платформу (собраны, протестированы) · red teaming описан, не применялся · видео-демо: терминальная часть записана, браузерные кадры нет.

**Главный урок: архитектура, не подтверждённая замером, — это гипотеза.**

**Вопросы?** Демонстрация: граф в браузере · трейс по `request_id` · дашборд · потоковый ответ.