

Мультиагентная платформа цифровых корпоративных сотрудников

Защищённая платформа мультимодального анализа корпоративных знаний с использованием графовых подходов

Александр Зубик · AI Architect · ООО «АртКлауд»

Выпускной проект OTUS AI Architect · сентябрь 2026

О себе

- Архитектор и инженер, ООО «АртКлауд», Минск
- Строю **on-prem AI-платформы** для организаций в контуре РБ
- В проде: `zubriq.by` — платформа доступа к моделям, биллинг в BYN
- Публичная копия решения, которое делается для банка
- Своя дообученная модель на праве РБ (QLoRA, опубликована на HF)

Задача из ТЗ

Спроектировать и реализовать **MVP производственного конвейера** извлечения знаний из **неструктурированных данных** в закрытом контуре.

Две проблемы, которые обязана решить архитектура:

Проблема	Ответ ТЗ
Галлюцинации и потеря контекста	GraphRAG — нейро-символический подход
Разграничение доступа	Security-by-Design на уровне чанков и узлов графа

Роль: Platform Engineer & AI Architect. Контур: **on-premise, air-gapped**, без внешних API.

Почему вообще on-prem

- Юрисдикция **Республики Беларусь**, санкции → облачные LLM недоступны
- **Закон РБ № 99-3** о персональных данных → данные не покидают периметр
- Коммерческая тайна в тех же документах
- Требование ТЗ: **нулевой egress** к внешним LLM

Решение принято **не по цене**. TCO обосновывает CapEx, а не выбирает между опциями: SaaS здесь просто недоступен.

Цель и задачи

Цель: безопасный корпоративный AI-ассистент, работающий полностью в контуре.


Задачи:

1. Ядро **GraphRAG** — граф связей документов, обход с учётом прав
2. **Security-by-Design** — права на уровне узлов графа, а не выдачи
3. **Мультиагентный слой** — роли-агенты со своими правами
4. **Наблюдаемость** — трейс по шагам, метрики качества графа
5. **Доказать замераами**, а не декларациями


Критерии приёмки ТЗ

Критерий	Статус
Облачные API не используются	✓ ADR-0001, весь стек self-hosted
Диаграммы Deployment и Data Flow	✓ обе есть
Реализация GraphRAG (не просто вектор)	✓ + контрольный замер без графа
Security: User B не получает закрытый документ	✓ автотест, проверяется контекст LLM
Control Plane / Data Plane разделены	✓ в C4 и в реализации
State machine, а не линейные скрипты	✓ LangGraph: цикл, ветвление, лимиты
Streaming (желательно)	✓ SSE
Тесты на промпты (желательно)	✓ golden set с гейтами

С4 · Контекст



С4 · Контейнеры и разделение плоскостей



Проблема, ради которой нужен граф

Вопрос: «Сколько дней основной ежегодный отпуск?»

- ЛПА-01 § 1: «28 календарных дней» ← вектор находит это
- ЛПА-04 § 1: «с 1 апреля — 30 дней, пункт 1 ЛПА-01 отменяется»

Отменяющий документ **текстуально похож на десятки других**. Гарантии попадания в top-k нет.

Сотрудник получает отменённую норму. Без единой оговорки. С цитатой.

Ответ: онтология из 4 типов узлов

```
( :Документ ) - [ :СОДЕРЖИТ ] -> ( :Чанк )  
( :Чанк ) - [ :ОТМЕНЯЕТ ] -> ( :Чанк )  
( :Чанк ) - [ :ССЫЛАЕТСЯ_НА ] -> ( :Документ )  
( :Чанк | :Документ ) - [ :ДОСТУПЕН_РОЛИ ] -> ( :Роль )
```

Retrieval: **vector-first** → **обход 1–2 хоп** → **rerank**

Отмены попадают в контекст **безусловно**, вне конкуренции за места: модификатор может быть непохож на вопрос, но именно он делает ответ верным.

Доказательство, что граф не декорация

\$ SUFLER_GRAPH=1

⚠ ЛПА-01 «Продолжительность
отпуска» отменён ЛПА-04


\$ SUFLER_GRAPH=0

(пометки нет)

- Тест `test_cancelled_clause_is_flagged` — пометка есть
- Тест `test_graph_disabled_loses_the_annotation` — **контрольный замер**: выключаем граф, пометка исчезает

Метрика в проде: доля ответов со сработавшим ребром **ОТМЕНЯЕТ**. **Ноль = граф не работает**, как бы хорошо он ни выглядел на демо.

Security: ACL на каждом узле обхода



Предикат стоит **на каждом узле пути**, а не на финальной выдаче.

Иначе закрытый документ утекает через **структуру**: сам факт существования, название, соседей.

Следствие: **факт отмены не раскрывается**, если отменяющий документ недоступен субъекту.

Security: границу доверия держит подпись

Было: роли приходили **в теле запроса**.


```
{"question": "...", "roles": ["legal"]}
```

 ← клиент объявлял сам

Стало: роли **только из подписанного JWT** (JWKS Keycloak), тело на доступ не влияет вообще.

- Фиксированный список асимметричных алгоритмов → подмена **RS256→HS256** и **alg:none** отсекаются
- Проверка **exp**, **aud**, **iss**; кэш ключей с TTL
- 18 тестов, подделка собирается побайтово

Мультиагентный слой: state machine



- 4 роли: Кадровик, Юрист, Инженер, Комплаенс
- Маршрутизация **правилами**, LLM — только на промахах
- Лимиты шагов, инструментов, токенов → явная деградация
- `thread_id` = `request_id` в checkpointer

Права агента = права пользователя $\cap$ мандат роли, и пересечение считается в инструменте, а не в промпте.

MAS: и честный результат замера

ADR-0015 требовал перед `accepted` измерить три вещи. Измерил все три:

Что	Результат
Точность маршрутизации	13 / 13
Прирост качества против монолита	нет (recall 1,0 = 1,0)
Стоимость	×2,6 латентности, накладные расходы 0,8 %

ADR обязывал: «если иерархия не даст прироста — честно зафиксировать в защите». **Фиксирую: не дала.**

Слой оправдан требованием ТЗ и **разделением прав**, но не качеством ответов.

Инфраструктура: что поднимается и зачем

Сервис	Роль	ADR
vLLM	инференс, FP8 на 2× H100 NVL	0003, 0006
Neo4j	граф ЛПА, обход с ACL	0012, 0013
Qdrant	dense-поиск, payload-фильтр по ролям	0004
PostgreSQL	checkpointer LangGraph, журнал доступа	0015, 0016
Keycloak	JWKS, группы → права	0016
OTel + Jaeger	трейсы по шагам	0017
VictoriaMetrics + Grafana	метрики, дашборд GraphRAG	0017

`docker compose --profile core --profile obs up -d` — весь стек, **проверено**: backend в контейнере, граф в Neo4j, трейсы в Jaeger, панели отвечают данными.

Наблюдаемость: request_id открывает трейс

request_id — это uuid4().hex, ровно 128 бит trace_id OpenTelemetry. Поэтому он не прокидывается атрибутом, а **становится** идентификатором трейса.

ask	868 мс	{outcome: ok, sources: 5, graph_contribution: true, cancellation_flagged: true}
retrieve.embed	188 мс	
retrieve.rerank	664 мс	{candidates: 14}
graph.expand	8,7 мс	{backend: neo4j, hops: 2}
graph.annotate	2,3 мс	

На защите это один жест: значение из ответа → поиск в Jaeger → разложение по шагам.

Содержимое запроса в трейс **не попадает**: Jaeger доступен шире, чем сами документы.

Нагрузочный отчёт: где узкое место

Шаг	Время	Доля
cross-encoder rerank	664 мс	76 %
эмбединг запроса	188 мс	22 %
обход графа	11 мс	~1 %
поиск в Qdrant	2,8 мс	0,3 %

- RPS **не растёт** с параллелизмом: 1,53 → 1,88 при росте латентности ×12,7
- Закон Литтла сходится на всех ступенях → очередь чисто накопительная
- Ёмкость реплики по SLO: **4 клиента**, и это **без генерации**

Качество: golden set и гейты приёмки

14 кейсов, метрики считаются **без LLM** — объективно и воспроизводимо.

Метрика	Значение	Гейт
Context recall	1,0	$\geq 0,85$ ✓
Нарушений ACL	0	$= 0$ ✓
Пометка об отмене	1,0	$= 1,0$ ✓
Честный отказ вне корпуса	1,0	—
Точность маршрутизации	13/13	$\geq 0,9$ ✓

Прогон возвращает код 1 при провале → **готовый шаг CI**.

Что нашли замеры (и чего не находили тесты)

Найдено	Было бы в проде
Обход в Neo4j не набирал глубину	цепочка отмен обрывалась на первом звене
В Cypher не было одного направления ребра	от отменяющего пункта не виден отменённый
Система отвечала на любой вопрос	ответ про спутники со ссылками на отпуск
Текст отказа выдавал существование закрытого документа	утечка через факт существования
Тест портил ACL в живой базе	демонстрация отмены ломалась молча

Порог отказа поставлен на **косинус эмбеддера**: логиты реранкера не разделяют вовсе — «что приготовить из курицы» набирает больше, чем вопрос про ПДн.

Честно: чего сейчас нет

Не сделано	Почему
Мультимодальный ingestion	спроектирован (ADR-0014), VL-ступень не реализована
Faithfulness / RAGAS	нужен GPU; судья обязан отличаться от отвечающей модели
Langfuse-экспорт	трейсы уходят только в Jaeger
Прогон JWT против живого Keycloak	проверено на сгенерированных ключах
Отзыв токена до <code>exp</code>	интроспекции нет, окно = время жизни токена
Алерты с runbook'ами	ADR-0017 требует runbook — его нет
Red teaming по методике занятия 33	методика описана, к системе не применялась
Soak-тест, DR-прогон	не проверялись

Дорожная карта

Ближайшее — закрывает названные дыры

1. Реранк на ONNX и в отдельный пул — 76 % латентности в одном компоненте
2. Кэш L1/L2 — при 60 % повторов убирает весь путь 0,65–1,15 с
3. Langfuse + RAGAS → faithfulness как метрика, а не как обещание
4. Алерты с runbook'ами; интроспекция токена

Следующее — расширяет возможности

5. Мультимодальный ingestion: layout → OCR → VL, провенанс на чанке
6. Golden set на вопросах **операторов**, а не автора системы
7. Проверка гипотезы MAS на большом разнородном корпусе
8. Red teaming в CI с ASR-гейтом

Экономика: TCO на 3 года

	Оценка, USD
CapEx: сервер + 2× H100 NVL + обвязка	~110 000
OpEx × 3 года (электричество, поддержка, 0,5 FTE)	~84 000
TCO (3 года)	~194 000
В пересчёте на год	~65 000

В OpEx доминирует персонал, а не электричество.

Сравнение с SaaS приведено как контекст, а не как выбор: из РБ он недоступен.

Технологии и впечатление от них

Технология	Впечатление
Neo4j	ожидал сложности — оказалась дешёвой: обход 8 мс. Дорого не считать, дорого синхронизировать граф с корпусом
LangGraph	даёт состояние и лимиты из коробки; цена — контекст не переживает <code>yield</code> , поймал на streaming
vLLM	предсказуем; всё интересное — в sizing, а не в запуске
OpenTelemetry	окупился в первый же день: разложение по шагам ответило на вопрос о латентности
cross-encoder	ранжирует хорошо, порог ставить нельзя — оценки не калиброваны

Выводы

- **Цель достигнута:** все четыре критичных требования ТЗ закрыты и подтверждены тестами
- **Легко далось:** документация, ADR, граф — опыт и готовые инструменты
- **Трудно далось:** честные замеры. Каждый прогон находил то, чего не видели тесты
- **Время:** проектная часть $\approx$ 3 недели, реализация и замеры $\approx$ неделя
- **Полезность курса: 9 / 10** — методики уроков 13–24 использованы напрямую
- **Главный урок:** архитектура, не подтверждённая замером, — это гипотеза

75 тестов, 3 отчёта с цифрами, 18 ADR, один честно зафиксированный отрицательный результат.

Спасибо

Вопросы?

- Репозиторий: `final-project/` — код, ADR, диаграммы, отчёты
- Демо: граф в Neo4j Browser, трейс в Jaeger, дашборд Grafana, живой SSE
- Отчёты: нагрузочный, golden set, экономика

Александр Зубик · AI Architect