

# Мультиагентная платформа цифровых корпоративных сотрудников

Защищённая платформа анализа корпоративных знаний с графовыми подходами

Александр Зубик · AI Architect · ООО «АртКлауд»

Выпускной проект OTUS AI Architect · сентябрь 2026

## Что защищаю



# Задача из ТЗ

Спроектировать и реализовать **MVP конвейера извлечения знаний из неструктурированных данных** в закрытом контуре.

| Проблема                               | Ответ ТЗ                                                 |
|----------------------------------------|----------------------------------------------------------|
| Галлюцинации и <b>потеря контекста</b> | <b>GraphRAG</b> — нейро-символический подход             |
| Разграничение доступа                  | <b>Security-by-Design</b> на уровне чанков и узлов графа |

Роль: Platform Engineer & AI Architect.

# Предмет проекта — закрытый контур

---

Платформа **гибридная**: рядом с закрытым контуром есть коммерческий режим доступа к проприетарным моделям через одного агрегатора.

**Предмет выпускного проекта — закрытый контур**: свои модели на своём инференсе, нулевой egress.

Критерий ТЗ «не принято, если используются облачные API» выполняется **физически**: внешние модели отсекаются правами ключа, проверка стоит до обращения к вендору.

# Цель и задачи

---

**Цель:** безопасный корпоративный ассистент, работающий полностью в контуре.

1. **GraphRAG** — граф связей документов, обход с учётом прав
2. **Security-by-Design** — права на уровне узлов, а не выдачи
3. **Мультиагентный слой** — роли-агенты со своими правами
4. **Наблюдаемость** — трейс по шагам, метрики пользы графа
5. **Доказать замерами**, а не декларациями

# Критерии приёмки ТЗ

| Критерий                                         | Статус                                             |
|--------------------------------------------------|----------------------------------------------------|
| Облачные API не используются                     | ✓ предмет — закрытый контур, граница правами ключа |
| Диаграммы Deployment и Data Flow                 | ✓ обе есть                                         |
| Реализация GraphRAG (не просто вектор)           | ✓ + контрольный замер без графа                    |
| Security: «User B» не получает закрытый документ | ✓ проверяется контекст модели, не только ответ     |
| Control Plane / Data Plane                       | ✓ в диаграммах и в коде                            |
| State machine, а не линейные скрипты             | ✓ цикл, ветвление, лимиты, checkpointer            |
| Streaming · тесты на промпты                     | ✓ SSE · golden set с гейтами                       |

# Стек: что взято и какое впечатление


| Слой          | Чем                          | Впечатление после работы                                                                 |
|---------------|------------------------------|------------------------------------------------------------------------------------------|
| Инференс      | vLLM, dense 27B в AWQ-INT4   | <b>Оправдал.</b> Нативно из systemd, без контейнера — иначе VRAM не контролируется       |
| Оркестрация   | LangGraph                    | <b>Спорно.</b> State machine нужна, но прироста качества не дала — <a href="#">замер</a> |
| Ранжирование  | bge-reranker-v2-m3           | <b>Лучшее решение проекта.</b> Свою модель надо было не ускорять, а убрать               |
| Граф          | рекурсивные CTE в PostgreSQL | <b>Пересмотрено по замеру.</b> Neo4j выразительнее, но это вторая СУБД                   |
| Наблюдаемость | OpenTelemetry                | <b>Окупилась трижды.</b> Все три узких места нашлись в разложении по спанам              |
| Права         | Keycloak, группы в токене    | <b>Без оговорок.</b> Роли из подписи — единственный вариант, остальное самообман         |

Общее впечатление: **дорогим оказался не выбор компонентов, а проверка того, что они делают то, что обещают.**


# С4 · Контекст



# С4 · Контейнеры




# Deployment · где это физически живёт




**Инференс в кластер не переносится.** Карты в боксе, движок нативно — ради контроля над видеопамятью; кластер обращается к нему как к внешнему эндпоинту.

# Data Flow · где поток решает про безопасность



Четыре решения о доступе — и все четыре **до** того, как данные куда-то уйдут.

# Sequence · путь запроса целиком




Требование ТЗ — User → Guardrails → Rerank → Agent Loop → Tool → Response. В реальной системе перед ЭТИМ СТОЯТ **два шага безопасности**: подпись и граница контура.

# Ingestion · как знания попадают в контур



**Права материализуются при загрузке, а не вычисляются при запросе** — иначе проверка превращается в фильтр поверх выдачи, а он протекает через структуру.

# ER · модель данных



Права лежат **и на документе, и на чанке**: предикат обязан работать на обоих путях — векторном фильтре и обходе графа.

# Проблема, ради которой нужен граф

---

Вопрос: «Сколько дней основной ежегодный отпуск?»

- ЛПА-01 § 1: «**28** календарных дней» ← это находит вектор
- ЛПА-04 § 1: «с 1 апреля — **30** дней, пункт 1 ЛПА-01 отменяется»

Отменяющий документ текстуально похож на десятки других. Гарантии попадания в top-k нет.

Сотрудник получает отменённую норму. Без оговорки. С цитатой.

# Ответ: граф связей ЛПА

---

```
( :Документ ) – [ :СОДЕРЖИТ ] –> ( :Чанк )  
( :Чанк ) – [ :ОТМЕНЯЕТ ] –> ( :Чанк )  
( :Чанк ) – [ :ССЫЛАЕТСЯ_НА ] –> ( :Документ )  
( :Чанк | :Документ ) – [ :ДОСТУПЕН_РОЛИ ] –> ( :Роль )
```

Retrieval: **вектор → обход 1–2 хопа → rerank**

Отмены попадают в контекст **безусловно**, вне конкуренции за места: модификатор может быть непохож на вопрос, но именно он делает ответ верным.



# Доказательство: граф не декорация

---


**Контрольный замер.** Тест `test_graph_disabled_loses_the_annotation`: выключаем граф — пометка об отмене исчезает.

**На живой модели платформы:**

Согласно действующей редакции, с 1 апреля 2026 года отпуск составляет **30 календарных дней**. Прежняя норма (28 дней) применению не подлежит.

**Метрика в проде:** доля ответов со сработавшим ребром `ОТМЕНЯЕТ`. Ноль = граф не работает, как бы хорошо он ни выглядел на демо.


## Security: ACL на каждом узле обхода



Предикат стоит **на каждом узле пути**, а не на финальной выдаче: иначе закрытый документ утекает через **структуру** — факт существования, название, соседей.

Следствие: **факт отмены не раскрывается**, если отменяющий документ недоступен субъекту.

# Границы доверия



| Граница                    | Контроль                   | Что при отказе контроля       |
|----------------------------|----------------------------|-------------------------------|
| Периметр → Control Plane   | OIDC, группы в токене      | доступ под чужим именем       |
| Control Plane → Data Plane | суженный контекст субъекта | выдача сверх прав             |
| Контур → наружу            | список моделей у ключа     | утечка содержимого запроса    |
| Сервис → секреты           | хранилище секретов         | компрометация ключей вендоров |

# Security: проверка «пользователь В» — критерий ТЗ

Один и тот же вопрос, две роли. ЛПА-03 «Регламент доступа к ПДн» закрыт (acl: legal, security).

вопрос: Как обрабатываются персональные данные командированного работника?


роль all → ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-02.3 ЛПА-04.2 ЛПА-01  
ЛПА-03 в выдаче: НЕТ

роль legal → ЛПА-02.3.1 ЛПА-02.1 ЛПА-02.4 ЛПА-03.2 ЛПА-03.4 ЛПА-03  
ЛПА-03 в выдаче: ДА

Пункт ЛПА-02 § 3.1 **ссылается** на ЛПА-03 и приходит обоим. Дальше пути расходятся: у роли all переход по ссылке не выполняется, потому что закрытый узел для неё не существует.

| Проверка                                         | Значение |
|--------------------------------------------------|----------|
| Нарушений ACL на golden set                      | 0        |
| Тест на обоих путях — одиночном и агентном       | ✓        |
| Мандат роли-агента $\subseteq$ прав пользователя | ✓        |


# Guardrails: три слоя и один разрыв между ними



| Слой                                                | Где                 | Статус                                            |
|-----------------------------------------------------|---------------------|---------------------------------------------------|
| Граница контура — модель разрешена ключу            | шлюз                | ✅ <b>работает</b> , проверяется до вызова вендора |
| Вход: инъекции · выход: маска ПДн на потоке         | курсовой контур     | ✅ <b>работает</b> , покрыто тестами               |
| Маскирование ПДн с рехидратацией, fail-closed, SIEM | прокси перед шлюзом | ❌ <b>спроектирован, не развёрнут</b>              |
| Встроенные guardrails LiteLLM                       | шлюз                | ❌ <b>не настроены</b>                             |

**Путь запроса проверен целиком:** `api.zubriq.by` → обратный прокси → ingress → **стоковый образ LiteLLM, один контейнер в поде**. Между клиентом и моделью нет ни одного нашего компонента — sidecar’у перехватить нечего.

# Security: граница контура — одно поле у ключа



Барьер один, проверяем, и приложение не может его расширить.

**Слабость названа честно:** пустой список = видно всё. Умолчание работает в сторону разрешения — это первое, что надо перевернуть.

# Security: роли берутся из подписи

---

Было: роли приходили **в теле запроса** — клиент сам объявлял, что ему можно.

Стало: только из подписанного токена; поле в теле на доступ не влияет вообще.

- фиксированный список асимметричных алгоритмов → подмена `RS256`→`HS256` и `alg: none` отсекаются
- проверка `exp`, `aud`, `iss`, кэш ключей с TTL
- 18 тестов; подделка собирается побайтово — библиотека её сделать не даёт

# Своя дообученная модель: Zubr-VL-32B


QLoRA поверх Qwen3-VL-32B-Instruct на праве Республики Беларусь. **Опубликована** — ArtCloud/Zubr1.5-VL-32B.

|                                 |                                                                                      |
|---------------------------------|--------------------------------------------------------------------------------------|
| Корпус                          | <b>757 НПА</b> (28 кодексов) + 5 545 аналитических статей, 133,4 млн СИМВОЛОВ        |
| Обучение                        | r=16, α=32, 896 тензоров = <b>0,4 %</b> параметров базы; 1 эпоха, 1x H100            |
| Артефакты                       | адаптер 269 МБ · GGUF Q4_K_M 19,8 ГБ · Model Card                                    |
| Сервинг измерен                 | 31–33 ток/с на 4x V100, ~27 ГиБ при контексте 16k                                    |
| <b>Проверка на memorization</b> | корпус в шинглах по 80 символов: <b>97,6 % фрагментов встречаются ровно один раз</b> |

**Оговорка, без которой это было бы рекламой: vision-башня при обучении заморожена, корпус текстовый.** Значит *ВИДИТ* страницу она ровно как базовая Qwen3-VL. Выигрыш — в языке домена: терминология, структура НПА, формулы ссылок и отмен. Поэтому в конвейере ([ADR-0014](#)) она стоит на извлечении связей, а не на распознавании.

**Честный статус:** в каталоге шлюза модель **не заведена** — алиас `zubr` указывает на зеркало. Прямой замер memorization на ней самой не сделан: юнит объявляет `Conflicts=` с боевым, все четыре карты заняты.

# Мультиагентный слой — state machine



4 роли · маршрутизация **правилами** · лимиты шагов, инструментов и токенов · checkpointer по `request_id`

**Права агента = права пользователя  $\cap$  мандат роли**, и пересечение считается в инструменте, а не в промпте.

# Роли-агенты: где именно сужаются права



Пересечение считается **в инструменте**, до обращения к данным — не в промпте и не при сборке ответа.

# MAS: честный результат замера

ADR-0015 требовал измерить три вещи перед принятием. Измерены все три:

| Что                              | Результат                     |
|----------------------------------|-------------------------------|
| Точность маршрутизации           | 13 / 13                       |
| Прирост качества против монолита | нет (recall 1,0 = 1,0)        |
| Стоимость                        | ×3,7 латентности с генерацией |

ADR обязывал: «если иерархия не даст прироста — честно зафиксировать в защите». **Фиксирую: не дала.**

Оправдан требованием ТЗ и **разделением прав**, но не качеством ответов.

## Инфраструктура платформы



Статус сервисов ZubrIQ



All Systems Operational

Доступность платформы ZubrIQ. Проверка каждую минуту из контура Республики Беларусь.



Платформа

100%

ZubrIQ — лендинг

1h



now

100%

ZubrIQ — чат

1h



now

100%

ZubrIQ — API моделей (LiteLLM)

1h



now

100%

ZubrIQ — ответы моделей

1h



now

100%

SearXNG — метапоиск (веб-поиск чата)

1h



now

100%

ZubrIQ — поиск по НПА

1h



now

100%

ZubrIQ — MCP-сервер

1h



now

100%

ZubrIQ Диск

1h



now

100%

ZubrIQ Диск — редактор (Collabora)

1h



now

# Потоковый ответ: источники раньше текста

```
event: meta      {"request_id": "a3f1..."}
event: sources   [{"doc_code": "ЛПА-01", "ordinal": "1"}, ...] ← сначала основания
event: token     "Основной"
event: token     " ежегодный"
event: note      "ЛПА-01 § 1 отменён документом ЛПА-04"
event: done
```

**Источники уходят раньше первого слова.** Для ассистента по нормативным документам цитата важнее скорости появления текста: пользователь сразу видит, на чём будет построен ответ, и может остановиться, если основание не то.

Регрессия, закрытая тестом: контекстные переменные **не переживают yield**. ASGI-сервер шагает генератор в разных контекстах, и обычная `with`-обёртка роняет спан. Родитель передаётся явно — трейс обязан остаться одним и закрытым.


# Наблюдаемость: request\_id открывает трейс

request\_id — это uuid4().hex, ровно 128 бит trace\_id OpenTelemetry. Он не прокидывается атрибутом, а **становится** идентификатором трейса.

|                      |         |                              |
|----------------------|---------|------------------------------|
| ask                  | 2368 мс |                              |
| retrieve.rerank      | 708 мс  | {candidates: 14}             |
| graph.expand + annot | 5,5 мс  |                              |
| llm.generate         | 1611 мс | {model: своя модель контура} |

Содержимое запроса в трейс **не попадает**: трассировка доступна шире, чем сами документы.

# Замеры: где на самом деле время



| Генерация | Реранк | Эмбединг | Обход графа |
|-----------|--------|----------|-------------|
| 68 %      | 30 %   | 1,5 %    | 0,3 %       |

Без генерации реранк занимает **76 %**.

Вопрос «не тормозит ли ваш GraphRAG» закрыт цифрой: граф — три десятых процента.

# Две модели на одном стенде

18.09 модель контура сменилась: MoE Qwen3.6-35B-A3B → плотная Qwen3.8-27B. Перемерил на живом стеке тем же инструментом, 25.09.

| Шаг ask             | Qwen3.6 · 12.09 | Qwen3.8 · 25.09 |               |
|---------------------|-----------------|-----------------|---------------|
| Генерация           | 1 611 мс        | 1 933 мс        | +20 %         |
| Реранк (CPU стенда) | 708 мс          | 1 423 мс        | ×2,0          |
| Обход графа         | 5,5 мс          | 12 мс           | 0,35 % ответа |
| Итого               | 2 368 мс        | 3 468 мс        | +46 %         |

| Движок, 24 клиента    | Qwen3.6 | Qwen3.8    |
|-----------------------|---------|------------|
| Выходных ток/с        | 200     | 218 (+9 %) |
| Первый токен, медиана | 0,59 с  | 1,31 с     |

**Быстрее на бенчмарке, медленнее в продукте.** Плотная модель печатает быстрее, но дольше до первого токена, а у RAG длинный промпт и короткий ответ.

# Своя модель в проде: цифры и рычаги

Реальный трафик ZubrlQ, Qwen3.8, 21–25.09 — метрики vLLM и шлюза, без синтетики.

| Первый токен    | Вызов модели | Генерация | Кеш шлюза (чат) | Prefix-кеш | Шлюз |
|-----------------|--------------|-----------|-----------------|------------|------|
| 1,6 с · p95 9 с | 2,3 с        | 29 ток/с  | 87 % без GPU    | 90 %       | 3 мс |

**Кто грузит модель:** сканер Shield — 57 % вызовов и ~60 % времени модели; чат из-за кеша — лишь 733 вызова из 5 655 запросов. У чата хвост первого токена **18 с** при медиане 1,5.

| Рычаг                            | Эффект                               |
|----------------------------------|--------------------------------------|
| Приоритет чату над Shield в vLLM | хвост первого токена у людей         |
| Shield — вне пиков               | до –60 % времени модели в часы людей |
| Короче контекст RAG              | prefill у Qwen3.8 на 16 % медленнее  |
| <del>max_num_seqs 24 → 96</del>  | в работе максимум 8 — не рычаг       |
| <del>Реранк на сервисе</del>     | сервис теперь на CPU: 1,4 → 3,8 с    |

# Три ошибки вокруг одного числа

---

Пилот платформы: «нарезка с заголовком дала **+22 п.п. hit@1**». Я взял это как основание и разнёс по шести документам.

1. **В пилоте это не измеряли.** 67 % → 89 % — сравнение двух систем, различавшихся размером куска, нарезчиком и реализацией rerank. «Дело в нарезке» — догадка автора.
2. **Я распространил догадку как факт** — потому что она вела туда, куда я и так собирался.
3. **Обнаружив это, я снова не стал мерить.** Построил довод: «адресных вопросов 3 % — 22 пункта они не дадут». Логично, посылка верна, вывод неверен.

**Скепсис без замера — такая же догадка, как утверждение.** И изнутри ощущается так же убедительно.

# Замер вместо рассуждения: 25 кодексов, 12 644 куска

Одна переменная — есть ли заголовок в теле куска. Протокол, нарезка и эталон платформы без изменений.

| Тело куска                 | hit@1  | hit@6  |
|----------------------------|--------|--------|
| полный якорь (как в проде) | 90,2 % | 98,4 % |
| только название статьи     | 90,2 % | 95,1 % |
| только адрес               | 75,4 % | 96,7 % |
| без якоря                  | 73,8 % | 95,1 % |

Якорь даёт +16,4 п.п. — догадка была верной. Но работает название, а не адрес: одно название даёт те же 90,2 %, один адрес — 75,4 %. Не в сумме: название адрес заменяет.

«Статья 164. Банковская гарантия» — метка, написанная человеком. Текст самой нормы этих слов рядом не содержит: норма описывает механизм, а не называет его.

# Замер дал рекомендацию. Рекомендация оказалась не той

Отчёт заканчивался пунктом № 1: **«реранк — на ONNX и в отдельный пул»**. Логично: 76 % времени в одном компоненте.

Проверка разделяющей способности показала другое:

|                    | Худший в корпусе | Лучший вне    | Зазор          |
|--------------------|------------------|---------------|----------------|
| ms-marco-MiniLM    | 8,2658           | 8,9686        | <b>-0,70</b>   |
| bge-reranker-v2-m3 | <b>0,9919</b>    | <b>0,0004</b> | <b>+0,9915</b> |

ONNX ускорил бы модель и **оставил бы главное**: её оценки не калиброваны, порог отказа на них невозможен.

А у платформы ранжирование **уже вынесено на GPU**. Держать свою модель там, где есть сервис, — не независимость, а дублирование.

# Реранк отдан сервису платформы — ADR-0027

Один стенд, одна переменная окружения. healthz 452 против 456 RPS — контроль, что стенд не менялся.

| Сценарий          | Своя модель         | Сервис платформы   |
|-------------------|---------------------|--------------------|
| ask , 1 клиент    | 1,32 RPS · 742 мс   | 5,32 RPS · 177 мс  |
| ask , 8 клиентов  | 1,79 RPS · 4 369 мс | 11,03 RPS · 719 мс |
| Доля реранка      | 96 %                | 68 %               |
| Токенов контекста | 739                 | 604                |

**Главное — не ×4, а изменившийся характер насыщения.** Было: пропускная способность не растёт с параллелизмом (+36 % на восьмикратном росте клиентов) — torch занимает все ядра внутри вызова. Стало: дорогой шаг — ожидание сети, **+107 %**.

ADR-0004 «Vector DB — Qdrant» → superseded . Предметом решения было **не хранилище, а конвейер ранжирования** — ровно то, что за месяц до этого показал пилот платформы: «решает реранкер, а не хранилище».

# Эмбеддер на GPU: перенос вскрыл несуществующий порог

Локальная MiniLM-384 выбиралась под CPU, а не по качеству. Сервис платформы отдаёт **bge-m3** — тот самый, которым считались все замеры качества на боевом корпусе.

| Эмбеддер                 | Худший <b>свой</b> | Лучший <b>чужой</b> | Зазор          |
|--------------------------|--------------------|---------------------|----------------|
| MiniLM-384 (CPU)         | 0,5754             | 0,6655              | <b>-0,0901</b> |
| <b>bge-m3-1024 (GPU)</b> | 0,6760             | 0,6497              | <b>+0,0263</b> |

**У MiniLM зазор отрицательный.** Чужой вопрос ближе к корпусу, чем худший свой: порога, разделяющего одно от другого, на этой модели **не существует** — любое значение либо режет свои вопросы, либо пропускает чужие.

Латентность: медиана 108 → **59 мс**, p90 **159 → 61 мс** — исчез хвост, а не медиана.

# Качество: golden set и гейты

14 кейсов, метрики считаются **без LLM** — объективно и воспроизводимо.

| Метрика                                      | Значение     |
|----------------------------------------------|--------------|
| Context recall                               | 1,0          |
| Нарушений ACL                                | 0            |
| Пометка об отмене                            | 1,0          |
| Честный отказ вне корпуса                    | 1,0          |
| Точность маршрутизации                       | 13/13        |
| <b>Faithfulness</b> (судья на другой модели) | <b>0,923</b> |

Прогон возвращает код 1 при провале — готовый шаг CI. **Локальная конфигурация его возвращает:** после ужесточения гейта «честный отказ» она приёмку не проходит.

# Что нашли замеры, а не тесты

| Найдено                                                       | Было бы в проде                                     |
|---------------------------------------------------------------|-----------------------------------------------------|
| Обход в графе <b>не набирал глубину</b>                       | цепочка отмен обрывалась на первом звене            |
| В запросе <b>не было одного направления ребра</b>             | от отменяющего пункта не виден отменённый           |
| Система отвечала <b>на любой вопрос</b>                       | ответ про спутники со ссылками на отпуск            |
| Текст отказа выдавал <b>существование</b> закрытого документа | утечка через факт существования                     |
| Тест <b>портил права в живой базе</b>                         | демонстрация отмены ломалась молча                  |
| <b>Сам эталон</b> засчитывал шум как успех                    | «не протёк закрытый документ» ≠ «ответил правильно» |

Последнее — про кейс, где ответа для роли в корпусе нет. Эталон проверял только утечку и принимал выдачу из **шести посторонних пунктов**. Проверено по корпусу: журнал аудита упомянут ровно один раз, и в закрытом документе. `refusal_pass` стал гейтом.

# Граф: Neo4j или та же СУБД, где уже лежат векторы

Три бэкенда за одним интерфейсом, один корпус, четыре критерия. Три из четырёх не разделили.

| Критерий           | Neo4j                  | PostgreSQL     |
|--------------------|------------------------|----------------|
| Качество выдачи    | 0 расхождений          | 0 расхождений  |
| Обход при hops=2   | 1,5 мс                 | 2,4 мс         |
| Обход при hops=11  | 13,2 мс                | 2,6 мс         |
| Изоляция окружений | невозможна на инстансе | отдельная база |

Решает онтология и предикат доступа, а не движок. Тот же вывод, что пилот платформы сделал про векторы: «решает реранкер, а не хранилище».

Neo4j Community: база одна на инстанс — CREATE DATABASE не поддерживается. Тест, стейдж и прод делят пространство имён.

Утверждение «в Postgres изоляция — существующая конвенция» я проверил и снял: конвенции в кластере нет, все базы прод без суффиксов. Разделяет не практика, а возможность — её вводим с графа: kb\_graph\_stage / kb\_graph\_prod .

# Граф на боевом корпусе, а не на демо

Демо-ЛПА — 4 документа, 19 чанков. Боевой корпус — **25 кодексов, 7 284 статьи**, в 380 раз больше.

|                               | Значение             |
|-------------------------------|----------------------|
| Рёбер «ссылается на статью N» | <b>2 845</b>         |
| Покрытие графом               | <b>34,6 %</b> статей |
| Сборка графа в PostgreSQL     | 1,6 с                |
| Обход 1–2 хопа                | <b>6–8 мс</b>        |

Прирост достижимости гаснет к третьему хопу: 805 → 904 → 930 узлов. Граф права — **звезда вокруг часто цитируемых норм**, а не длинная цепочка.

**Но ребро ОТМЕНЯЕТ из этого корпуса не строится вовсе.** `pravo.by` отдаёт консолидированную действующую редакцию: отменённый пункт заменён маркером «исключен», его текста нет — указывать ребру не на что. Отмен-статей: **0**.

# Замер нашёл дефект, которого демо не показывало

Первый прогон на боевом корпусе: **один хоп — 492 мс** при том, что весь ответ укладывается в 177 мс.

| Хопов | Было       | Стало         |     |
|-------|------------|---------------|-----|
| 1     | 491,9 мс   | <b>6,4 мс</b> | x77 |
| 3     | 1 236,4 мс | 13,3 мс       | x93 |
| 5     | 2 104,9 мс | 79,7 мс       | x26 |

Представление `graph_neighbours` разрешало ссылку join'ом по `(doc_code, ordinal)` — и Postgres **материализовал его заново на каждом шаге рекурсии**. Исправление: разрешать ссылку в `chunk_id` один раз на сборке.

**Исправление сломало тест паритета** — и правильно: до пункта стало можно дойти и по отмене, и по ссылке, а `DISTINCT ON` выбирал пометку по порядку строк. Приоритет сделан явным: отмена важнее ссылки.

# Сравнение нашло дефект в том, что уже работало

Первый прогон: у Neo4j **12 расхождений** — при зелёных собственных тестах.

ЛПА-03 § 4 → ЛПА-03 § 1      ребро от ПРЕЖНЕЙ редакции правил

`build` работал на одних `MERGE` — это **доливка, а не пересборка**. Что перестало следовать из корпуса, живёт вечно и молча добавляет пункт в обход.

Снос пришлось ограничить кодами документов: инстанс общий, `DETACH DELETE` вынес бы чужое. У Postgres развилки нет — своя база, `TRUNCATE` безопасен.

**Ограничение «база одна на инстанс» заставило написать менее правильный код.** Это и есть аргумент изоляции — на живом дефекте, а не в рассуждении.

# Зачем граф: спрос легко измерить не там

Платформа измерила спрос на исторические вопросы к праву: **0 из 3 738** сообщений пользователей. Вывод напрашивался — механизм есть, спроса нет.

Вывод неверен: смешаны два класса вопросов.

|           | «Что действовало до поправки?» | «Сколько дней отпуска?»          |
|-----------|--------------------------------|----------------------------------|
| спрос     | <b>0 из 3 738</b>              | каждый вопрос к изменённой норме |
| без графа | нет ответа                     | <b>уверенно неверный ответ</b>   |

граф ВКЛЮЧЁН    ЛПА-01 § 1    пометка: отменён документом ЛПА-04

граф ВКЛЮЧЁН    ЛПА-01 § 1    пометка: нет    «29 дней» вместо 30


Граф нужен **не** затем, чтобы отвечать на исторические вопросы, а затем, чтобы **не выдавать отменённую норму за действующую**.

И сразу оговорка, без которой это становится обещанием: гарантия покрывает только отмены, **известные корпусу**. Акт, отменённый тем, чего не загружали, останется действующим — граф этого не заметит по построению.

А на боевом корпусе платформы механизм сверки с источником **существует и написан правильно** — и сверялись им **10 %** документов, а 29 % не сверяются никогда: у них нет адреса источника. По коду этого не видно.

# Экономика: решает утилизация

Железо **арендовано**: 1 200 BYN/мес, всё включено (со слов владельца — договора в репозиториях нет). Наш CapEx — только диски хранилки и свитч, ~\$1,2k. **TCO ≈ \$29,4k за три года**, три четверти — ФОТ.



Линия — **потолок коридора внешнего вендора** (\$0,3–2 за 1М выходных). Порог окупаемости — **~70 % утилизации**: \$9,8k в год ÷ \$2 за 1М = 4 900 млн токенов при потолке ~220 ток/с (Qwen3.8, 24 запроса одновременно). До смены модели, при 506 ток/с и 96 запросах, — ~31 %.

Это модель. Дальше — что показал замер.

Ниже — платим за простой. И покупаем при этом не цену, а юрисдикцию.

# Утилизация измерена: 0,9 %

Тридцать дней, скрейп раз в 15 с, покрытие 99,9 %.

|                                                                    | Значение                |
|--------------------------------------------------------------------|-------------------------|
| Доля времени с ненулевой загрузкой SM                              | 0,9 %                   |
| Средняя занятость VRAM                                             | 62–90 %                 |
| Выходных токенов за месяц (счётчики vLLM)                          | 1 347 948               |
| Месячный объём на полке 506 ток/с (Qwen3.6) · ~220 ток/с (Qwen3.8) | 44 минуты · ~1 ч 42 мин |

Диапазон 5–100 %, которым я оперировал во всех редакциях расчёта, ответа не содержал: он весь выше реальности.

| Цена 1М выходных токенов | Модель при 100 % | Факт при 0,9 % |
|--------------------------|------------------|----------------|
| Инфраструктура           | \$0,33           | ~\$142         |
| С ФОТ                    | \$1,41           | ~\$605         |

На сегодняшнем трафике контур не окупается по цене токена — разрыв с вендорским коридором в два порядка. Оптимизацией инференса он не закрывается: дело не в эффективности, а в спросе.

# Чего сейчас нет

---

- **граф и агентный слой в платформе** — собраны и протестированы, **не встроены**
- **мультимодальный ingestion** — спроектирован, конвейера нет
- ~~эмбеддер на CPU~~ → **перенесён на сервис платформы**, и это вскрыло, что порога отказа на старой модели не существовало
- **сквозной трейсинг** через продукты
- **алерты с runbook'ами**, ретеншн следов
- **видео-демо 5–7 минут по ТЗ** — раскадровка написана, запись не сделана
- **слой маскирования ПДн перед шлюзом** — спроектирован платформой, не развёрнут; встроенные guardrails шлюза пусты
- **red teaming по методике занятия 33** — описан, не применялся
- ~~утилизация инференса не измерена~~ → **измерена: 0,9 %**, и она переворачивает вывод экономики

# Дорожная карта

---

1. **Встроить граф и агентный слой в платформу** — интерфейсы уже совместимы
2. Перевернуть умолчание прав ключа: пусто = только свои модели
3. Тест на схему БД шлюза в CI — иначе счета сломаются молча
4. ~~Реранк на ONNX~~ → **сделано иначе: сервисом платформы** ([ADR-0027](#)). Следующий — эмбеддер на `bge-m3` там же, с переиндексацией
5. Измерить утилизацию инференса — без неё экономика остаётся диапазоном
6. Ретеншн и режим доступа к трассировке
7. Red teaming с ASR-гейтом в CI

# Что получилось: артефакты

```
final-project/  
  infra/      docker-compose: Neo4j · PostgreSQL · Qdrant · OTel · Grafana  
  backend/    3 518 строк кода · 1 634 строки тестов · 103 теста  
  docs/       28 ADR · 9 диаграмм · 5 отчётов с цифрами
```

| Отчёт                          | Что в нём                                             |
|--------------------------------|-------------------------------------------------------|
| <a href="#">load-report</a>    | RPS и латентность по ступеням, разложение по шагам    |
| <a href="#">eval-report</a>    | golden set, гейты приёмки, три разобранные ошибки     |
| <a href="#">eval/ab-anchor</a> | изолированный A/B на 12 644 кусках реального корпуса  |
| <a href="#">graph-backends</a> | сравнение трёх графовых бэкендов по четырём критериям |
| <a href="#">economics/tco</a>  | TCO и себестоимость запроса по утилизации             |

**Репозиторий:** `git.artcloud.by/ai/architect` · внешних зеркал нет намеренно — в пакете реальная топология с адресами и путями Vault.

# Выводы

---

- **Цель достигнута:** блокирующие критерии ТЗ закрыты и подтверждены замерами, а не декларациями
- **Работа делалась на реальной системе** — поэтому в ней есть и техдолг, и отрицательные результаты
- **Легко далось:** проектирование и ADR — навык из уроков 04–08 лёг напрямую
- **Трудно далось:** честные замеры. Каждый прогон находил то, чего не видели тесты
- **Сроки:** 4 месяца, 75 коммитов по проекту (12.05 — 13.09.2026)
- **Полезность курса: 9 / 10** — методики уроков 13–24 использованы напрямую
- **Главный урок:** архитектура, не подтверждённая замером, — это гипотеза

103 теста · 28 ADR · 5 отчётов с цифрами · **четыре отрицательных результата, оставленных как есть**

Отрицательные: мультиагентный слой не дал прироста качества · чужая цифра, взятая без проверки · рекомендация собственного отчёта оказалась не той · **порог окупаемости посчитан верно и оказался бесполезен — фактическая утилизация ниже его в 34 раза.**

# Спасибо

---

## Вопросы?

Александр Зубик · AI Architect · ООО «АртКлауд»

Демонстрация: граф в браузере Neo4j · трейс по `request_id` · дашборд · потоковый ответ