

ZubrIQ

Платформа доступа к языковым моделям в юрисдикции Республики Беларусь

Архитектура работающей системы · не проект, а снимок состояния

Александр Зубик · AI Architect · ООО «АртКлауд»

сентябрь 2026

Что продаём



Три ценности, ради которых платформа существует

	Почему это не решается готовым софтом
Юрисдикция РБ	данные и расчёты в контуре; для части клиентов это условие входа в разговор
Расчёты в BYN	договор с белорусским юрлицом, счета, акты, эквайринг. Зарубежная подписка в валюте для белорусского юрлица — отдельная задача целиком
Единая точка доступа	свои и чужие модели с общим учётом, бюджетами и ключами вместо зоопарка аккаунтов

Чат можно взять открытый, модель — арендовать. Продаётся то, чего в готовых компонентах нет.


Продукты платформы

Продукт	Что это
Чат	собственный, React + Vercel AI SDK; приложение в Google Play
Консоль	организации, ключи, потребление, кошелёк, счета
API моделей	OpenAI-совместимый — то, что покупает разработчик
Drive	документы клиентов в контуре, с онлайн-редактором
Академия	курс → практика в Jupyter → лаборатория → пилот
zq	консольный инструмент разработчика, форк Qwen Code
MCP-шлюз	инструменты для агентов
Builder	конструктор ассистентов


Доступность: что мониторится




Контекст



Контейнеры



Шлюз моделей — центр платформы, а не прокси



Он одновременно выпускает ключи, ведёт бюджеты, считает потребление для счёта и решает, какие модели ключу видны.

Два режима доступа

	Закрытый	Внешний
Куда идёт запрос	свой GPU-бокс	OpenRouter, Mistral, DashScope
Что покидает контур	ничего	промт целиком
Кому	контурные сценарии, чувствительные данные	доступ к сильным проприетарным моделям
Как продаётся	базовый доступ	второй режим, отдельное предложение

Внешний режим — не компромисс, а продукт. Ошибка не в том, что он есть, а в том, кому его выдать.

Барьер — одно поле у ключа

Разрешение живёт при ключе, а не при пользователе, интерфейсе или сети. Проверка стоит **до** вызова вендора.

Что хорошо:

- барьер один и проверяем — посмотреть одно поле
- приложение не может расширить себе доступ
- контурным ключам внешние модели просто не выдаются

Что плохо, и это надо называть:


- **пустое поле = видно всё**, включая внешние модели
- граница **логическая**, сетевого дублирования нет
- пользователю в чате не показано, покинул ли вопрос контур

Собственный инференс

- GPU-бокс: **4x NVIDIA Tesla V100 SXM2 по 16 ГБ**
- vLLM **нативно, без контейнера** — прямой контроль над VRAM и порядком запуска
- Модель: **Qwen3.8-27B, плотная, INT4** (с 18.09.2026 вместо MoE 35B-A3B), tensor-parallel по 4 картам, окно 262K
- Одна модель на текст **и** зрение — вечное имя `zubr`, смена весов не трогает клиентов
- Веса — в объектном хранилище, синхронизация на бокс при старте
- Предыдущая модель оставлена как путь отката

VRAM эксклюзивна. Второй жилец и прод на одном боксе не сосуществуют: пилот свёрнут, VL-модель погашена, эмбединги ушли на CPU.


Путь денег



Учёт пишет тот же компонент, который выполняет запрос — иначе счёт рано или поздно разойдётся с фактом.

Отчётный API шлюза закрыт в бесплатной редакции, поэтому консоль читает его базу напрямую. Цена решения: обновление шлюза может сломать счета **молча**.

Идентификация и права



Единый вход для всех продуктов, группы приходят в токене. Учётные записи — федерацией из внутреннего каталога.

Инфраструктура

Слой	Как устроено
Гипервизор	Proxmox, четыре узла; ВМ и контейнеры описаны кодом
Кластер	Talos Linux: control-plane + группы воркеров, Cilium как CNI и LB
Доставка	GitOps — контроллер приводит кластер к состоянию из репозитория
Состояние	PostgreSQL HA с виртуальным адресом, объектное хранилище, секреты в Vault
Периметр	обратный прокси, wildcard-сертификат через DNS-01
CI	self-hosted GitLab с раннерами, выкаты сериализованы

Кластер поднимается **одним применением**: образ, узлы, сеть, GitOps, сертификаты, мониторинг — без ручных команд.

Переезд в кластер: причиной был инцидент

Шлюз на одиночной ВМ работал **в одном экземпляре**. Каждый выкат означал перезапуск, а перезапуск шлюза — остановку выпуска ключей и отказ всей платформы.

Это вышло наружу: клиент получил ошибку сервера на входе в консольный инструмент ровно во время выката.

Компонент, от которого зависит всё, не может обновляться с простоем.

Кластер дал здесь не моду на Kubernetes, а конкретное свойство: несколько реплик и выкат без остановки.

Откат как часть конструкции

- Старый экземпляр шлюза **намеренно оставлен живым**
- Обе копии смотрят в одну базу — состояния на шлюзе нет
- Откат = вернуть цель имени на периметре, а не восстанавливать из бэкапа

Цена названа прямо: две копии конфигурации, способные разъехаться. Поэтому правило записано в репозитории: каталог моделей править только в кластерной копии.

Честный переезд выглядит так: «переехали, откат жив, вот его цена и когда мы его уберём».

Наблюдаемость

Что	Чем
Трассировка LLM: промпты, стоимость	Langfuse
Метрики и дашборды	Grafana
Ошибки приложений	GlitchTip
Доступность, статус-страница	Uptime Kuma
Веб-аналитика	Matomo, в контуре РБ
SIEM	Wazuh

Чего нет: сквозного трейсинга через продукты. Разбор инцидента — сопоставление по времени между логами продукта, шлюза и трассировкой.

Техдолг — как есть

1. **Две копии конфигурации шлюза** на время переезда
2. **Биллинг читает чужую схему БД напрямую** — сломается молча при обновлении
3. **Пустое поле прав = доступ ко всему**, умолчание в сторону разрешения
4. **Общий ключ векторной базы** на два независимых потребителя — разделение только по именам коллекций
5. **Одна VM совмещает** стейдж, трассировку и зависимости кластерного сервиса — гасить нельзя
6. **Инференс без резерва**: один бокс, VRAM эксклюзивна
7. **Ретеншн не определён** для диалогов, трассировок, логов
8. **Ручные шаги в IaC**: админ-токены двух продуктов — admin-API закрыт в их бесплатных редакциях

Чего не проверял

- **Бэкапы:** система резервного копирования есть, охват и восстановимость не проверены
- **Сетевая сегментация:** правила маршрутизатора не разобрал
- **Порядок подъёма площадки** после полного обесточивания нигде не описан
- **Межарендное разделение** в базе консоли — на уровне запросов не смотрел
- **Тестирование защищённости моделей** — методика есть, к платформе не применялась

Это не «наверное, работает». Это «не проверял, поэтому не утверждаю».

Дорожная карта

Сначала — то, что закрывает названные дыры

1. Погасить старую VM шлюза → снять две копии конфигурации
2. Перевернуть умолчание прав ключа: пусто = только свои модели
3. Тест на схему чужой БД в CI → биллинг перестанет ломаться молча
4. Ретеншн и режим доступа к трассировке
5. Сетевой запрет исходящего для контурных ключей — второй слой под логическим барьером

Потом — расширение

6. Изоляция в векторной базе по токенам, а не по именам
7. Сквозной трейсинг через продукты
8. Резерв инференса и план восстановления площадки

Выводы

- Платформа **работает и продаётся**: восемь продуктов на одном платформенном слое
- Архитектура держится на **одном центре** — шлюзе моделей, и это и сила, и главный риск
- **Граница контура — одно поле у ключа**; барьер проверяем, но однослойный
- Переезд в кластер сделан **по причине**, а не по моде, и остаётся обратимым
- Слабые места названы здесь же — их восемь, и у каждого понятно, что делать

Архитектура, о которой нельзя сказать, что в ней сломано, — это не архитектура, а презентация.

Спасибо

Вопросы?

Александр Зубик · AI Architect · ООО «АртКлауд»

Полное описание архитектуры: zubriq-platform/docs/ — обзор, C4, потоки данных, инвентарь, безопасность, эксплуатация, решения